

Topic Models Shiro:Chapter3 学習アルゴリズム

@anemptyarchive*

2019/11/21-2020/02/04

Contents

はじめに	2
3 学習アルゴリズム	3
3.1 統計的学習アルゴリズム	3
・ KL 情報量	3
3.2 サンプル近似法	3
・ モデルの生成過程	4
3.2.1 ギブスサンプリング	4
・ z_i のサンプリング式の導出	4
・ ϕ_k のサンプリング式の導出	5
・ π のサンプリング式の導出	5
3.2.2 周辺化ギブスサンプリング	6
・ z_i のサンプリング式の導出	6
3.2.3 LDA のギブスサンプリング	7
・ 潜在トピックのサンプリング式の導出	7
・ トピック分布のサンプリング式の導出	8
・ 単語分布のサンプリング式の導出	8
3.2.4 LDA の周辺化ギブスサンプリング	9
・ 潜在トピックのサンプリング式の導出	9
3.3 変分近似法	10
3.3.1 変分法	10
3.3.2 変分ベイズ法 (1)	10
・ 変分下限の導出	11
・ 近似事後分布 $q(z_i)$ の導出	14
・ 近似事後分布 $q(\pi)$ の導出	16
・ 近似事後分布 $q(\phi_k)$ の導出	19
3.3.3 変分ベイズ法 (2)	22
3.3.4 LDA の変分ベイズ法 (準備)	22
・ Dirichlet 分布の期待値の導出	22
・ Dirichlet 分布の KL 情報量の導出	24
3.3.5 LDA の変分ベイズ法 (1)	24
・ 変分下限の導出	24
・ トピック分布の近似事後分布の導出	26
・ 単語分布の近似事後分布の導出	28
・ トピック集合の近似事後分布の導出	30
3.3.6 LDA の変分ベイズ法 (2)	32
・ 変分下限の導出	32
・ トピック分布の近似事後分布のパラメータの導出	35
・ 単語分布の近似事後分布のパラメータの導出	36
3.3.7 LDA の変分ベイズ法 (3)	36
・ 変分下限の導出	37
・ 単語分布の導出	37
3.3.8 LDA の周辺化変分ベイズ法	39

*<https://www.anarchive-beta.com/>

・変分下限の導出	39
・潜在トピックの近似事後分布の導出	40
・テイラー展開による近似	41
3.4 逐次ベイズ学習——変分近似法の場合——	45
3.4.1 確率的最適化と逐次学習	45
・勾配法	45
・確率的勾配法	45
3.4.2 自然勾配法	47
・勾配の導出	47
・フィッシャー情報量	48
・フィッシャー情報行列	50
・KL 情報量とフィッシャー情報行列の関係	50
・勾配の近似	51
3.4.3 LDA の確率的変分ベイズ法	52
・フィッシャー情報行列の導出	52
・変分下限の勾配の導出	54
・更新式の導出	54
・確率的最適化	55
3.5 逐次ベイズ学習——サンプリング近似法の場合——	56
3.5.1 粒子フィルタ	56
・重みの導入	56
・重みの更新式の導出	57
3.5.2 LDA の粒子フィルタ	59
・サンプリング式の導出	59
・重みの更新式の導出	60
・事後分布の近似	61
3.6 Dirichlet 分布のパラメータ推定	61
3.6.1 対象/非対称 Dirichlet 分布の性質	61
3.6.2 変分ベイズ法における Dirichlet 分布のパラメータ推定	61
3.6.3 固定点反復法	61
・変分下限の導出	62
・トピック分布のパラメータの更新式の導出	64
・単語分布のパラメータの更新式の導出	65
3.6.4 ニュートン・ラフソン法	67
・変分下限の導出	67
・テイラー展開による近似	68
・ヘッセ行列の逆行列の導出	70
・ハイパーパラメータの更新式の導出	72
3.6.5 逐次学習—確率的ニュートン・ラフソン法	73
3.6.6 周辺化ギブスサンプリング/変分ベイズ法の場合	73
・周辺化ギブスサンプリングの場合	73
・変分ベイズ法の場合	75

おわりに

77

はじめに

青トピ本に引き続き薄い本 2 冊目です。楽しんで書きました。頑張って読んでください。

3 学習アルゴリズム

3.1 統計的学習アルゴリズム

・KL 情報量

統計モデルの「近さ」(≠ 距離)を表す指標として、カルバック・ライブラー情報量を導入する。

$$\begin{aligned} KL[p^*(x) \| p(x|\phi)] &= \int p^*(x) \log \frac{p^*(x)}{p(x|\phi)} dx \\ &= \int p^*(x) (\log p^*(x) - \log p(x|\phi)) dx \\ &= - \int p^*(x) (\log p(x|\phi) - \log p^*(x)) dx \\ &= - \int p^*(x) \log \frac{p(x|\phi)}{p^*(x)} dx \end{aligned} \tag{3.2}$$

-1 を掛けることで、1 行目の分母分子、あるいは 2 行目の括弧の中を入れ替えることができる。

$$\begin{aligned} KL[p^*(x) \| p(x|\phi)] &= \int p^*(x) \log \frac{p^*(x)}{p(x|\phi)} dx \\ &= \mathbb{E}_{p^*(x)} \left[\log \frac{p^*(x)}{p(x|\phi)} \right] \\ &= \mathbb{E}_{p^*(x)} [\log p^*(x)] - \mathbb{E}_{p^*(x)} [\log p(x|\phi)] \end{aligned} \tag{3.2}$$

確率分布 $p^*(x)$ による期待値とみることができる。

$$\begin{aligned} KL[p^*(x) \| p(x|\phi)] &= \int p^*(x) \log \frac{p^*(x)}{p(x|\phi)} dx \\ &= \int p^*(x) (\log p^*(x) - \log p(x|\phi)) dx \\ &= \int p^*(x) \log p^*(x) dx - \int p^*(x) \log p(x|\phi) dx \\ &= \mathbb{E}_{p^*(x)} [\log p^*(x)] - \mathbb{E}_{p^*(x)} [\log p(x|\phi)] \end{aligned} \tag{3.2}$$

1 行目の分母分子を別々の積分計算に分割することもよく用いる。

その他は省略する。

3.2 サンプリング近似法

確率分布からのサンプリングに基づく近似アルゴリズムについて説明する。

・モデルの生成過程

$$\begin{aligned}x_i &\sim p(x_i|\phi_{z_i}) \\z_i &\sim \text{Multi}(z_i|\boldsymbol{\pi}) \\\phi_k &\sim p(\phi_k|\eta) \\\boldsymbol{\pi} &\sim \text{Dir}(\boldsymbol{\pi}|\alpha)\end{aligned}$$

3.2.1 ギブスサンプリング

$\phi, \boldsymbol{\pi}$ を経由して、潜在変数 $z_{1:n}$ をサンプリングする。

$$p(\mathbf{x}_{1:n}, \phi, \boldsymbol{\pi}|\eta, \alpha) = \sum_{\mathbf{z}_{1:n}} p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \boldsymbol{\pi}|\eta, \alpha)$$

を用いる。

・ z_i のサンプリング式の導出

$$p(z_i = k|\mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i}, \phi, \boldsymbol{\pi}, \eta, \alpha) = \frac{p(z_i = k, \mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i}, \phi, \boldsymbol{\pi}|\eta, \alpha)}{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i}, \phi, \boldsymbol{\pi}|\eta, \alpha)} \quad (3.17)$$

$$\propto p(z_i = k, \mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i}, \phi, \boldsymbol{\pi}|\eta, \alpha) \quad (3.18)$$

$$= p(x_i|z_i = k, \phi)p(\mathbf{x}_{1:n}^{\setminus i}|\mathbf{z}_{1:n}^{\setminus i}, \phi)p(z_i|\boldsymbol{\pi})p(\mathbf{z}_{1:n}^{\setminus i}|\boldsymbol{\pi})p(\phi|\eta)p(\boldsymbol{\pi}|\alpha)$$

$$= \left[\prod_{i'=1}^n p(x_{i'}|z_{i'} = k, \phi)p(z_{i'}|\boldsymbol{\pi}) \right] \left[\prod_{k=1}^K p(\phi_k|\eta) \right] p(\boldsymbol{\pi}|\alpha) \quad (3.19)$$

$$\begin{aligned}\propto p(x_i|z_i = k, \phi)p(z_i|\boldsymbol{\pi}) \\ = p(x_i|\phi_k)p(z_i|\boldsymbol{\pi})\end{aligned} \quad (3.20)$$

【途中式の途中式】

0. $p(A|B, C) = \frac{p(A, B|C)}{p(B|C)}$ より、項を変形する。
1. $z_i = k$ と関係のない分母を省く。
2. 生成過程より分解する。
3. i を含む $i' = 1, 2, \dots, n$ として項をまとめる。また、それぞれ項を分解する。
4. z_i に関係のある項のみを残す。

条件付き独立性から

$$p(z_i = k|\mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i}, \phi, \boldsymbol{\pi}, \eta, \alpha) = p(z_i = k|x_i, \phi_k, \boldsymbol{\pi})$$

である(?)。
これを正規化すると

$$p(z_i = k|x_i, \phi_k, \boldsymbol{\pi}) = \frac{p(x_i|\phi_k)p(z_i = k|\boldsymbol{\pi})}{\sum_{k'=1}^K p(x_i|\phi_{k'})p(z_i = k'|\boldsymbol{\pi})}$$

が得られる。

・ ϕ_k のサンプリング式の導出

$$\begin{aligned}
p(\phi_k | \mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi^{\setminus k}, \boldsymbol{\pi}, \eta, \alpha) &= \frac{p(\phi_k, \mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi^{\setminus k}, \boldsymbol{\pi} | \eta, \alpha)}{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi^{\setminus k}, \boldsymbol{\pi} | \eta, \alpha)} \\
&\propto p(\phi_k, \mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi^{\setminus k}, \boldsymbol{\pi} | \eta, \alpha) \\
&= p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi_k, \phi^{\setminus k}) p(\mathbf{z}_{1:n} | \boldsymbol{\pi}) p(\phi_k, \phi^{\setminus k} | \eta) p(\boldsymbol{\pi} | \alpha) \\
&= \left[\prod_{i=1}^n p(x_i | z_i, \phi) p(z_i | \boldsymbol{\pi}) \right] p(\phi_k | \eta) p(\phi^{\setminus k} | \eta) p(\boldsymbol{\pi} | \alpha) \\
&\propto \left[\prod_{i=1}^n p(x_i | \phi_{z_i})^{\delta(z_i=k)} \right] p(\phi_k | \eta)
\end{aligned}$$

条件付き独立性から

$$p(\phi_k | \mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi^{\setminus k}, \boldsymbol{\pi}, \eta, \alpha) = p(\phi_k | \mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \eta)$$

である。

これを正規化すると

$$p(\phi_k | \mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \eta) = \frac{\left[\prod_{i=1}^n p(x_i | \phi_{z_i})^{\delta(z_i=k)} \right] p(\phi_k | \eta)}{\sum_{k'=1}^K \left[\prod_{i=1}^n p(x_i | \phi_{z_i})^{\delta(z_i=k')} \right] p(\phi_{k'} | \eta)}$$

が得られる。

・ $\boldsymbol{\pi}$ のサンプリング式の導出

$$\begin{aligned}
p(\boldsymbol{\pi} | \mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \eta, \alpha) &= \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \boldsymbol{\pi} | \eta, \alpha)}{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi | \eta, \alpha)} \\
&\propto p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \boldsymbol{\pi} | \eta, \alpha) \\
&= p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi) p(\mathbf{z}_{1:n} | \boldsymbol{\pi}) p(\phi | \eta) p(\boldsymbol{\pi} | \alpha) \\
&= \left[\prod_{i=1}^n p(x_i | z_i, \phi) p(z_i | \boldsymbol{\pi}) \right] \left[\prod_{k=1}^K p(\phi_k | \eta) \right] p(\boldsymbol{\pi} | \alpha) \\
&\propto \left[\prod_{i=1}^n p(z_i | \boldsymbol{\pi}) \right] p(\boldsymbol{\pi} | \alpha) \tag{3.22}
\end{aligned}$$

条件付き独立性から

$$p(\boldsymbol{\pi} | \mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \eta, \alpha) = p(\boldsymbol{\pi} | \mathbf{z}_{1:n}, \alpha)$$

である。

これを正規化すると

$$p(\boldsymbol{\pi} | \mathbf{z}_{1:n}, \alpha) = \frac{\left[\prod_{i=1}^n p(z_i | \boldsymbol{\pi}) \right] p(\boldsymbol{\pi} | \alpha)}{\int \left[\prod_{i=1}^n p(z_i | \boldsymbol{\pi}) \right] p(\boldsymbol{\pi} | \alpha) d\boldsymbol{\pi}}$$

が得られる。

3.2.2 周辺化ギブスサンプリング

ϕ, π を積分消去して、潜在変数 $\mathbf{z}_{1:n}$ のみをサンプリングする。

周辺化した結合確率は

$$p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \eta, \alpha) = \int p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \eta, \alpha) d\phi d\pi$$

となる。

・ z_i のサンプリング式の導出

$$\begin{aligned} p(z_i = k | \mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) &= \frac{p(z_i = k, \mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i} | \eta, \alpha)}{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i} | \eta, \alpha)} \\ &\propto p(z_i = k, \mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i} | \eta, \alpha) \\ &= p(z_i = k, x_i, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i} | \eta, \alpha) \\ &= p(x_i | z_i = k, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) p(z_i = k, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i} | \eta, \alpha) \\ &= p(x_i | z_i = k, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) p(z_i = k | \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) p(\mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i} | \eta, \alpha) \\ &\propto p(x_i | z_i = k, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) p(z_i = k | \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) \end{aligned}$$

【途中式の途中式】

0. $p(A|B, C) = \frac{p(A, B|C)}{p(B|C)}$ より、変形する。
1. $z_i = k$ と関係のない分母を省く。
2. $\mathbf{x}_{1:n}$ を、 i についての x_i とそれ以外の $\mathbf{x}_{1:n}^{\setminus i}$ に分解する。
3. $p(A, B|C) = p(A|B, C)p(B|C)$ より、分解する。
4. $p(A, B|C) = p(A|B, C)p(B|C)$ より、後の項を分解する。
5. i 以外の項を省く。

ここからは、積分消去した ϕ, π を明示して進める。

$$\begin{aligned} p(z_i = k | \mathbf{x}_{1:n}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) &\propto p(x_i | z_i = k, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) p(z_i = k | \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) \\ &= \int p(x_i, \phi | z_i = k, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) d\phi \int p(z_i = k, \pi | \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) d\pi \\ &= \int p(x_i | \phi, z_i = k, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) p(\phi | z_i = k, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) d\phi \\ &\quad * \int p(z_i = k | \pi, \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) p(\pi | \mathbf{x}_{1:n}^{\setminus i}, \mathbf{z}_{1:n}^{\setminus i}, \eta, \alpha) d\pi \\ &= \int p(x_i | \phi, z_i = k) p(\phi_k, \phi^{\setminus k} | \mathbf{z}_{1:n}^{\setminus i}, \mathbf{x}_{1:n}^{\setminus i}, \eta) d\phi_k d\phi^{\setminus k} \int p(z_i = k | \pi) p(\pi | \mathbf{z}_{1:n}^{\setminus i}, \alpha) d\pi \\ &= \int p(x_i | \phi_k) p(\phi_k | \mathbf{z}_{1:n}^{\setminus i}, \mathbf{x}_{1:n}^{\setminus i}, \eta) d\phi_k \int p(\phi^{\setminus k} | \mathbf{z}_{1:n}^{\setminus i}, \mathbf{x}_{1:n}^{\setminus i}, \eta) d\phi^{\setminus k} \int p(z_i = k | \pi) p(\pi | \mathbf{z}_{1:n}^{\setminus i}, \alpha) d\pi \\ &= \int p(x_i | \phi_k) p(\phi_k | \mathbf{z}_{1:n}^{\setminus i}, \mathbf{x}_{1:n}^{\setminus i}, \eta) d\phi_k \int p(z_i = k | \pi) p(\pi | \mathbf{z}_{1:n}^{\setminus i}, \alpha) d\pi \\ &= \mathbb{E}_{p(\phi_k | \mathbf{z}_{1:n}^{\setminus i}, \mathbf{x}_{1:n}^{\setminus i}, \eta)} [p(x_i | \phi_k)] \mathbb{E}_{p(\pi | \mathbf{z}_{1:n}^{\setminus i}, \alpha)} [p(z_i = k | \pi)] \end{aligned} \tag{3.25}$$

【途中式の途中式】

1. 積分消去した確率変数を明示する。
2. $p(A, B|C) = p(A|B, C)p(B|C)$ より、項を分割する。
3. 式を整理する。
 - 条件付き独立性から、影響しない条件を消す。
 - ϕ を、 k についての ϕ_k とそれ以外の $\phi^{\setminus k}$ に分解する。
4. ϕ_k と $\phi^{\setminus k}$ で項を分解する。
5. $\int p(\phi^{\setminus k} | \mathbf{z}_{1:n}^{\setminus i}, \mathbf{x}_{1:n}^{\setminus i}, \eta) d\phi^{\setminus k} = 1$ より消える。
6. 期待値に置き換える。

3.2.3 LDA のギブスサンプリング

LDA のギブスサンプリングを導出する。

結合分布は生成過程より

$$\begin{aligned}
p(\mathbf{w}, \mathbf{z}, \boldsymbol{\theta}, \phi | \boldsymbol{\alpha}, \boldsymbol{\beta}) &= p(\mathbf{w} | \mathbf{z}, \phi) p(\mathbf{z} | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \boldsymbol{\alpha}) p(\phi | \boldsymbol{\beta}) \\
&= \prod_{d=1}^M \prod_{i=1}^{n_d} p(w_{d,i} | z_{d,i}, \phi) p(z_{d,i} | \boldsymbol{\theta}_d) \prod_{d=1}^M p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) \prod_{k=1}^K p(\phi_k | \boldsymbol{\beta})
\end{aligned} \tag{3.27}$$

と分解できる。

・潜在トピックのサンプリング式の導出

$$\begin{aligned}
&p(z_{d,i} = k | w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \phi, \boldsymbol{\theta}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= \frac{p(z_{d,i} = k, w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \phi, \boldsymbol{\theta} | \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \phi, \boldsymbol{\theta} | \boldsymbol{\alpha}, \boldsymbol{\beta})} \\
&\propto p(z_{d,i} = k, w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \phi, \boldsymbol{\theta} | \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= p(w_{d,i} = v | z_{d,i} = k, \phi) p(z_{d,i} = k | \boldsymbol{\theta}_d) p(\mathbf{w}^{\setminus d,i} | \mathbf{z}^{\setminus d,i}, \phi) p(\mathbf{z}^{\setminus d,i} | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \boldsymbol{\alpha}) p(\phi | \boldsymbol{\beta}) \\
&\propto p(w_{d,i} = v | z_{d,i} = k, \phi) p(z_{d,i} = k | \boldsymbol{\theta}_d) \\
&= \phi_{k,v} \theta_{d,k}
\end{aligned} \tag{3.28}$$

条件付き独立性から

$$p(z_{d,i} = k | w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \phi, \boldsymbol{\theta}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = p(z_{d,i} = k | w_{d,i} = v, \phi, \boldsymbol{\theta}) \tag{3.30}$$

である。

これを正規化すると

$$p(z_{d,i} = k | w_{d,i} = v, \phi, \boldsymbol{\theta}) = \frac{\phi_{k,v} \theta_{d,k}}{\sum_{k'=1}^K \phi_{k',v} \theta_{d,k'}} \tag{3.29}$$

が得られる。

・トピック分布のサンプリング式の導出

$$\begin{aligned}
p(\theta_d | \mathbf{w}, \mathbf{z}, \phi, \theta^{\setminus d}, \alpha, \beta) &= \frac{p(\theta_d, \mathbf{w}, \mathbf{z}, \phi, \theta^{\setminus d} | \alpha, \beta)}{p(\mathbf{w}, \mathbf{z}, \phi, \theta^{\setminus d} | \alpha, \beta)} \\
&\propto p(\theta_d, \mathbf{w}, \mathbf{z}, \phi, \theta^{\setminus d} | \alpha, \beta) \\
&= p(\mathbf{w} | \mathbf{z}, \phi) p(\mathbf{z}_d | \theta_d) p(\mathbf{z}^{\setminus d} | \theta^{\setminus d}) p(\theta_d | \alpha) p(\theta^{\setminus d} | \alpha) p(\phi | \beta) \\
&\propto p(\mathbf{z}_d | \theta_d) p(\theta_d | \alpha)
\end{aligned}$$

更に、正規化項を省いた Dirichlet 分布 $p(\theta_d | \alpha) \propto \prod_{k=1}^K \theta_{d,k}^{\alpha_k - 1}$ を用いて

$$\begin{aligned}
p(\theta_d | \mathbf{w}, \mathbf{z}, \phi, \theta^{\setminus d}, \alpha, \beta) &\propto p(\mathbf{z}_d | \theta_d) p(\theta_d | \alpha) \\
&= \prod_{k=1}^K \theta_{d,k}^{n_{d,k}} \prod_{k=1}^K \theta_{d,k}^{\alpha_k - 1} \\
&= \prod_{k=1}^K \theta_{d,k}^{n_{d,k} + \alpha_k - 1}
\end{aligned} \tag{3.31}$$

となる。

また、条件付き独立性から

$$p(\theta_d | \mathbf{w}, \mathbf{z}, \phi, \theta^{\setminus d}, \alpha, \beta) = p(\theta_d | \mathbf{z}_d, \alpha) \tag{3.32}$$

である。

よって、 $p(\theta_d | \mathbf{z}, \alpha)$ は、 $n_{d,k} + \alpha_k$ をパラメータを持つ正規化項のない Dirichlet 分布であることが分かる。従って、正規化する (Dirichlet 分布の正規化項を与える) と

$$p(\theta_d | \mathbf{z}_d, \alpha) = \frac{\Gamma(\sum_{k=1}^K n_{d,k} + \alpha_k)}{\prod_{k=1}^K \Gamma(n_{d,k} + \alpha_k)} \prod_{k=1}^K \theta_{d,k}^{n_{d,k} + \alpha_k} \tag{3.36}$$

が得られる。

・単語分布のサンプリング式の導出

$$\begin{aligned}
p(\phi_k | \mathbf{w}, \mathbf{z}, \phi^{\setminus k}, \theta, \alpha, \beta) &= \frac{p(\phi_k, \mathbf{w}, \mathbf{z}, \phi^{\setminus k}, \theta | \alpha, \beta)}{p(\mathbf{w}, \mathbf{z}, \phi^{\setminus k}, \theta | \alpha, \beta)} \\
&\propto p(\phi_k, \mathbf{w}, \mathbf{z}, \phi^{\setminus k}, \theta | \alpha, \beta) \\
&= p(\mathbf{w} | \mathbf{z}, \phi_k, \phi^{\setminus k}) p(\mathbf{z} | \theta) p(\theta | \alpha) p(\phi_k | \beta) p(\phi^{\setminus k} | \beta) \\
&\propto p(\mathbf{w} | \mathbf{z}, \phi) p(\phi_k | \beta)
\end{aligned}$$

更に、正規化項を省いた Dirichlet 分布 $p(\phi_k | \beta) \propto \prod_{v=1}^V \phi_{k,v}^{\beta_v - 1}$ を用いて

$$\begin{aligned}
p(\phi_k | \mathbf{w}, \mathbf{z}, \phi^{\setminus k}, \boldsymbol{\theta}, \boldsymbol{\alpha}, \boldsymbol{\beta}) &\propto p(\mathbf{w} | \mathbf{z}, \phi) p(\phi_k | \boldsymbol{\beta}) \\
&= \left[\prod_{d=1}^M \prod_{i=1}^{n_d} \prod_{k=1}^K p(w_{d,i} | z_{d,i} = k, \phi_k) \right] p(\phi_k | \boldsymbol{\beta}) \\
&\propto \left[\prod_{d=1}^M \prod_{i=1}^{n_d} p(w_{d,i} | z_{d,i} = k, \phi_k) \right] p(\phi_k | \boldsymbol{\beta}) \\
&\propto \prod_{v=1}^V \phi_{k,v}^{n_{k,v}} \prod_{v=1}^V \phi_{k,v}^{\beta_v - 1} \\
&= \prod_{v=1}^V \phi_{k,v}^{n_{k,v} + \beta_v - 1}
\end{aligned} \tag{3.34}$$

となる。

また、条件付き独立性から

$$p(\phi_k | \mathbf{w}, \mathbf{z}, \phi^{\setminus k}, \boldsymbol{\theta}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = p(\phi_k | \mathbf{w}, \mathbf{z}, \boldsymbol{\beta}) \tag{3.35}$$

である。

よって、 $p(\phi_k | \mathbf{w}, \mathbf{z}, \boldsymbol{\beta})$ は、パラメータ $n_{k,v} + \beta_v$ を持つ正規化項のない Dirichlet 分布であることが分かる。従って、正規化すると

$$p(\phi_k | \mathbf{w}, \mathbf{z}, \boldsymbol{\beta}) = \frac{\Gamma(\sum_{v=1}^V n_{k,v} + \beta_v)}{\prod_{v=1}^V \Gamma(n_{k,v} + \beta_v)} \prod_{v=1}^V \phi_{k,v}^{n_{k,v} + \beta_v - 1} \tag{3.37}$$

が得られる。

3.2.4 LDA の周辺化ギブスサンプリング

LDA の周辺化ギブスサンプリングを導出する。

パラメータ $\phi, \boldsymbol{\theta}$ について周辺化 (積分消去) した

$$p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta}) = \int p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta} | \boldsymbol{\alpha}, \boldsymbol{\beta}) d\phi d\boldsymbol{\theta}$$

を用いる。

・潜在トピックのサンプリング式の導出

$$\begin{aligned}
&p(z_{d,i} = k | w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= \frac{p(z_{d,i} = k, w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i} | \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i} | \boldsymbol{\alpha}, \boldsymbol{\beta})} \\
&\propto p(z_{d,i} = k, w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i} | \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= p(w_{d,i} = v | z_{d,i} = k, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(z_{d,i} = k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(\mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i} | \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&\propto p(w_{d,i} = v | z_{d,i} = k, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(z_{d,i} = k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta})
\end{aligned}$$

ここからは、周辺化したパラメータを明示して進める。

$$\begin{aligned}
& p(z_{d,i} = k | w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) \\
& \propto p(w_{d,i} = v | z_{d,i} = k, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) p(z_{d,i} = k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) \\
& = \int p(w_{d,i} = v, \phi | z_{d,i} = k, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) d\phi \int p(z_{d,i} = k, \theta | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) d\theta \\
& = \int p(w_{d,i} = v | \phi, z_{d,i} = k, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) p(\phi | z_{d,i} = k, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) d\phi \\
& \quad * \int p(z_{d,i} = k | \theta, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) p(\theta | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) d\theta \\
& = \int p(w_{d,i} = v | z_{d,i} = k, \phi) p(\phi | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \beta) d\phi \int p(z_{d,i} = k | \theta) p(\theta | \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}) d\theta \\
& \propto \int p(w_{d,i} = v | \phi_k) p(\phi_k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \beta) d\phi_k \int p(z_{d,i} = k | \theta_d) p(\theta_d | \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}) d\theta_d \\
& = \int \phi_{k,v} p(\phi_k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \beta) d\phi_k \int \theta_{d,k} p(\theta_d | \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}) d\theta_d \\
& = \mathbb{E}_{p(\phi_k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \beta)} [\phi_{k,v}] \mathbb{E}_{p(\theta_d | \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha})} [\theta_{d,k}]
\end{aligned}$$

式 (3.36) と式 (3.37) から $p(\phi_k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \beta)$, $p(\theta_d | \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha})$ も Dirichlet 分布である。よって、正規化した (正規化項を付けた) 上で、Dirichlet 分布の期待値計算 (2.10) を行うと

$$\begin{aligned}
p(z_{d,i} = k | w_{d,i} = v, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \beta) &= \mathbb{E}_{p(\phi_k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \beta)} [\phi_{k,v}] \mathbb{E}_{p(\theta_d | \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha})} [\theta_{d,k}] \\
&= \frac{n_{k,v}^{\setminus d,i} + \beta_v}{\sum_{v'=1}^V n_{k,v'}^{\setminus d,i} + \beta_{v'}} \frac{n_{d,k}^{\setminus d,i} + \alpha_k}{\sum_{k'=1}^K n_{d,k'}^{\setminus d,i} + \alpha_{k'}} \\
&= \frac{n_{k,v}^{\setminus d,i} + \beta_v}{n_{k,\cdot}^{\setminus d,i} + \sum_{v'=1}^V \beta_{v'}} \frac{n_{d,k}^{\setminus d,i} + \alpha_k}{n_d^{\setminus d,i} + \sum_{k'=1}^K \alpha_{k'}} \tag{3.38}
\end{aligned}$$

が得られる。

3.3 変分近似法

変分ベイズ法と呼ばれる決定論的な近似アルゴリズムについて説明する。

3.3.1 変分法

本を参照のこと。

3.3.2 変分ベイズ法 (1)

一般的なモデルにおける変分ベイズ法の導出を行っていく。

- ・ 本節で対象とするモデルの生成過程

$$\begin{aligned}
x_i &\sim p(x_i | \phi_{z_i}) \\
z_i &\sim \text{Multi}(z_i | \boldsymbol{\pi}) \\
\phi_k &\sim p(\phi_k | \eta) \\
\boldsymbol{\pi} &\sim \text{Dir}(\boldsymbol{\pi} | \boldsymbol{\alpha})
\end{aligned}$$

$p(\mathbf{z}_{1:n}, \phi, \pi | \mathbf{x}_{1:n}, \alpha, \eta)$ の計算は難しい。そこで、尤度関数のパラメータを周辺化 (積分消去) し

$$p(\mathbf{x}_{1:n} | \alpha, \eta) = \int \sum_{\mathbf{z}_{1:n}} p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \alpha, \eta) d\phi d\pi$$

更に、対数をとった

$$\log p(\mathbf{x}_{1:n} | \alpha, \eta) = \log \int \sum_{\mathbf{z}_{1:n}} p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \alpha, \eta) d\phi d\pi \quad (3.45)$$

対数周辺尤度を用いる。

・ 変分下限の導出

対数周辺尤度に対して、イエンセンの不等式を用いて

$$\log p(\mathbf{x}_{1:n} | \alpha, \eta) = \log \int \sum_{\mathbf{z}_{1:n}} p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \alpha, \eta) d\phi d\pi \quad (3.45)$$

$$\begin{aligned} &= \log \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}, \phi, \pi) \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \alpha, \eta)}{q(\mathbf{z}_{1:n}, \phi, \pi)} d\phi d\pi \\ &\geq \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}, \phi, \pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \alpha, \eta)}{q(\mathbf{z}_{1:n}, \phi, \pi)} d\phi d\pi \equiv F[q(\mathbf{z}_{1:n}, \phi, \pi)] \end{aligned} \quad (3.50)$$

【途中式の途中式】

1. $\frac{q(\mathbf{z}_{1:n}, \phi, \pi)}{q(\mathbf{z}_{1:n}, \phi, \pi)} = 1$ を掛ける。
2. イエンセンの不等式を用いる。

変分下限 $F[q(\mathbf{z}_{1:n}, \phi, \pi)]$ が得られる。

対数周辺尤度と変分下限との差を求めると

$$\begin{aligned} &\log p(\mathbf{x}_{1:n} | \alpha, \eta) - F[q(\mathbf{z}_{1:n}, \phi, \pi)] \\ &= \sum_{\mathbf{z}_{1:n}} \int q(\mathbf{z}_{1:n}, \phi, \pi) \log p(\mathbf{x}_{1:n} | \alpha, \eta) d\phi d\pi - \sum_{\mathbf{z}_{1:n}} \int q(\mathbf{z}_{1:n}, \phi, \pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \alpha, \eta)}{q(\mathbf{z}_{1:n}, \phi, \pi)} d\phi d\pi \\ &= \sum_{\mathbf{z}_{1:n}} \int q(\mathbf{z}_{1:n}, \phi, \pi) \left(\log p(\mathbf{x}_{1:n} | \alpha, \eta) - \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \alpha, \eta)}{q(\mathbf{z}_{1:n}, \phi, \pi)} \right) d\phi d\pi \\ &= \sum_{\mathbf{z}_{1:n}} \int q(\mathbf{z}_{1:n}, \phi, \pi) \log \frac{p(\mathbf{x}_{1:n} | \alpha, \eta) q(\mathbf{z}_{1:n}, \phi, \pi)}{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi | \alpha, \eta)} d\phi d\pi \\ &= \sum_{\mathbf{z}_{1:n}} \int q(\mathbf{z}_{1:n}, \phi, \pi) \log \frac{q(\mathbf{z}_{1:n}, \phi, \pi)}{p(\mathbf{z}_{1:n}, \phi, \pi | \mathbf{x}_{1:n}, \alpha, \eta)} d\phi d\pi \\ &= \text{KL}[q(\mathbf{z}_{1:n}, \phi, \pi) \parallel p(\mathbf{z}_{1:n}, \phi, \pi | \mathbf{x}_{1:n}, \alpha, \eta)] \end{aligned} \quad (\text{A.2})$$

【途中式の途中式】

0. 変分下限の式と形を揃えるため、対数周辺尤度に $\sum_{\mathbf{z}_{1:n}} \int q(\mathbf{z}_{1:n}, \phi, \pi) d\phi d\pi = 1$ を掛ける。
1. 括弧でくくる。
2. $\log A - \log \frac{B}{C} = \log(A \frac{C}{B})$ の変形を行う。

3. ベイズの定理 $\frac{p(A,B|C)}{p(A|C)} = p(B|A, C)$ より、 $\frac{p(\mathbf{x}_{1:n}|\alpha, \eta)}{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi|\alpha, \eta)} = \frac{1}{p(\mathbf{z}_{1:n}, \phi, \pi|\mathbf{x}_{1:n}, \alpha, \eta)}$ である。

4. KL 情報量に置き換える。

近似事後分布 $q(\mathbf{z}_{1:n}, \phi, \pi)$ と $p(\mathbf{z}_{1:n}, \phi, \pi|\mathbf{x}_{1:n}, \alpha, \eta)$ の KL 情報量になることが分かる。

またここから、対数周辺尤度と変分下限、KL 情報量は

$$\log p(\mathbf{x}_{1:n}|\alpha, \eta) = F[q(\mathbf{z}_{1:n}, \phi, \pi)] + \text{KL}[q(\mathbf{z}_{1:n}, \phi, \pi) \| p(\mathbf{z}_{1:n}, \phi, \pi|\mathbf{x}_{1:n}, \alpha, \eta)] \quad (3.46)$$

の関係を満たすことが分かる。

従って、変分下限を最大 (KL 情報量を最小) にする $q(\mathbf{z}_{1:n}, \phi, \pi)$ を求めることで、対数周辺尤度を最大化できることが分かる。(図 3.3)

更に、変分下限は

$$\begin{aligned} F[q(\mathbf{z}_{1:n}, \phi, \pi)] &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}, \phi, \pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \phi, \pi|\alpha, \eta)}{q(\mathbf{z}_{1:n}, \phi, \pi)} d\phi d\pi \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\phi, \pi) p(\phi|\eta) p(\pi|\alpha)}{q(\mathbf{z}_{1:n}) q(\phi) q(\pi)} d\phi d\pi \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \left(\log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\phi, \pi)}{q(\mathbf{z}_{1:n})} + \log \frac{p(\phi|\eta)}{q(\phi)} + \log \frac{p(\pi|\alpha)}{q(\pi)} \right) d\phi d\pi \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \\ &\quad + \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\phi|\eta)}{q(\phi)} d\phi d\pi + \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\pi|\alpha)}{q(\pi)} d\phi d\pi \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \\ &\quad + \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\pi) d\pi \int q(\phi) \log \frac{p(\phi|\eta)}{q(\phi)} d\phi + \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) d\phi \int q(\pi) \log \frac{p(\pi|\alpha)}{q(\pi)} d\pi \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \\ &\quad + \sum_{k=1}^K \int q(\phi_k) \log \frac{p(\phi_k|\eta)}{q(\phi_k)} d\phi_k + \int q(\pi) \log \frac{p(\pi|\alpha)}{q(\pi)} d\pi \end{aligned} \quad (3.50)$$

【途中式の途中式】

1. 因子分解仮定 (3.42)、生成過程より、それぞれ分解する。
2. $\log(AB) = \log A + \log B$ の変形を行う。
3. 括弧を展開する。
4. 式を整理する。
5. $\sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) = \int q(\phi) d\phi = \int q(\pi) d\pi = 1$ より消える。

となる。ここから更に、KL 情報量の形にしていく。

$$\begin{aligned}
F[q(\mathbf{z}_{1:n}, \phi, \pi)] &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \\
&\quad + \sum_{k=1}^K \int q(\phi_k) \log \frac{p(\phi_k | \eta)}{q(\phi_k)} d\phi_k + \int q(\pi) \log \frac{p(\pi | \alpha)}{q(\pi)} d\pi \\
&= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \\
&\quad + \sum_{k=1}^K \int q(\phi_k) (\log p(\phi_k | \eta) - \log q(\phi_k)) d\phi_k + \int q(\pi) (\log p(\pi | \alpha) - \log q(\pi)) d\pi \\
&= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \\
&\quad - \sum_{k=1}^K \int q(\phi_k) (-\log p(\phi_k | \eta) + \log q(\phi_k)) d\phi_k - \int q(\pi) (-\log p(\pi | \alpha) + \log q(\pi)) d\pi \\
&= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \\
&\quad - \sum_{k=1}^K \int q(\phi_k) \log \frac{q(\phi_k)}{p(\phi_k | \eta)} d\phi_k - \int q(\pi) \log \frac{q(\pi)}{p(\pi | \alpha)} d\pi \\
&= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \tag{3.52}
\end{aligned}$$

$$- \sum_{k=1}^K \text{KL}[q(\phi_k) \parallel p(\phi_k | \eta)] - \text{KL}[q(\pi) \parallel p(\pi | \alpha)] \tag{3.53}$$

【途中式の途中式】

1. $\log \frac{A}{B} = \log A - \log B$ の変形を行う。
2. 元の分母分子を入れ替えるために、括弧から -1 を括り出す。
3. $-\log A + \log B = \log \frac{B}{A}$ の変形を行う。
4. KL 情報量に置き換える。

式 (3.52) について

$$\begin{aligned}
\log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi) &= \log \prod_{i=1}^n p(x_i, z_i | \phi, \pi) \\
&= \sum_{i=1}^n \log p(x_i, z_i | \phi, \pi)
\end{aligned}$$

であり、また

$$\begin{aligned}
\sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \log q(\mathbf{z}_{1:n}) &= \sum_{i=1}^n \sum_{z_i} q(z_i) \log q(z_i) \\
&= \sum_{i=1}^n \sum_{k=1}^K q(z_i = k) \log q(z_i = k)
\end{aligned}$$

である。よって、式 (3.52) は

$$\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi)}{q(\mathbf{z}_{1:n})} d\phi d\pi \quad (3.52)$$

$$\begin{aligned} &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \left(\log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi) - \log q(\mathbf{z}_{1:n}) \right) d\phi d\pi \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi) d\phi d\pi - \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log q(\mathbf{z}_{1:n}) d\phi d\pi \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi) d\phi d\pi - \int q(\phi) q(\pi) d\phi d\pi \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \log q(\mathbf{z}_{1:n}) \\ &= \int \sum_{i=1}^n \sum_{z_i} q(z_i) q(\phi) q(\pi) \log p(x_i, z_i | \phi, \pi) d\phi d\pi - \sum_{i=1}^n \sum_{k=1}^K q(z_i = k) \log q(z_i = k) \end{aligned} \quad (3.55)$$

【途中式の途中式】

1. $\log \frac{A}{B} = \log A - \log B$ の変形を行う。
2. 括弧を展開する。
3. 式を整理する。
4. 式を整理する。
 - $\int q(\phi) d\phi = \int q(\pi) d\pi = 1$ より消える。
 - 式を置き換える。

となる。従って、変分下限は

$$\begin{aligned} F[q(\mathbf{z}_{1:n}, \phi, \pi)] &= \int \sum_{i=1}^n \sum_{z_i} q(z_i) q(\phi) q(\pi) \log p(x_i, z_i | \phi, \pi) d\phi d\pi - \sum_{i=1}^n \sum_{k=1}^K q(z_i = k) \log q(z_i = k) \\ &\quad + \sum_{k=1}^K \int q(\phi_k) \log \frac{p(\phi_k | \eta)}{q(\phi_k)} d\phi_k + \int q(\pi) \log \frac{p(\pi | \alpha)}{q(\pi)} d\pi \\ &= \int \sum_{i=1}^n \sum_{z_i} q(z_i) q(\phi) q(\pi) \log p(x_i, z_i | \phi, \pi) d\phi d\pi - \sum_{i=1}^n \sum_{k=1}^K q(z_i = k) \log q(z_i = k) \\ &\quad - \sum_{k=1}^K \text{KL}[q(\phi_k) \parallel p(\phi_k | \eta)] - \text{KL}[q(\pi) \parallel p(\pi | \alpha)] \end{aligned}$$

になる。

・近似事後分布 $q(z_i)$ の導出

変分下限 $F[q(\mathbf{z}_{1:n}, \phi, \pi)]$ から $q(z_i)$ に関係のある項のみ取り出して $\tilde{F}[q(z_i)]$ とおく (取り出さなくとも変分の時点で消えてしまう (たぶん))。

$$\begin{aligned} \tilde{F}[q(z_i)] &= \int \sum_{z_i} q(z_i) q(\phi) q(\pi) \log p(x_i, z_i | \phi, \pi) d\phi d\pi - \sum_{k=1}^K q(z_i = k) \log q(z_i = k) \\ &= \sum_{k=1}^K q(z_i = k) \int q(\phi) q(\pi) \log p(x_i, z_i = k | \phi, \pi) d\phi d\pi - \sum_{k=1}^K q(z_i = k) \log q(z_i = k) \end{aligned} \quad (3.56)$$

z_i についてのみ取り出したので、 $z_1, z_2, \dots, z_{i-1}, z_{i+1}, \dots, z_n$ は含まれない。

・ 正攻法 Ver

制約 $\sum_{k=1}^K q(z_i = k) = 1$ の下での最適化問題として、ラグランジュ乗数 λ を用いて、ラグランジュ関数 $L[q(z_i)]$ を置く。

$$L[q(z_i)] = \sum_{k=1}^K q(z_i = k) \int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi - \sum_{k=1}^K q(z_i = k) \log q(z_i = k) + \lambda \left(1 - \sum_{k=1}^K q(z_i = k) \right)$$

この式を $q(z_i = k)$ に関して変分する。

$$\begin{aligned} \frac{\partial L[q(z_i)]}{\partial q(z_i = k)} &= \int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi - \log q(z_i = k) - q(z_i = k) \frac{1}{q(z_i = k)} - \lambda \\ &= \int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi - \log q(z_i = k) - 1 - \lambda \end{aligned} \quad (3.57)$$

$\frac{\partial L[q(z_i)]}{\partial q(z_i = k)} = 0$ となる $q(z_i = k)$ を求める。

$$\int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi - \log q(z_i = k) - 1 - \lambda = 0 \quad (3.57)$$

$$\begin{aligned} \log q(z_i = k) &= \int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi - 1 - \lambda \\ q(z_i = k) &= \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi - 1 - \lambda \right] \end{aligned} \quad (3.58)$$

制約条件 $\sum_{k=1}^K q(z_i = k) = 1$ に代入すると

$$\begin{aligned} \sum_{k=1}^K \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi - 1 - \lambda \right] &= 1 \\ \exp[-1 - \lambda] \sum_{k=1}^K \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi \right] &= 1 \\ \exp[-1 - \lambda] &= \frac{1}{\sum_{k=1}^K \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi \right]} \end{aligned}$$

となる。これを式 (3.58) に代入すると

$$q(z_i = k) = \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi - 1 - \lambda \right] \quad (3.58)$$

$$\begin{aligned} &= \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi \right] \exp[-1 - \lambda] \\ &= \frac{\exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k|\phi, \pi) d\phi d\pi \right]}{\sum_{k'=1}^K \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k'|\phi, \pi) d\phi d\pi \right]} \end{aligned} \quad (3.60)$$

が得られる。

・工夫 Ver

$$\tilde{F}[q(z_i = k)] = \sum_{k=1}^K f(z_i = k, q)$$

とおくと、 $f(z_i = k, q)$ は

$$f(z_i = k, q) = q(z_i = k) \int q(\phi)q(\pi) \log p(x_i, z_i = k | \phi, \pi) d\phi d\pi - q(z_i = k) \log q(z_i = k)$$

である。この式を $q(z_i = k)$ に関して変分する。

$$\begin{aligned} \frac{\partial f(z_i = k, q)}{\partial q(z_i = k)} &= \int q(\phi)q(\pi) \log p(x_i, z_i = k | \phi, \pi) d\phi d\pi - \log q(z_i = k) - q(z_i = k) \frac{1}{q(z_i = k)} \\ &= \int q(\phi)q(\pi) \log p(x_i, z_i = k | \phi, \pi) d\phi d\pi - \log q(z_i = k) - 1 \end{aligned}$$

$\frac{\partial f(z_i = k, q)}{\partial q(z_i = k)} = 0$ となる $q(z_i = k)$ を求める。

$$\int q(\phi)q(\pi) \log p(x_i, z_i = k | \phi, \pi) d\phi d\pi - \log q(z_i = k) - 1 = 0$$

$$\log q(z_i = k) = \int q(\phi)q(\pi) \log p(x_i, z_i = k | \phi, \pi) d\phi d\pi - 1$$

$$\begin{aligned} q(z_i = k) &= \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k | \phi, \pi) d\phi d\pi - 1 \right] \\ &\propto \exp \left[\int q(\phi)q(\pi) \log p(x_i, z_i = k | \phi, \pi) d\phi d\pi \right] \end{aligned}$$

$\exp[-1]$ は $z_i = k$ に無関係な定数因子なので省き、 $q(z_i = k)$ との比例関係に注目する。

この式を正規化 (和が 1 となるように) する。ここでは、1 から K までの和をとったもので割ると、式 (3.60) になることが確認できる。

・近似事後分布 $q(\pi)$ の導出

続いて、変分下限 $F[q(z_{1:n}, \phi, \pi)]$ から $q(\pi)$ に関係のある項のみ取り出して $\tilde{F}[q(\pi)]$ とおく。

$$\tilde{F}[q(\pi)] = \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi) d\phi d\pi + \int q(\pi) \log \frac{p(\pi | \alpha)}{q(\pi)} d\pi$$

・正攻法 Ver

制約条件 $\int q(\pi) d\pi = 1$ から、ラグランジュ乗数 λ を用いて、ラグランジュ関数 $L[q(\pi)]$ をおき、制約付き最適化問題として解く。

$$\begin{aligned}
L[q(\boldsymbol{\pi})] &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi})q(\boldsymbol{\pi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi}d\boldsymbol{\pi} \\
&\quad + \int q(\boldsymbol{\pi}) \log \frac{p(\boldsymbol{\pi}|\alpha)}{q(\boldsymbol{\pi})}d\boldsymbol{\pi} + \lambda \left(1 - \int q(\boldsymbol{\pi})d\boldsymbol{\pi}\right) \\
&= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi})q(\boldsymbol{\pi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi}d\boldsymbol{\pi} \\
&\quad + \int q(\boldsymbol{\pi}) \left(\log p(\boldsymbol{\pi}|\alpha) - \log q(\boldsymbol{\pi}) \right) d\boldsymbol{\pi} + \lambda \left(1 - \int q(\boldsymbol{\pi})d\boldsymbol{\pi}\right) \\
&= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi})q(\boldsymbol{\pi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi}d\boldsymbol{\pi} \\
&\quad + \int q(\boldsymbol{\pi}) \log p(\boldsymbol{\pi}|\alpha)d\boldsymbol{\pi} - \int q(\boldsymbol{\pi}) \log q(\boldsymbol{\pi})d\boldsymbol{\pi} + \lambda \left(1 - \int q(\boldsymbol{\pi})d\boldsymbol{\pi}\right)
\end{aligned}$$

この式を $q(\boldsymbol{\pi})$ に関して変分する。

$$\begin{aligned}
\frac{\partial L[q(\boldsymbol{\pi})]}{\partial q(\boldsymbol{\pi})} &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi} \\
&\quad + \log p(\boldsymbol{\pi}|\alpha) - \log q(\boldsymbol{\pi}) - q(\boldsymbol{\pi}) \frac{1}{q(\boldsymbol{\pi})} - \lambda \\
&= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi} \\
&\quad + \log p(\boldsymbol{\pi}|\alpha) - \log q(\boldsymbol{\pi}) - 1 - \lambda
\end{aligned}$$

$\frac{\partial L[q(\boldsymbol{\pi})]}{\partial q(\boldsymbol{\pi})} = 0$ となる $q(\boldsymbol{\pi})$ を求める。

$$\begin{aligned}
\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi} + \log p(\boldsymbol{\pi}|\alpha) - \log q(\boldsymbol{\pi}) - 1 - \lambda &= 0 \\
\log q(\boldsymbol{\pi}) &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi} + \log p(\boldsymbol{\pi}|\alpha) - 1 - \lambda \\
q(\boldsymbol{\pi}) &= \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi} + \log p(\boldsymbol{\pi}|\alpha) - 1 - \lambda \right] \\
&= p(\boldsymbol{\pi}|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi} \right] \exp[-1 - \lambda]
\end{aligned}$$

制約条件 $\int q(\boldsymbol{\pi})d\boldsymbol{\pi} = 1$ に代入すると

$$\begin{aligned}
\int p(\boldsymbol{\pi}|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi} \right] \exp[-1 - \lambda]d\boldsymbol{\pi} &= 1 \\
\exp[-1 - \lambda] &= \frac{1}{\int p(\boldsymbol{\pi}|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\phi}, \boldsymbol{\pi})d\boldsymbol{\phi} \right] d\boldsymbol{\pi}}
\end{aligned}$$

となる。これを上の式に代入すると

$$q(\boldsymbol{\pi}) = \frac{p(\boldsymbol{\pi}|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} \right]}{\int p(\boldsymbol{\pi}|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} \right] d\boldsymbol{\pi}}$$

が得られる。次で求める式 (3.66) を正規化したものと等しくなることが確認できる。

・工夫 Ver

$$\tilde{F}[q(\boldsymbol{\pi})] = \int f(\boldsymbol{\pi}, q) d\boldsymbol{\pi}$$

とおくと、 $f(\boldsymbol{\pi}, q)$ は

$$\begin{aligned} f(\boldsymbol{\pi}, q) &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) q(\boldsymbol{\pi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} + q(\boldsymbol{\pi}) \log \frac{p(\boldsymbol{\pi}|\alpha)}{q(\boldsymbol{\pi})} \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) q(\boldsymbol{\pi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} + q(\boldsymbol{\pi}) \left(\log p(\boldsymbol{\pi}|\alpha) - \log q(\boldsymbol{\pi}) \right) \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) q(\boldsymbol{\pi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} + q(\boldsymbol{\pi}) \log p(\boldsymbol{\pi}|\alpha) - q(\boldsymbol{\pi}) \log q(\boldsymbol{\pi}) \end{aligned} \quad (3.63)$$

である。この式を $q(\boldsymbol{\pi})$ に関して変分する。

$$\begin{aligned} \frac{\partial f(\boldsymbol{\pi}, q)}{\partial q(\boldsymbol{\pi})} &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} + \log p(\boldsymbol{\pi}|\alpha) - \log q(\boldsymbol{\pi}) - q(\boldsymbol{\pi}) \frac{1}{q(\boldsymbol{\pi})} \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} + \log p(\boldsymbol{\pi}|\alpha) - \log q(\boldsymbol{\pi}) - 1 \end{aligned} \quad (3.64)$$

$\frac{\partial f(\boldsymbol{\pi}, q)}{\partial q(\boldsymbol{\pi})} = 0$ となる $q(\boldsymbol{\pi})$ を求める。

$$\begin{aligned} \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} + \log p(\boldsymbol{\pi}|\alpha) - \log q(\boldsymbol{\pi}) - 1 &= 0 \\ \log q(\boldsymbol{\pi}) &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} + \log p(\boldsymbol{\pi}|\alpha) - 1 \\ q(\boldsymbol{\pi}) &= \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} + \log p(\boldsymbol{\pi}|\alpha) - 1 \right] \\ &= p(\boldsymbol{\pi}|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} \right] \exp[-1] \\ &\propto p(\boldsymbol{\pi}|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\boldsymbol{\phi}) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) d\boldsymbol{\phi} \right] \end{aligned} \quad (3.66)$$

更に、生成過程より

$$p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \boldsymbol{\phi}, \boldsymbol{\pi}) = p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \boldsymbol{\phi}) p(\mathbf{z}_{1:n} | \boldsymbol{\pi})$$

と分割できるので、 π と関係のない定数因子を省くと $q(\pi)$ は

$$q(\pi) \propto p(\pi|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi) d\phi \right] \quad (3.66)$$

$$\begin{aligned} &= p(\pi|\alpha) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi) \log \left(p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi) p(\mathbf{z}_{1:n} | \pi) \right) d\phi \right] \\ &\propto p(\pi|\alpha) \exp \left[\sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \log p(\mathbf{z}_{1:n} | \pi) \right] \end{aligned} \quad (3.67)$$

となる。

・ 近似事後分布 $q(\phi_k)$ の導出

最後に、変分下限 $F[q(\mathbf{z}_{1:n}, \phi, \pi)]$ から $q(\phi_k)$ に関係のある項のみを取り出して $\tilde{F}[q(\phi_k)]$ とおく。

ただし、生成過程より

$$p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi) = p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi) p(\mathbf{z}_{1:n} | \pi)$$

と分割でき、また

$$\begin{aligned} p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi) &= \prod_{i=1}^n p(x_i | z_i, \phi) \\ &= \prod_{i=1}^n \prod_{k=1}^K p(x_i | \phi_{z_i})^{\delta(z_i=k)} \\ \log p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi) &= \log \prod_{i=1}^n \prod_{k=1}^K p(x_i | \phi_{z_i})^{\delta(z_i=k)} \\ &= \sum_{i=1}^n \sum_{k=1}^K \delta(z_i = k) \log p(x_i | \phi_{z_i}) \end{aligned}$$

である。よって、変分下限の 1 つ目の因子は

$$\begin{aligned} &\int \sum_{i=1}^n \sum_{z_i} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n} | \phi, \pi) d\phi d\pi \\ &= \int \sum_{i=1}^n \sum_{z_i} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log \left(p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi) p(\mathbf{z}_{1:n} | \pi) \right) d\phi d\pi \\ &= \int \sum_{i=1}^n \sum_{z_i} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \left(\log p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi) + \log p(\mathbf{z}_{1:n} | \pi) \right) d\phi d\pi \\ &= \int \sum_{i=1}^n \sum_{z_i} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log p(\mathbf{x}_{1:n} | \mathbf{z}_{1:n}, \phi) d\phi d\pi + \int \sum_{i=1}^n \sum_{z_i} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \log p(\mathbf{z}_{1:n} | \pi) d\phi d\pi \\ &= \int \sum_{i=1}^n \sum_{z_i} q(\mathbf{z}_{1:n}) q(\phi) q(\pi) \sum_{i=1}^n \sum_{k=1}^K \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\phi d\pi + \int \sum_{i=1}^n \sum_{z_i} q(\mathbf{z}_{1:n}) q(\pi) \log p(\mathbf{z}_{1:n} | \pi) d\pi \end{aligned}$$

となる。

従って、 $\tilde{F}[q(\phi_k)]$ は

$$\tilde{F}[q(\phi_k)] = \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi_k) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\phi_k d\boldsymbol{\pi} + \int q(\phi_k) \log \frac{p(\phi_k | \eta)}{q(\phi_k)} d\phi_k \quad (3.69)$$

である。 $(\sum_{i=1}^n q(z_i = k))$ ではなく $\sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})$ なのは何故だ??)

・ 正攻法 Ver

制約条件 $\int q(\phi_k) d\phi_k = 1$ から、ラグランジュ乗数 λ を用いて、ラグランジュ関数 $L[q(\phi_k)]$ をおき、制約付き最適化問題として解く。

$$\begin{aligned} L[q(\phi_k)] &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi_k) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\phi_k d\boldsymbol{\pi} \\ &\quad + \int q(\phi_k) \log \frac{p(\phi_k | \eta)}{q(\phi_k)} d\phi_k + \lambda \left(1 - \int q(\phi_k) d\phi_k \right) \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi_k) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\phi_k d\boldsymbol{\pi} \\ &\quad + \int q(\phi_k) \left(\log p(\phi_k | \eta) - \log q(\phi_k) \right) d\phi_k + \lambda \left(1 - \int q(\phi_k) d\phi_k \right) \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi_k) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\phi_k d\boldsymbol{\pi} \\ &\quad + \int q(\phi_k) \log p(\phi_k | \eta) d\phi_k - \int q(\phi_k) \log q(\phi_k) d\phi_k + \lambda \left(1 - \int q(\phi_k) d\phi_k \right) \end{aligned}$$

この式を $q(\phi_k)$ に関して変分する。

$$\begin{aligned} \frac{\partial L[q(\phi_k)]}{\partial q(\phi_k)} &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} + \log p(\phi_k | \eta) - \log q(\phi_k) - q(\phi_k) \frac{1}{q(\phi_k)} - \lambda \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} + \log p(\phi_k | \eta) - \log q(\phi_k) - 1 - \lambda \end{aligned}$$

$\frac{\partial L[q(\phi_k)]}{\partial q(\phi_k)} = 0$ となる $q(\phi_k)$ を求める。

$$\begin{aligned} \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} + \log p(\phi_k | \eta) - \log q(\phi_k) - 1 - \lambda &= 0 \\ \log q(\phi_k) &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} + \log p(\phi_k | \eta) - 1 - \lambda \\ q(\phi_k) &= \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} + \log p(\phi_k | \eta) - 1 - \lambda \right] \\ &= \log p(\phi_k | \eta) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} \right] \exp[-1 - \lambda] \end{aligned}$$

制約条件 $\int q(\phi_k) d\phi_k = 1$ に代入すると

$$\int \log p(\phi_k | \eta) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} \right] \exp[-1 - \lambda] d\phi_k = 1$$

$$\exp[-1 - \lambda] = \frac{1}{\int \log p(\phi_k | \eta) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} \right] d\phi_k}$$

となる。これを上の式に代入すると

$$q(\phi_k) = \frac{\log p(\phi_k | \eta) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} \right]}{\int \log p(\phi_k | \eta) \exp \left[\int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) d\boldsymbol{\pi} \right] d\phi_k}$$

が得られる。次で求める式 (3.71) を正規化したものと等しくなることが確認できる。

・工夫 Ver

$$\tilde{F}[q(\phi_k)] = \int f(\phi_k, q) d\phi_k$$

とおくと、 $f(\phi_k, q)$ は

$$\begin{aligned} f(\phi_k, q) &= \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi_k) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) + q(\phi_k) \log \frac{p(\phi_k | \eta)}{q(\phi_k)} \\ &= \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi_k) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) + q(\phi_k) \left(\log p(\phi_k | \eta) - \log q(\phi_k) \right) \\ &= \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) q(\phi_k) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) + q(\phi_k) \log p(\phi_k | \eta) - q(\phi_k) \log q(\phi_k) \end{aligned}$$

である。この式を $q(\phi_k)$ に関して変分する。

$$\begin{aligned} \frac{\partial f(\phi_k, q)}{\partial q(\phi_k)} &= \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) + \log p(\phi_k | \eta) - \log q(\phi_k) - q(\phi_k) \frac{1}{q(\phi_k)} \\ &= \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) + \log p(\phi_k | \eta) - \log q(\phi_k) - 1 \end{aligned} \quad (3.70)$$

$\frac{\partial f(\phi_k, q)}{\partial q(\phi_k)} = 0$ となる $q(\phi_k)$ を求める。

$$\sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) + \log p(\phi_k | \eta) - \log q(\phi_k) - 1 = 0$$

$$\begin{aligned} \log q(\phi_k) &= \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) + \log q(\phi_k | \eta) - 1 \\ q(\phi_k) &= \exp \left[\sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) + \log q(\phi_k | \eta) - 1 \right] \\ &= q(\phi_k | \eta) \exp \left[\sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) \right] \exp[-1] \\ &\propto q(\phi_k | \eta) \exp \left[\sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}) \sum_{i=1}^n \delta(z_i = k) \log p(x_i | \phi_{z_i}) \right] \\ &= q(\phi_k | \eta) \exp \left[\sum_{i=1}^n \sum_{z_i} q(z_i) \delta(z_i = k) \log p(x_i | \phi_{z_i}) \right] \\ &= q(\phi_k | \eta) \exp \left[\sum_{i=1}^n q(z_i = k) \log p(x_i | \phi_k) \right] \end{aligned} \tag{3.71}$$

3.3.3 変分ベイズ法 (2)

本を参照のこと。

3.3.4 LDA の変分ベイズ法 (準備)

・ Dirichlet 分布の期待値の導出

Dirichlet 分布の期待値計算を導出する。

・ プサイ関数

$$\frac{d\Gamma(x)}{dx} = \Psi(x)$$

$$\begin{aligned}
\int p(\boldsymbol{\theta}|\boldsymbol{\alpha})d\boldsymbol{\theta} &= 1 \\
\int \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K \theta_k^{\alpha_k-1} d\boldsymbol{\theta} &= 1 \\
\int \prod_{k=1}^K \theta_k^{\alpha_k-1} d\boldsymbol{\theta} &= \frac{\prod_{k=1}^K \Gamma(\alpha_k)}{\Gamma(\sum_{k=1}^K \alpha_k)} \quad (3.75)
\end{aligned}$$

$$\begin{aligned}
\int \exp \left[\log \left(\prod_{k=1}^K \theta_k^{\alpha_k-1} \right) \right] d\boldsymbol{\theta} &= \frac{\prod_{k=1}^K \Gamma(\alpha_k)}{\Gamma(\sum_{k=1}^K \alpha_k)} \\
\int \exp \left[\sum_{k=1}^K (\alpha_k - 1) \log \theta_k \right] d\boldsymbol{\theta} &= \frac{\prod_{k=1}^K \Gamma(\alpha_k)}{\Gamma(\sum_{k=1}^K \alpha_k)} \quad (3.76)
\end{aligned}$$

$$\begin{aligned}
\log \left(\int \exp \left[\sum_{k=1}^K (\alpha_k - 1) \log \theta_k \right] d\boldsymbol{\theta} \right) &= \log \left(\frac{\prod_{k=1}^K \Gamma(\alpha_k)}{\Gamma(\sum_{k=1}^K \alpha_k)} \right) \\
&= \sum_{k=1}^K \log \Gamma(\alpha_k) - \log \Gamma \left(\sum_{k=1}^K \alpha_k \right) \quad (3.77)
\end{aligned}$$

この式の両辺を α_k で微分する。

$$\begin{aligned}
\frac{1}{\int \exp \left[\sum_{k'=1}^K (\alpha_{k'} - 1) \log \theta_{k'} \right] d\boldsymbol{\theta}} \int \exp \left[\sum_{k'=1}^K (\alpha_{k'} - 1) \log \theta_{k'} \right] d\boldsymbol{\theta} (\log \theta_k) &= \frac{d \log \Gamma(\alpha_k)}{d \alpha_k} - \frac{d \log \Gamma \left(\sum_{k=1}^K \alpha_k \right)}{d \alpha_k} \\
\int (\log \theta_k) \frac{\Gamma(\sum_{k'=1}^K \alpha_{k'})}{\prod_{k'=1}^K \Gamma(\alpha_{k'})} \prod_{k'=1}^K \theta_{k'}^{\alpha_{k'}-1} d\boldsymbol{\theta} &= \Psi(\alpha_k) - \Psi \left(\sum_{k=1}^K \alpha_k \right) \\
\int p(\boldsymbol{\theta}|\boldsymbol{\alpha}) \log \theta_k d\boldsymbol{\theta} &= \Psi(\alpha_k) - \Psi \left(\sum_{k=1}^K \alpha_k \right) \\
\mathbb{E}_{p(\boldsymbol{\theta}|\boldsymbol{\alpha})} [\log \theta_k] &= \Psi(\alpha_k) - \Psi \left(\sum_{k=1}^K \alpha_k \right) \quad (3.79)
\end{aligned}$$

【途中式の途中式】

0. 左辺は合成関数の微分より

- $f' = (\log A)' = \frac{1}{A}$
- $A' = (\exp[B])' = \exp[B]$
- $B' = (\sum_{k=1}^K \alpha_k \log \theta_k - \theta_k)' = \log \theta_k$

1.
 - 左辺の前の項を式 (3.76) より正規化項の逆数に置き換える。
 - 左辺の後の項の $\exp[\log(\cdot)]$ を外す。
 - 右辺をプサイ関数にそれぞれ置き換える。

2. Dirichlet 分布の式を $p(\cdot)$ の表記に戻す。

3. 期待値の計算式になっているため $\mathbb{E}[\cdot]$ の表記に置き換える。

続いて、この期待値計算を用いて、Dirichlet 分布の KL 情報量を求めていく。

・ Dirichlet 分布の KL 情報量の導出

$$\begin{aligned}
\int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \log p(\boldsymbol{\theta}|\boldsymbol{\alpha}) d\boldsymbol{\theta} &= \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K \theta_k^{\alpha_k-1} d\boldsymbol{\theta} \\
&= \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \left(\log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} + \log \prod_{k=1}^K \theta_k^{\alpha_k-1} \right) d\boldsymbol{\theta} \\
&= \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) d\boldsymbol{\theta} \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} + \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \log \prod_{k=1}^K \theta_k^{\alpha_k-1} d\boldsymbol{\theta} \\
&= \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} + \sum_{k=1}^K (\alpha_k - 1) \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \log \theta_k d\boldsymbol{\theta} \\
&= \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} + \sum_{k=1}^K (\alpha_k - 1) \mathbb{E}_{p(\boldsymbol{\theta}|\boldsymbol{\xi})} [\log \theta_k] \tag{3.80}
\end{aligned}$$

これを用いて、KL 情報量は

$$\begin{aligned}
\text{KL}[p(\boldsymbol{\theta}|\boldsymbol{\xi}) \parallel p(\boldsymbol{\theta}|\boldsymbol{\alpha})] &= \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \log \frac{p(\boldsymbol{\theta}|\boldsymbol{\xi})}{p(\boldsymbol{\theta}|\boldsymbol{\alpha})} d\boldsymbol{\theta} \\
&= \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \left(\log p(\boldsymbol{\theta}|\boldsymbol{\xi}) - \log p(\boldsymbol{\theta}|\boldsymbol{\alpha}) \right) d\boldsymbol{\theta} \\
&= \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \log p(\boldsymbol{\theta}|\boldsymbol{\xi}) d\boldsymbol{\theta} - \int p(\boldsymbol{\theta}|\boldsymbol{\xi}) \log p(\boldsymbol{\theta}|\boldsymbol{\alpha}) d\boldsymbol{\theta} \\
&= \log \frac{\Gamma(\sum_{k=1}^K \xi_k)}{\prod_{k=1}^K \Gamma(\xi_k)} + \sum_{k=1}^K (\xi_k - 1) \mathbb{E}_{p(\boldsymbol{\theta}|\boldsymbol{\xi})} [\log \theta_k] \\
&\quad - \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} - \sum_{k=1}^K (\alpha_k - 1) \mathbb{E}_{p(\boldsymbol{\theta}|\boldsymbol{\xi})} [\log \theta_k] \\
&= \log \frac{\Gamma(\sum_{k=1}^K \xi_k)}{\prod_{k=1}^K \Gamma(\xi_k)} - \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} + \sum_{k=1}^K \{(\xi_k - 1) - (\alpha_k - 1)\} \mathbb{E}_{p(\boldsymbol{\theta}|\boldsymbol{\xi})} [\log \theta_k] \\
&= \log \frac{\Gamma(\sum_{k=1}^K \xi_k)}{\prod_{k=1}^K \Gamma(\xi_k)} - \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} + \sum_{k=1}^K (\xi_k - \alpha_k) \mathbb{E}_{p(\boldsymbol{\theta}|\boldsymbol{\xi})} [\log \theta_k] \tag{3.81}
\end{aligned}$$

となる。

3.3.5 LDA の変分ベイズ法 (1)

LDA の変分ベイズ法の導出を行う。この節では、あらかじめ近似事後分布の形を仮定せずに導出する。

・ 変分下限の導出

$\mathbf{z}, \boldsymbol{\phi}, \boldsymbol{\theta}$ について周辺化 (積分消去) して対数をとった対数周辺尤度 $\log p(\mathbf{w}|\boldsymbol{\alpha}, \boldsymbol{\beta})$ に対して、イエンセンの不等式を用いて変分下限を求める。

$$\begin{aligned}
\log p(\mathbf{w}|\boldsymbol{\alpha}, \beta) &= \log \int \sum_{\mathbf{z}} p(\mathbf{w}, \mathbf{z}, \boldsymbol{\phi}, \boldsymbol{\theta}|\boldsymbol{\alpha}, \beta) d\boldsymbol{\phi} d\boldsymbol{\theta} \\
&= \log \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi}) \frac{p(\mathbf{w}, \mathbf{z}, \boldsymbol{\phi}, \boldsymbol{\theta}|\boldsymbol{\alpha}, \beta)}{q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi})} d\boldsymbol{\phi} d\boldsymbol{\theta} \\
&\geq \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi}) \log \frac{p(\mathbf{w}, \mathbf{z}, \boldsymbol{\phi}, \boldsymbol{\theta}|\boldsymbol{\alpha}, \beta)}{q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi})} d\boldsymbol{\phi} d\boldsymbol{\theta} \equiv F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi})]
\end{aligned} \tag{3.82}$$

ここで、近似事後分布は

$$\begin{aligned}
q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi}) &= q(\mathbf{z})q(\boldsymbol{\theta})q(\boldsymbol{\phi}) \\
&= \left[\prod_{d=1}^M \prod_{i=1}^{n_d} q(z_{d,i}) \right] \left[\prod_{d=1}^M q(\boldsymbol{\theta}_d) \right] \left[\prod_{k=1}^K q(\boldsymbol{\phi}_k) \right]
\end{aligned} \tag{3.83}$$

と因子分解できると仮定する。

また、結合分布は生成過程より、ベイズの定理を用いて

$$\begin{aligned}
p(\mathbf{w}, \mathbf{z}, \boldsymbol{\phi}, \boldsymbol{\theta}|\boldsymbol{\alpha}, \beta) &= p(\mathbf{w}, \mathbf{z}|\boldsymbol{\phi}, \boldsymbol{\theta})p(\boldsymbol{\phi}|\beta)p(\boldsymbol{\theta}|\boldsymbol{\alpha}) \\
&= p(\mathbf{w}|\mathbf{z}, \boldsymbol{\phi})p(\mathbf{z}|\boldsymbol{\theta})p(\boldsymbol{\phi}|\beta)p(\boldsymbol{\theta}|\boldsymbol{\alpha}) \\
&= \left[\prod_{d=1}^M \prod_{i=1}^{n_d} p(w_{d,i}|\phi_{z_{d,i}})p(z_{d,i}|\boldsymbol{\theta}_d) \right] \left[\prod_{k=1}^K p(\boldsymbol{\phi}_k|\beta) \right] \left[\prod_{d=1}^M p(\boldsymbol{\theta}_d|\boldsymbol{\alpha}) \right]
\end{aligned} \tag{3.84}$$

となる。

従って、式 (3.83) と式 (3.84) より、変分下限 $F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi})]$ は

$$\begin{aligned}
F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi})] &= \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi}) \log \frac{p(\mathbf{w}, \mathbf{z}, \boldsymbol{\phi}, \boldsymbol{\theta}|\boldsymbol{\alpha}, \beta)}{q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi})} d\boldsymbol{\phi} d\boldsymbol{\theta} \\
&= \int \sum_{\mathbf{z}} q(\mathbf{z})q(\boldsymbol{\theta})q(\boldsymbol{\phi}) \log \frac{p(\mathbf{w}|\mathbf{z}, \boldsymbol{\phi})p(\mathbf{z}|\boldsymbol{\theta})p(\boldsymbol{\phi}|\beta)p(\boldsymbol{\theta}|\boldsymbol{\alpha})}{q(\mathbf{z})q(\boldsymbol{\theta})q(\boldsymbol{\phi})} d\boldsymbol{\phi} d\boldsymbol{\theta} \\
&= \int \sum_{\mathbf{z}} q(\mathbf{z})q(\boldsymbol{\theta})q(\boldsymbol{\phi}) \left(\log p(\mathbf{w}|\mathbf{z}, \boldsymbol{\phi})p(\mathbf{z}|\boldsymbol{\theta}) - \log q(\mathbf{z}) + \log \frac{p(\boldsymbol{\theta}|\boldsymbol{\alpha})}{q(\boldsymbol{\theta})} + \log \frac{p(\boldsymbol{\phi}|\beta)}{q(\boldsymbol{\phi})} \right) d\boldsymbol{\phi} d\boldsymbol{\theta} \\
&= \int \sum_{\mathbf{z}} q(\mathbf{z})q(\boldsymbol{\theta})q(\boldsymbol{\phi}) \log p(\mathbf{w}|\mathbf{z}, \boldsymbol{\phi})p(\mathbf{z}|\boldsymbol{\theta}) d\boldsymbol{\phi} d\boldsymbol{\theta} - \int q(\boldsymbol{\theta})q(\boldsymbol{\phi}) d\boldsymbol{\phi} d\boldsymbol{\theta} \sum_{\mathbf{z}} q(\mathbf{z}) \log q(\mathbf{z}) \\
&\quad + \int \sum_{\mathbf{z}} q(\mathbf{z})q(\boldsymbol{\phi}) d\boldsymbol{\phi} \int q(\boldsymbol{\theta}) \log \frac{p(\boldsymbol{\theta}|\boldsymbol{\alpha})}{q(\boldsymbol{\theta})} d\boldsymbol{\theta} + \int \sum_{\mathbf{z}} q(\mathbf{z})q(\boldsymbol{\theta}) d\boldsymbol{\theta} \int q(\boldsymbol{\phi}) \log \frac{p(\boldsymbol{\phi}|\beta)}{q(\boldsymbol{\phi})} d\boldsymbol{\phi} \\
&= \int \sum_{\mathbf{z}} q(\mathbf{z})q(\boldsymbol{\theta})q(\boldsymbol{\phi}) \log p(\mathbf{w}|\mathbf{z}, \boldsymbol{\phi})p(\mathbf{z}|\boldsymbol{\theta}) d\boldsymbol{\phi} d\boldsymbol{\theta} - \sum_{\mathbf{z}} q(\mathbf{z}) \log q(\mathbf{z}) \\
&\quad + \int q(\boldsymbol{\theta}) \log \frac{p(\boldsymbol{\theta}|\boldsymbol{\alpha})}{q(\boldsymbol{\theta})} d\boldsymbol{\theta} + \int q(\boldsymbol{\phi}) \log \frac{p(\boldsymbol{\phi}|\beta)}{q(\boldsymbol{\phi})} d\boldsymbol{\phi}
\end{aligned} \tag{3.82}$$

【途中式の途中式】

1. 式 (3.83)、式 (3.84) より項を分解する。

2. $\log \frac{AB}{C} = \log A + \log B - \log C$ の変形を行う。
3. 括弧を展開する。
4. $\sum_{\mathbf{z}} q(\mathbf{z}) = \int q(\boldsymbol{\theta}) d\boldsymbol{\theta} = \int q(\phi) d\phi = 1$ であるため消える。

となる。ここから更に、KL 情報量の形にしていく。

$$\begin{aligned}
F[q(\mathbf{z}, \boldsymbol{\theta}, \phi)] &= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}) q(\phi) \log p(\mathbf{w}|\mathbf{z}, \phi) p(\mathbf{z}|\boldsymbol{\theta}) d\phi d\boldsymbol{\theta} - \sum_{\mathbf{z}} q(\mathbf{z}) \log q(\mathbf{z}) \\
&\quad + \int q(\boldsymbol{\theta}) \log \frac{p(\boldsymbol{\theta}|\boldsymbol{\alpha})}{q(\boldsymbol{\theta})} d\boldsymbol{\theta} + \int q(\phi) \log \frac{p(\phi|\beta)}{q(\phi)} d\phi \\
&= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}) q(\phi) \log p(\mathbf{w}|\mathbf{z}, \phi) p(\mathbf{z}|\boldsymbol{\theta}) d\phi d\boldsymbol{\theta} - \sum_{\mathbf{z}} q(\mathbf{z}) \log q(\mathbf{z}) \\
&\quad + \int q(\boldsymbol{\theta}) \left(\log p(\boldsymbol{\theta}|\boldsymbol{\alpha}) - \log q(\boldsymbol{\theta}) \right) d\boldsymbol{\theta} + \int q(\phi) \left(\log p(\phi|\beta) - \log q(\phi) \right) d\phi \\
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{z_{d,i}} q(z_{d,i}) q(\boldsymbol{\theta}_d) q(\phi) \log p(w_{d,i}|z_{d,i}, \phi) p(z_{d,i}|\boldsymbol{\theta}_d) d\phi d\boldsymbol{\theta}_d - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&\quad - \sum_{d=1}^M \int q(\boldsymbol{\theta}_d) \left(-\log p(\boldsymbol{\theta}_d|\boldsymbol{\alpha}) + \log q(\boldsymbol{\theta}_d) \right) d\boldsymbol{\theta}_d - \sum_{k=1}^K \int q(\phi_k) \left(-\log p(\phi_k|\beta) + \log q(\phi_k) \right) d\phi_k \\
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{z_{d,i}} q(z_{d,i}) q(\boldsymbol{\theta}_d) q(\phi) \log p(w_{d,i}|z_{d,i}, \phi) p(z_{d,i}|\boldsymbol{\theta}_d) d\phi d\boldsymbol{\theta}_d - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&\quad - \sum_{d=1}^M \int q(\boldsymbol{\theta}_d) \log \frac{q(\boldsymbol{\theta}_d)}{p(\boldsymbol{\theta}_d|\boldsymbol{\alpha})} d\boldsymbol{\theta}_d - \sum_{k=1}^K \int q(\phi_k) \log \frac{q(\phi_k)}{p(\phi_k|\beta)} d\phi_k \\
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{z_{d,i}} q(z_{d,i}) q(\boldsymbol{\theta}_d) q(\phi) \log p(w_{d,i}|z_{d,i}, \phi) p(z_{d,i}|\boldsymbol{\theta}_d) d\phi d\boldsymbol{\theta}_d - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&\quad - \sum_{d=1}^M \text{KL}[q(\boldsymbol{\theta}_d) \parallel p(\boldsymbol{\theta}_d|\boldsymbol{\alpha})] - \sum_{k=1}^K \text{KL}[q(\phi_k) \parallel p(\phi_k|\beta)] \tag{3.85}
\end{aligned}$$

【途中式の途中式】

1. $\log \frac{A}{B} = \log A - \log B$ の変形を行う。
2.
 - 前の 2 つの因子は、式 (3.84) より項を更に分解する。
 - 後の 2 つの因子は、分母分子を入れ替えるために括弧から -1 を外に出す。
3. $-\log A + \log B = \log \frac{B}{A}$ の変形を行う。
4. KL 情報量に置き換える。

以上で変分下限が求まった。次からは、この変分下限を最大にする近似事後分布を求めていく。

・トピック分布の近似事後分布の導出

変分下限 $F[q(\mathbf{z}_{1:n}, \phi, \boldsymbol{\pi})]$ から、 $q(\boldsymbol{\theta}_d)$ に関係する項のみを取り出して $\tilde{F}[q(\boldsymbol{\theta}_d)]$ とおく。

$$\tilde{F}[q(\boldsymbol{\theta}_d)] = \int q(\boldsymbol{\theta}_d) \sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i}|\boldsymbol{\theta}_d) d\boldsymbol{\theta}_d - \int q(\boldsymbol{\theta}_d) \log \frac{q(\boldsymbol{\theta}_d)}{p(\boldsymbol{\theta}_d|\boldsymbol{\alpha})} d\boldsymbol{\theta}_d \tag{3.86}$$

$q(\boldsymbol{\theta}_d)$ に関する項を取り出したので、 $d = 1, 2, \dots, d-1, d+1, \dots, D$ については含まれない。(頭の $q(\mathbf{z})$ はそのままなのは何故??)

$\tilde{F}[q(\boldsymbol{\theta}_d)] = \int f(\boldsymbol{\theta}_d, q(\boldsymbol{\theta}_d)) d\boldsymbol{\theta}_d$ とすると、 $f(\boldsymbol{\theta}_d, q(\boldsymbol{\theta}_d))$ は

$$\begin{aligned} f(\boldsymbol{\theta}_d, q(\boldsymbol{\theta}_d)) &= q(\boldsymbol{\theta}_d) \sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) - q(\boldsymbol{\theta}_d) \log \frac{q(\boldsymbol{\theta}_d)}{p(\boldsymbol{\theta}_d | \boldsymbol{\alpha})} \\ &= q(\boldsymbol{\theta}_d) \sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) - q(\boldsymbol{\theta}_d) (\log q(\boldsymbol{\theta}_d) - \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha})) \\ &= q(\boldsymbol{\theta}_d) \sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) - q(\boldsymbol{\theta}_d) \log q(\boldsymbol{\theta}_d) + q(\boldsymbol{\theta}_d) \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) \end{aligned}$$

である。この式を $q(\boldsymbol{\theta}_d)$ に関して変分する。

$$\begin{aligned} \frac{\partial f(\boldsymbol{\theta}_d, q(\boldsymbol{\theta}_d))}{\partial q(\boldsymbol{\theta}_d)} &= \sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) - \log q(\boldsymbol{\theta}_d) - q(\boldsymbol{\theta}_d) \frac{1}{q(\boldsymbol{\theta}_d)} + \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) \\ &= \sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) - \log q(\boldsymbol{\theta}_d) + \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) - 1 \end{aligned} \quad (3.87)$$

$\frac{\partial f(\boldsymbol{\theta}_d, q(\boldsymbol{\theta}_d))}{\partial q(\boldsymbol{\theta}_d)} = 0$ となる $q(\boldsymbol{\theta}_d)$ を求める。

$$\begin{aligned} \sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) - \log q(\boldsymbol{\theta}_d) + \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) - 1 &= 0 \\ \log q(\boldsymbol{\theta}_d) &= \sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) + \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) - 1 \\ q(\boldsymbol{\theta}_d) &= \exp \left[\sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) + \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) - 1 \right] \\ &\propto \exp \left[\sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) + \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) \right] \end{aligned}$$

更に、正規化項を省いた Dirichlet 分布 $p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) \propto \prod_{k=1}^K \theta_{d,k}^{\alpha_k - 1}$ を用いて

$$\begin{aligned}
q(\boldsymbol{\theta}_d) &\propto \exp \left[\sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log p(z_{d,i} | \boldsymbol{\theta}_d) + \log p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) \right] \\
&\propto \exp \left[\sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \log \prod_{k=1}^K \theta_{d,k}^{\delta(z_{d,i}=k)} + \log \prod_{k=1}^K \theta_{d,k}^{\alpha_k-1} \right] \\
&= \exp \left[\sum_{\mathbf{z}} q(\mathbf{z}) \sum_{i=1}^{n_d} \sum_{k=1}^K \delta(z_{d,i}=k) \log \theta_{d,k} + \sum_{k=1}^K (\alpha_k - 1) \log \theta_{d,k} \right] \\
&= \exp \left[\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z})}[n_{d,k}] \log \theta_{d,k} + \sum_{k=1}^K (\alpha_k - 1) \log \theta_{d,k} \right] \\
&= \exp \left[\sum_{k=1}^K (\mathbb{E}_{q(\mathbf{z})}[n_{d,k}] + \alpha_k - 1) \log \theta_{d,k} \right] \\
&= \prod_{k=1}^K \theta_{d,k}^{\mathbb{E}_{q(\mathbf{z})}[n_{d,k}] + \alpha_k - 1}
\end{aligned} \tag{3.88}$$

となる。
ここで

$$\xi_{d,k}^\theta = \mathbb{E}_{q(\mathbf{z})}[n_{d,k}] + \alpha_k \tag{3.89}$$

とおくと式 (3.88) から、 $q(\boldsymbol{\theta}_d)$ はパラメータ $\boldsymbol{\xi}_d^\theta = (\xi_{d,1}^\theta, \xi_{d,2}^\theta, \dots, \xi_{d,K}^\theta)$ を持つ正規化項のない Dirichlet 分布の形をしていることが分かる。正規化すると

$$q(\boldsymbol{\theta} | \boldsymbol{\xi}_d^\theta) = \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \xi_{d,k}^\theta} \prod_{k=1}^K \theta_{d,k}^{\xi_{d,k}^\theta - 1} \tag{3.90}$$

が得られる。

・単語分布の近似事後分布の導出

続いて、単語分布の近似事後分布を導出する。

トピック分布と同様に、変分下限 $F[q(\mathbf{z}_{1:n}, \boldsymbol{\phi}, \boldsymbol{\pi})]$ から $\boldsymbol{\phi}_k$ に関係のある項のみ取り出して、 $\hat{F}[\boldsymbol{\phi}_k]$ とおく。

ここで、変分下限の 1 つ目の因子は

$$\begin{aligned}
& \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{z_{d,i}} q(z_{d,i}) q(\boldsymbol{\theta}_d) q(\boldsymbol{\phi}) \log p(w_{d,i} | z_{d,i}, \boldsymbol{\phi}) p(z_{d,i} | \boldsymbol{\theta}_d) d\boldsymbol{\phi} d\boldsymbol{\theta}_d \\
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{z_{d,i}} q(z_{d,i}) q(\boldsymbol{\theta}_d) q(\boldsymbol{\phi}) \log p(w_{d,i} | \boldsymbol{\phi}_{z_{d,i}}) p(z_{d,i} | \boldsymbol{\theta}_d) d\boldsymbol{\phi} d\boldsymbol{\theta}_d \\
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{z_{d,i}} q(z_{d,i}) q(\boldsymbol{\theta}_d) q(\boldsymbol{\phi}) \log \left(\prod_{k=1}^K p(w_{d,i} | \boldsymbol{\phi}_k)^{\delta(z_{d,i}=k)} p(z_{d,i} | \boldsymbol{\theta}_d) \right) d\boldsymbol{\phi} d\boldsymbol{\theta}_d \\
&= \int q(\boldsymbol{\phi}) \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{z_{d,i}} q(\boldsymbol{\theta}_d) q(z_{d,i}) \sum_{k=1}^K \delta(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) p(z_{d,i} | \boldsymbol{\theta}_d) d\boldsymbol{\phi} d\boldsymbol{\theta}_d \\
&= \int q(\boldsymbol{\phi}) \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(\boldsymbol{\theta}_d) q(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) p(z_{d,i} | \boldsymbol{\theta}_d) d\boldsymbol{\phi} d\boldsymbol{\theta}_d \\
&= \int \sum_{k=1}^K q(\boldsymbol{\phi}_k) \sum_{d=1}^M \sum_{i=1}^{n_d} q(\boldsymbol{\theta}_d) q(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) p(z_{d,i} | \boldsymbol{\theta}_d) d\boldsymbol{\phi} d\boldsymbol{\theta}_d \tag{3.91}
\end{aligned}$$

である。(ちよつとよく解ってない...)

$$\tilde{F}[\boldsymbol{\phi}_k] = \int q(\boldsymbol{\phi}_k) \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) d\boldsymbol{\phi}_k - \int q(\boldsymbol{\phi}_k) \log \frac{q(\boldsymbol{\phi}_k)}{p(\boldsymbol{\phi}_k | \boldsymbol{\beta})} d\boldsymbol{\phi}_k \tag{3.92}$$

$q(\boldsymbol{\phi}_k)$ に関係する項を取り出したので、 $k = 1, 2, \dots, k-1, k+1, \dots, K$ については含まれない。

$\tilde{F}[\boldsymbol{\phi}_k] = \int f(\boldsymbol{\phi}_k, q(\boldsymbol{\phi}_k)) d\boldsymbol{\phi}_k$ とすると

$$\begin{aligned}
f(\boldsymbol{\phi}_k, q(\boldsymbol{\phi}_k)) &= q(\boldsymbol{\phi}_k) \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) - q(\boldsymbol{\phi}_k) \log \frac{q(\boldsymbol{\phi}_k)}{p(\boldsymbol{\phi}_k | \boldsymbol{\beta})} \\
&= q(\boldsymbol{\phi}_k) \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) - q(\boldsymbol{\phi}_k) \left(\log q(\boldsymbol{\phi}_k) - \log p(\boldsymbol{\phi}_k | \boldsymbol{\beta}) \right) \\
&= q(\boldsymbol{\phi}_k) \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) - q(\boldsymbol{\phi}_k) \log q(\boldsymbol{\phi}_k) + q(\boldsymbol{\phi}_k) \log p(\boldsymbol{\phi}_k | \boldsymbol{\beta})
\end{aligned}$$

である。

この式を $q(\boldsymbol{\phi}_k)$ に関して変分する。

$$\begin{aligned}
\frac{\partial f(\boldsymbol{\phi}_k, q(\boldsymbol{\phi}_k))}{\partial q(\boldsymbol{\phi}_k)} &= \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) - \log q(\boldsymbol{\phi}_k) - q(\boldsymbol{\phi}_k) \frac{1}{q(\boldsymbol{\phi}_k)} + \log p(\boldsymbol{\phi}_k | \boldsymbol{\beta}) \\
&= \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i}=k) \log p(w_{d,i} | \boldsymbol{\phi}_k) - \log q(\boldsymbol{\phi}_k) + \log p(\boldsymbol{\phi}_k | \boldsymbol{\beta}) - 1 \tag{3.93}
\end{aligned}$$

$\frac{\partial f(\boldsymbol{\phi}_k, q(\boldsymbol{\phi}_k))}{\partial q(\boldsymbol{\phi}_k)} = 0$ となる $q(\boldsymbol{\phi}_k)$ を求める。

$$\begin{aligned}
\sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i} = k) \log p(w_{d,i} | \phi_k) - \log q(\phi_k) + \log p(\phi_k | \beta) - 1 &= 0 \\
\log q(\phi_k) &= \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i} = k) \log p(w_{d,i} | \phi_k) + \log p(\phi_k | \beta) - 1 \\
q(\phi_k) &= \exp \left[\sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i} = k) \log p(w_{d,i} | \phi_k) + \log p(\phi_k | \beta) - 1 \right] \\
&\propto \exp \left[\sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i} = k) \log p(w_{d,i} | \phi_k) + \log p(\phi_k | \beta) \right]
\end{aligned}$$

更に、正規化項を省いた Dirichlet 分布 $p(\phi_k | \beta) \propto \prod_{v=1}^V \phi_{k,v}^{\beta_v - 1}$ を用いて

$$\begin{aligned}
q(\phi_k) &\propto \exp \left[\sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i} = k) \log p(w_{d,i} | \phi_k) + \log p(\phi_k | \beta) \right] \\
&\propto \exp \left[\sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i} = k) \log \prod_{v=1}^V \phi_{k,v}^{\delta(w_{d,i}=v)} + \log \prod_{v=1}^V \phi_{k,v}^{\beta_v - 1} \right] \\
&= \exp \left[\sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{v=1}^V q(z_{d,i} = k) \delta(w_{d,i} = v) \log \phi_{k,v} + \sum_{v=1}^V (\beta_v - 1) \log \phi_{k,v} \right] \\
&= \exp \left[\sum_{v=1}^V \mathbb{E}_{q(z)}[n_{k,v}] \log \phi_{k,v} + \sum_{v=1}^V (\beta_v - 1) \log \phi_{k,v} \right] \\
&= \exp \left[\sum_{v=1}^V (\mathbb{E}_{q(z)}[n_{k,v}] + \beta_v - 1) \log \phi_{k,v} \right] \\
&= \prod_{v=1}^V \phi_{k,v}^{\mathbb{E}_{q(z)}[n_{k,v}] + \beta_v - 1}
\end{aligned} \tag{3.94}$$

となる。
ここで

$$\xi_{k,v}^\phi = \mathbb{E}_{q(z)}[n_{k,v}] + \beta_v \tag{3.95}$$

とおくと式 (3.94) から、 $q(z)$ はパラメータ $\xi_k^\phi = (\xi_{k,1}^\phi, \xi_{k,2}^\phi, \dots, \xi_{k,V}^\phi)$ を持つ正規化項のない Dirichlet 分布の形をしていることが分かる。正規化すると

$$q(\phi_k | \xi_k^\phi) = \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \prod_{v=1}^V \phi_{k,v}^{\xi_{k,v}^\phi - 1} \tag{3.96}$$

が得られる。

・トピック集合の近似事後分布の導出

最後に、トピック集合の近似事後分布を求めていく。

これまでと同様に、変分下限 $F[q(z_{1:n}, \phi, \pi)]$ から $q(z_{d,i})$ に関する項のみ取り出して $\tilde{F}[q(z_{d,i})]$ とする。

$$\begin{aligned}
\tilde{F}[q(z_{d,i})] &= \int \sum_{z_{d,i}} q(z_{d,i}) q(\boldsymbol{\theta}_d) q(\boldsymbol{\phi}) \log \left(p(w_{d,i}|z_{d,i}, \boldsymbol{\phi}) p(z_{d,i}|\boldsymbol{\theta}_d) \right) d\boldsymbol{\phi} d\boldsymbol{\theta}_d - \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&= \sum_{k=1}^K q(z_{d,i} = k) \int q(\boldsymbol{\phi}_k) q(\boldsymbol{\theta}_d) \log \left(p(w_{d,i}|\boldsymbol{\phi}_k) p(z_{d,i} = k|\boldsymbol{\theta}_d) \right) d\boldsymbol{\phi}_k d\boldsymbol{\theta}_d - \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&= \sum_{k=1}^K q(z_{d,i} = k) \int q(\boldsymbol{\phi}_k) q(\boldsymbol{\theta}_d) \log(\phi_{k,w_{d,i}} \theta_{d,k}) d\boldsymbol{\phi}_k d\boldsymbol{\theta}_d - \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \quad (3.97)
\end{aligned}$$

$\tilde{F}[q(z_{d,i})]$ を $q(z_{d,i} = k)$ に関して変分する。

$$\begin{aligned}
\frac{\partial \tilde{F}[q(z_{d,i})]}{\partial q(z_{d,i} = k)} &= \int q(\boldsymbol{\phi}_k) q(\boldsymbol{\theta}_d) \log(\phi_{k,w_{d,i}} \theta_{d,k}) d\boldsymbol{\phi}_k d\boldsymbol{\theta}_d - \log q(z_{d,i} = k) - q(z_{d,i} = k) \frac{1}{q(z_{d,i} = k)} \\
&= \int q(\boldsymbol{\phi}_k) q(\boldsymbol{\theta}_d) \log(\phi_{k,w_{d,i}} \theta_{d,k}) d\boldsymbol{\phi}_k d\boldsymbol{\theta}_d - \log q(z_{d,i} = k) - 1 \quad (3.98)
\end{aligned}$$

$\frac{\partial \tilde{F}[q(z_{d,i})]}{\partial q(z_{d,i} = k)} = 0$ となる $q(z_{d,i} = k)$ を求める。

$$\begin{aligned}
\int q(\boldsymbol{\phi}_k) q(\boldsymbol{\theta}_d) \log(\phi_{k,w_{d,i}} \theta_{d,k}) d\boldsymbol{\phi}_k d\boldsymbol{\theta}_d - \log q(z_{d,i} = k) - 1 &= 0 \\
\log q(z_{d,i} = k) &= \int q(\boldsymbol{\phi}_k) q(\boldsymbol{\theta}_d) \log(\phi_{k,w_{d,i}} \theta_{d,k}) d\boldsymbol{\phi}_k d\boldsymbol{\theta}_d - 1 \\
q(z_{d,i} = k) &= \exp \left[\int q(\boldsymbol{\phi}_k) q(\boldsymbol{\theta}_d) \log(\phi_{k,w_{d,i}} \theta_{d,k}) d\boldsymbol{\phi}_k d\boldsymbol{\theta}_d - 1 \right] \\
&= \exp \left[\int q(\boldsymbol{\phi}_k) q(\boldsymbol{\theta}_d) (\log \phi_{k,w_{d,i}} + \log \theta_{d,k}) d\boldsymbol{\phi}_k d\boldsymbol{\theta}_d - 1 \right] \\
&= \exp \left[\int q(\boldsymbol{\theta}_d) d\boldsymbol{\theta}_d \int q(\boldsymbol{\phi}_k) \log \phi_{k,w_{d,i}} d\boldsymbol{\phi}_k + \int q(\boldsymbol{\phi}_k) d\boldsymbol{\phi}_k \int q(\boldsymbol{\theta}_d) \log \theta_{d,k} d\boldsymbol{\theta}_d - 1 \right] \\
&\propto \exp \left[\int q(\boldsymbol{\phi}_k) \log \phi_{k,w_{d,i}} d\boldsymbol{\phi}_k \right] \exp \left[\int q(\boldsymbol{\theta}_d) \log \theta_{d,k} d\boldsymbol{\theta}_d \right] \\
&= \exp \left[\mathbb{E}_{q(\boldsymbol{\phi}_k)} [\log \phi_{k,w_{d,i}}] \right] \exp \left[\mathbb{E}_{q(\boldsymbol{\theta}_d)} [\log \theta_{d,k}] \right]
\end{aligned}$$

更に、先ほど得られた

$$\begin{aligned}
q(\boldsymbol{\phi}_k) &\propto q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi) \\
q(\boldsymbol{\theta}_d) &\propto q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_k^\theta)
\end{aligned}$$

の関係と期待値計算式 (3.79) を用いて

$$\begin{aligned}
q(z_{d,i} = k) &\propto \exp [\mathbb{E}_{q(\phi_k)} [\log \phi_{k,w_{d,i}}]] \exp [\mathbb{E}_{q(\theta_d)} [\log \theta_{d,k}]] \\
&\propto \exp [\mathbb{E}_{q(\phi_k|\xi_k^\phi)} [\log \phi_{k,w_{d,i}}]] \exp [\mathbb{E}_{q(\theta_d|\xi_k^\theta)} [\log \theta_{d,k}]] \\
&= \exp \left[\Psi(\xi_{k,w_{d,i}}^\phi) - \Psi \left(\sum_{v'=1}^V \xi_{k,v'}^\theta \right) \right] \exp \left[\Psi(\xi_{d,k}^\theta) - \Psi \left(\sum_{k'=1}^K \xi_{d,k'}^\theta \right) \right] \\
&= \exp [\Psi(\xi_{k,w_{d,i}}^\phi)] \frac{1}{\exp [\Psi(\sum_{v'=1}^V \xi_{k,v'}^\theta)]} \exp [\Psi(\xi_{d,k}^\theta)] \frac{1}{\exp [\Psi(\sum_{k'=1}^K \xi_{d,k'}^\theta)]} \\
&= \frac{\exp [\Psi(\xi_{k,w_{d,i}}^\phi)]}{\exp [\Psi(\sum_{v'=1}^V \xi_{k,v'}^\theta)]} \frac{\exp [\Psi(\xi_{d,k}^\theta)]}{\exp [\Psi(\sum_{k'=1}^K \xi_{d,k'}^\theta)]} \tag{3.99}
\end{aligned}$$

が得られる。

3.3.6 LDA の変分ベイズ法 (2)

LDA に対して、あらかじめ近似事後分布の形を仮定して導出する。

トピック分布と単語分布の近似事後分布に関して、それぞれ ξ_d^θ, ξ_k^ϕ をパラメータとする Dirichlet 分布 $q(\theta_d|\xi_d^\theta), q(\phi_k|\xi_k^\phi)$ を仮定する。

・ 変分下限の導出

z, ϕ, θ について周辺化 (積分消去) して対数をとった対数周辺尤度 $\log p(w|\alpha, \beta)$ に対して、イエンセンの不等式を用いて変分下限を求める。

$$\begin{aligned}
\log p(w|\alpha, \beta) &= \log \int \sum_z p(w, z, \phi, \theta|\alpha, \beta) d\phi d\theta \\
&= \log \int \sum_z q(z, \theta, \phi|\xi^\theta, \xi^\phi) \frac{p(w, z, \phi, \theta|\alpha, \beta)}{q(z, \theta, \phi|\xi^\theta, \xi^\phi)} d\phi d\theta \\
&\geq \int \sum_z q(z, \theta, \phi|\xi^\theta, \xi^\phi) \log \frac{p(w, z, \phi, \theta|\alpha, \beta)}{q(z, \theta, \phi|\xi^\theta, \xi^\phi)} d\phi d\theta \equiv F[q(z, \theta, \phi|\xi^\theta, \xi^\phi)]
\end{aligned}$$

ここで、近似事後分布は

$$\begin{aligned}
q(z, \theta, \phi|\xi^\theta, \xi^\phi) &= q(z)q(\theta|\xi^\theta)q(\phi|\xi^\phi) \\
&= \left[\prod_{d=1}^M \prod_{i=1}^{n_d} q(z_{d,i}) \right] \left[\prod_{d=1}^M q(\theta_d|\xi_d^\theta) \right] \left[\prod_{k=1}^K q(\phi_k|\xi_k^\phi) \right]
\end{aligned}$$

と因子分解できると仮定する。

また、結合分布は生成過程より、ベイズの定理を用いて

$$\begin{aligned}
p(w, z, \phi, \theta|\alpha, \beta) &= p(w, z|\phi, \theta)p(\phi|\beta)p(\theta|\alpha) \\
&= p(w|z, \phi)p(z|\theta)p(\phi|\beta)p(\theta|\alpha) \\
&= \left[\prod_{d=1}^M \prod_{i=1}^{n_d} p(w_{d,i}|\phi_{z_{d,i}})p(z_{d,i}|\theta_d) \right] \left[\prod_{k=1}^K p(\phi_k|\beta) \right] \left[\prod_{d=1}^M p(\theta_d|\alpha) \right]
\end{aligned}$$

となる。

従って、変分下限 $F[q(\mathbf{z}, \boldsymbol{\theta}, \phi)]$ は

$$\begin{aligned}
F[q(\mathbf{z}, \boldsymbol{\theta}, \phi|\boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)] &= \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}, \phi|\boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi) \log \frac{p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta}|\boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z}, \boldsymbol{\theta}, \phi|\boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)} d\phi d\boldsymbol{\theta} \\
&= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}|\boldsymbol{\xi}^\theta) q(\phi|\boldsymbol{\xi}^\phi) \log \frac{p(\mathbf{w}|\mathbf{z}, \phi) p(\mathbf{z}|\boldsymbol{\theta}) p(\phi|\boldsymbol{\beta}) p(\boldsymbol{\theta}|\boldsymbol{\alpha})}{q(\mathbf{z}) q(\boldsymbol{\theta}|\boldsymbol{\xi}^\theta) q(\phi|\boldsymbol{\xi}^\phi)} d\phi d\boldsymbol{\theta} \\
&= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}|\boldsymbol{\xi}^\theta) q(\phi|\boldsymbol{\xi}^\phi) \left(\log(p(\mathbf{w}|\mathbf{z}, \phi) p(\mathbf{z}|\boldsymbol{\theta})) - \log q(\mathbf{z}) + \log \frac{p(\boldsymbol{\theta}|\boldsymbol{\alpha})}{q(\boldsymbol{\theta}|\boldsymbol{\xi}^\theta)} + \log \frac{p(\phi|\boldsymbol{\beta})}{q(\phi|\boldsymbol{\xi}^\phi)} \right) d\phi d\boldsymbol{\theta} \\
&= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}|\boldsymbol{\xi}^\theta) q(\phi|\boldsymbol{\xi}^\phi) \log(p(\mathbf{w}|\mathbf{z}, \phi) p(\mathbf{z}|\boldsymbol{\theta})) d\phi d\boldsymbol{\theta} - \sum_{\mathbf{z}} q(\mathbf{z}) \log q(\mathbf{z}) \\
&\quad + \int q(\boldsymbol{\theta}|\boldsymbol{\xi}^\theta) \log \frac{p(\boldsymbol{\theta}|\boldsymbol{\alpha})}{q(\boldsymbol{\theta}|\boldsymbol{\xi}^\theta)} d\boldsymbol{\theta} + \int q(\phi|\boldsymbol{\xi}^\phi) \log \frac{p(\phi|\boldsymbol{\beta})}{q(\phi|\boldsymbol{\xi}^\phi)} d\phi \\
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta) q(\phi_k|\boldsymbol{\xi}_k^\phi) \log(p(w_{d,i}|\phi_{z_{d,i}}) p(z_{d,i} = k|\boldsymbol{\theta}_d)) d\phi_k d\boldsymbol{\theta}_d \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&\quad + \sum_{d=1}^M \int q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta) \log \frac{p(\boldsymbol{\theta}_d|\boldsymbol{\alpha})}{q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta)} d\boldsymbol{\theta}_d + \sum_{k=1}^K \int q(\phi_k|\boldsymbol{\xi}_k^\phi) \log \frac{p(\phi_k|\boldsymbol{\beta})}{q(\phi_k|\boldsymbol{\xi}_k^\phi)} d\phi_k
\end{aligned} \tag{a}$$

$$\begin{aligned}
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&\quad + \sum_{d=1}^M \int q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta) \log \frac{p(\boldsymbol{\theta}_d|\boldsymbol{\alpha})}{q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta)} d\boldsymbol{\theta}_d + \sum_{k=1}^K \int q(\phi_k|\boldsymbol{\xi}_k^\phi) \log \frac{p(\phi_k|\boldsymbol{\beta})}{q(\phi_k|\boldsymbol{\xi}_k^\phi)} d\phi_k
\end{aligned} \tag{b}$$

となる。式 (a) は更に

$$\begin{aligned}
&\int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta) q(\phi_k|\boldsymbol{\xi}_k^\phi) \log(p(w_{d,i}|\phi_{z_{d,i}}) p(z_{d,i} = k|\boldsymbol{\theta}_d)) d\phi_k d\boldsymbol{\theta}_d \\
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta) q(\phi_k|\boldsymbol{\xi}_k^\phi) \log\left(\prod_{v=1}^V p(w_{d,i}|\phi_{k,v})^{\delta(z_{d,i}=k)} p(z_{d,i} = k|\boldsymbol{\theta}_{d,k})\right) d\phi_k d\boldsymbol{\theta}_d \\
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K \sum_{v=1}^V q(z_{d,i} = k) q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta) q(\phi_k|\boldsymbol{\xi}_k^\phi) \log\left(\phi_{k,v}^{\delta(z_{d,i}=k)\delta(w_{d,i}=v)} \theta_{d,k}^{\delta(z_{d,i}=k)}\right) d\phi_k d\boldsymbol{\theta}_d \\
&= \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K \sum_{v=1}^V q(z_{d,i} = k) \delta(z_{d,i} = k) \delta(w_{d,i} = v) \int q(\phi_k|\boldsymbol{\xi}_k^\phi) \log \phi_{k,v} d\phi_k \\
&\quad + \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \delta(z_{d,i} = k) \int q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta) \log \theta_{d,k} d\boldsymbol{\theta}_d \\
&= \sum_{k=1}^K \sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] \mathbb{E}_{q(\phi_k|\boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] + \sum_{d=1}^M \sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] \mathbb{E}_{q(\boldsymbol{\theta}_d|\boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}]
\end{aligned} \tag{a}$$

となる。また、式 (b) を KL 情報量に置き換える。

$$\begin{aligned}
& \sum_{d=1}^M \int q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta) \log \frac{p(\boldsymbol{\theta}_d | \boldsymbol{\alpha})}{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)} d\boldsymbol{\theta}_d + \sum_{k=1}^K \int q(\phi_k | \boldsymbol{\xi}_k^\phi) \log \frac{p(\phi_k | \boldsymbol{\beta})}{q(\phi_k | \boldsymbol{\xi}_k^\phi)} d\phi_k \quad (b) \\
&= \sum_{d=1}^M \int q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta) \log \left(p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) - q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta) \right) d\boldsymbol{\theta}_d + \sum_{k=1}^K \int q(\phi_k | \boldsymbol{\xi}_k^\phi) \log \left(p(\phi_k | \boldsymbol{\beta}) - q(\phi_k | \boldsymbol{\xi}_k^\phi) \right) d\phi_k \\
&= - \sum_{d=1}^M \int q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta) \log \left(-p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) + q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta) \right) d\boldsymbol{\theta}_d - \sum_{k=1}^K \int q(\phi_k | \boldsymbol{\xi}_k^\phi) \log \left(-p(\phi_k | \boldsymbol{\beta}) + q(\phi_k | \boldsymbol{\xi}_k^\phi) \right) d\phi_k \\
&= - \sum_{d=1}^M \int q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta) \log \frac{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}{p(\boldsymbol{\theta}_d | \boldsymbol{\alpha})} d\boldsymbol{\theta}_d - \sum_{k=1}^K \int q(\phi_k | \boldsymbol{\xi}_k^\phi) \log \frac{q(\phi_k | \boldsymbol{\xi}_k^\phi)}{p(\phi_k | \boldsymbol{\beta})} d\phi_k \\
&= - \sum_{d=1}^M \text{KL}[q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta) \parallel p(\boldsymbol{\theta}_d | \boldsymbol{\alpha})] - \sum_{k=1}^K \mathbb{E}[q(\phi_k | \boldsymbol{\xi}_k^\phi) \parallel p(\phi_k | \boldsymbol{\beta})]
\end{aligned}$$

更に、式 (3.81) を用いて KL 情報量を置き換える。

$$\begin{aligned}
& - \sum_{d=1}^M \text{KL}[q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta) \parallel p(\boldsymbol{\theta}_d | \boldsymbol{\alpha})] - \sum_{k=1}^K \mathbb{E}[q(\phi_k | \boldsymbol{\xi}_k^\phi) \parallel p(\phi_k | \boldsymbol{\beta})] \\
&= - \sum_{d=1}^M \left[\log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} - \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \right] - \sum_{d=1}^M \sum_{k=1}^K (\xi_{k,v}^\theta - \alpha_k) \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)} [\log \theta_{d,k}] \\
&\quad - \sum_{k=1}^K \left[\log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} - \log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} \right] - \sum_{k=1}^K \sum_{v=1}^V (\xi_{k,v}^\phi - \beta_v) \mathbb{E}_{q(\phi_k | \boldsymbol{\xi}_k^\phi)} [\log \phi_{k,v}] \\
&= \sum_{d=1}^M \left[\log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} - \log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \right] + \sum_{d=1}^M \sum_{k=1}^K (\alpha_k - \xi_{k,v}^\theta) \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)} [\log \theta_{d,k}] \\
&\quad + \sum_{k=1}^K \left[\log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} - \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right] + \sum_{k=1}^K \sum_{v=1}^V (\beta_v - \xi_{k,v}^\phi) \mathbb{E}_{q(\phi_k | \boldsymbol{\xi}_k^\phi)} [\log \phi_{k,v}]
\end{aligned}$$

従って、変分下限は

$$\begin{aligned}
F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)] &= \sum_{k=1}^K \sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] + \sum_{d=1}^M \sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&\quad + \sum_{d=1}^M \left[\log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} - \log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \right] + \sum_{d=1}^M \sum_{k=1}^K (\alpha_k - \xi_{k,v}^\theta) \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \\
&\quad + \sum_{k=1}^K \left[\log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} - \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right] + \sum_{k=1}^K \sum_{v=1}^V (\beta_v - \xi_{k,v}^\phi) \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&= \sum_{k=1}^K \left[\log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} - \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right] + \sum_{k=1}^K \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&\quad + \sum_{d=1}^M \left[\log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} - \log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \right] + \sum_{d=1}^M \sum_{k=1}^K (\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k - \xi_{k,v}^\theta) \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \tag{3.102}
\end{aligned}$$

になる。

・トピック分布の近似事後分布のパラメータの導出

変分下限を $\xi_{d,k}^\theta$ で微分するには

$$\begin{aligned}
\frac{\partial F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)]}{\partial \xi_{d,k}^\theta} &= \frac{\partial}{\partial \xi_{d,k}^\theta} \left(-\log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \right) + \frac{\partial}{\partial \xi_{d,k}^\theta} \left(-\xi_{d,k}^\theta \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \right) \\
&\quad + \sum_{k'=1}^K (\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k'}] + \alpha_{k'} - \xi_{d,k'}^\theta) \frac{\partial}{\partial \xi_{d,k}^\theta} \left(\mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k'}] \right)
\end{aligned}$$

の3つの項の微分をすればよい。

1つ目の項は、プサイ関数への置き換え (あるいは式 (3.76) から式 (3.77) への式変形) と Dirichlet 分布の期待値計算 (3.74) を用いて

$$\begin{aligned}
\frac{\partial}{\partial \xi_{d,k}^\theta} \left(-\log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \right) &= \frac{\partial}{\partial \xi_{d,k}^\theta} \left(\sum_{k=1}^K \log \Gamma(\xi_{d,k}^\theta) - \log \Gamma\left(\sum_{k=1}^K \xi_{d,k}^\theta\right) \right) \\
&= \Psi(\xi_{d,k}^\theta) - \Psi\left(\sum_{k=1}^K \xi_{d,k}^\theta\right) \\
&= \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}]
\end{aligned}$$

となる。2つ目の項は

$$\frac{\partial}{\partial \xi_{d,k}^\theta} \left(-\xi_{d,k}^\theta \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \right) = -\mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}]$$

となるので、1つ目の項と合わせて消えてしまう。よって、3つ目の項が0となる $\xi_{d,k}^\theta$ を求めればよいことが分かる。

$$\begin{aligned}\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k - \xi_{d,k}^\theta &= 0 \\ \xi_{d,k}^\theta &= \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k\end{aligned}$$

これは式 (3.89) と等しくなることが確認できる。

・単語分布の近似事後分布のパラメータの導出

トピック分布と同様に、変分下限を $\xi_{d,k}^\phi$ で微分するには

$$\begin{aligned}\frac{\partial F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)]}{\partial \xi_{k,v}^\phi} &= \frac{\partial}{\partial \xi_{k,v}^\phi} \left(-\log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right) + \frac{\partial}{\partial \xi_{k,v}^\phi} \left(-\xi_{k,v}^\phi \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \right) \\ &\quad + \sum_{v'=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v'}] + \beta_{v'} - \xi_{k,v'}^\phi) \frac{\partial}{\partial \xi_{k,v}^\phi} \left(\mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v'}] \right)\end{aligned}$$

の3つの項の微分をすればよい。

1つ目の項は、プサイ関数への置き換え (あるいは式 (3.76) から式 (3.77) への式変形) と Dirichlet 分布の期待値計算 (3.74) を用いて

$$\begin{aligned}\frac{\partial}{\partial \xi_{k,v}^\phi} \left(-\log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right) &= \frac{\partial}{\partial \xi_{k,v}^\phi} \left(\sum_{v=1}^V \log \Gamma(\xi_{k,v}^\phi) - \log \Gamma\left(\sum_{v=1}^V \xi_{k,v}^\phi\right) \right) \\ &= \Psi(\xi_{k,v}^\phi) - \Psi\left(\sum_{v=1}^V \xi_{k,v}^\phi\right) \\ &= \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}]\end{aligned}\tag{3.103}$$

となる。2つ目の項は

$$\frac{\partial}{\partial \xi_{k,v}^\phi} \left(-\xi_{k,v}^\phi \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \right) = -\mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}]$$

となるので、1つ目の項と合わせて消えてしまう。よって、3つ目の項が0となる $\xi_{k,v}^\phi$ を求めればよいことが分かる。

$$\begin{aligned}\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi &= 0 \\ \xi_{k,v}^\phi &= \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v\end{aligned}$$

これは式 (3.95) と等しくなることが確認できる。

3.3.7 LDA の変分ベイズ法 (3)

トピック集合とトピック分布の近似事後分布を変分ベイズ法で求めて、単語分布は MAP 推定で求める。

・変分下限の導出

対数周辺尤度 $\log p(\mathbf{w}, \phi | \alpha, \beta)$ に対してイエンセンの不等式を用いて変分下限を求める。

$$\begin{aligned}\log p(\mathbf{w}, \phi | \alpha, \beta) &= \log \int \sum_{\mathbf{z}} p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta} | \alpha, \beta) d\boldsymbol{\theta} \\ &= \log \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}) \frac{p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta} | \alpha, \beta)}{q(\mathbf{z}, \boldsymbol{\theta})} d\boldsymbol{\theta} \\ &\geq \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}) \log \frac{p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta} | \alpha, \beta)}{q(\mathbf{z}, \boldsymbol{\theta})} d\boldsymbol{\theta} \equiv F[q(\mathbf{z}, \boldsymbol{\theta})]\end{aligned}$$

ここで、近似事後分布は

$$\begin{aligned}q(\mathbf{z}, \boldsymbol{\theta}) &= q(\mathbf{z})q(\boldsymbol{\theta}) \\ &= \left[\prod_{d=1}^M \prod_{i=1}^{n_d} q(z_{d,i}) \right] \left[\prod_{d=1}^M q(\boldsymbol{\theta}_d) \right]\end{aligned}$$

と因子分解できると仮定する。

また、結合分布は生成過程より、ベイズの定理を用いて

$$\begin{aligned}p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta} | \alpha, \beta) &= p(\mathbf{w} | \mathbf{z}, \phi) p(\mathbf{z} | \boldsymbol{\theta}) p(\phi | \beta) p(\boldsymbol{\theta} | \alpha) \\ &= \prod_{d=1}^M \prod_{i=1}^{n_d} p(w_{d,i} | z_{d,i}, \phi) p(z_{d,i} | \boldsymbol{\theta}_d) \prod_{k=1}^K p(\phi_k | \beta) \prod_{d=1}^M p(\boldsymbol{\theta}_d | \alpha) \\ &= \prod_{d=1}^M \prod_{i=1}^{n_d} p(w_{d,i} | \phi_{z_{d,i}}) p(z_{d,i} | \boldsymbol{\theta}_d) \prod_{k=1}^K p(\phi_k | \beta) \prod_{d=1}^M p(\boldsymbol{\theta}_d | \alpha)\end{aligned}$$

となる。

従って、変分下限は

$$\begin{aligned}F[q(\mathbf{z}, \boldsymbol{\theta})] &= \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}) \log \frac{p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta} | \alpha, \beta)}{q(\mathbf{z}, \boldsymbol{\theta})} d\boldsymbol{\theta} \\ &= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}) \log \frac{p(\mathbf{w} | \mathbf{z}, \phi) p(\mathbf{z} | \boldsymbol{\theta}) p(\phi | \beta) p(\boldsymbol{\theta} | \alpha)}{q(\mathbf{z}) q(\boldsymbol{\theta})} d\boldsymbol{\theta} \\ &= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}) \left(\log p(\mathbf{w} | \mathbf{z}, \phi) p(\mathbf{z} | \boldsymbol{\theta}) - \log q(\mathbf{z}) + \log p(\phi | \beta) + \log \frac{p(\boldsymbol{\theta} | \alpha)}{q(\boldsymbol{\theta})} \right) d\boldsymbol{\theta} \\ &= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}) \log p(\mathbf{w} | \mathbf{z}, \phi) p(\mathbf{z} | \boldsymbol{\theta}) d\boldsymbol{\theta} - \sum_{\mathbf{z}} q(\mathbf{z}) \log q(\mathbf{z}) + \log p(\phi | \beta) \\ &\quad + \int q(\boldsymbol{\theta}) \log \frac{p(\boldsymbol{\theta} | \alpha)}{q(\boldsymbol{\theta})} d\boldsymbol{\theta}\end{aligned}\tag{3.105}$$

となる。

・単語分布の導出

変分下限から ϕ_k に関する項を取り出して $\tilde{F}[\phi_k]$ とおく。

ここで

$$\begin{aligned}
\sum_{\mathbf{z}} q(\mathbf{z}) \log p(\mathbf{w}|\mathbf{z}, \phi) &= \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i}) \log p(w_{d,i}|\phi_{z_{d,i}}) \\
&= \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log p(w_{d,i}|\phi_k)^{\delta(z_{d,i}=k)}
\end{aligned}$$

である。

$$\begin{aligned}
\tilde{F}[\phi_k] &= \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i} = k) \log p(w_{d,i}|\phi_k) + \log p(\phi_k|\beta) \\
&\propto \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{v=1}^V q(z_{d,i} = k) \log \phi_{k,v}^{\delta(w_{d,i}=v)} + \log \prod_{v=1}^V \phi_{k,v}^{\beta_{k,v}-1} \\
&= \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{v=1}^V q(z_{d,i} = k) \delta(w_{d,i} = v) \log \phi_{k,v} + \sum_{v=1}^V (\beta_{k,v} - 1) \log \phi_{k,v} \\
&= \sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] \log \phi_{k,v} + \sum_{v=1}^V (\beta_{k,v} - 1) \log \phi_{k,v} \\
&= \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1) \log \phi_{k,v}
\end{aligned} \tag{3.107}$$

制約条件 $\sum_{v=1}^V \phi_{k,v} = 1$ から、ラグランジュ乗数 λ を用いて、ラグランジュ関数 $L[q(\phi_k)]$ をおき、制約付き最適化問題として解く。

$$L[q(\phi_k)] = \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1) \log \phi_{k,v} + \lambda \left(1 - \sum_{v=1}^V \phi_{k,v} \right)$$

この式を ϕ_k で微分する。

$$\frac{\partial L[q(\phi_k)]}{\partial \phi_k} = (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1) \frac{1}{\phi_{k,v}} - \lambda$$

$\frac{\partial L[q(\phi_k)]}{\partial \phi_k} = 0$ となる $\phi_{k,v}$ を求める。

$$\begin{aligned}
(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1) \frac{1}{\phi_{k,v}} - \lambda &= 0 \\
\phi_{k,v} &= \frac{\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1}{\lambda}
\end{aligned}$$

これを制約条件に代入すると

$$\begin{aligned}
\sum_{v=1}^V \frac{\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1}{\lambda} &= 1 \\
\lambda &= \sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1
\end{aligned}$$

となる。これを上の式に代入すると

$$\phi_{k,v} = \frac{\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1}{\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_{k,v} - 1}$$

が得られる。

トピック分布の近似事後分布は $\tilde{F}[q(\boldsymbol{\theta})]$ に ϕ が無関係なため、3.3.5 の方法で導出できる。

トピック集合の近似事後分布の導出については、少し変更が必要である。

式 (3.99) の計算において、点推定した $\phi_{k,v}$ の期待値は $\phi_{k,v}$ なので、 $\mathbb{E}_{q(\phi_k)}[\log \phi_{k,v}] = \log \phi_{k,v}$ である。よって、 $w_{d,i} = v$ のとき

$$\begin{aligned} q(z_{d,i} = k) &\propto \exp[\mathbb{E}_{q(\phi_k)}[\log \phi_{k,v}]] \exp[\mathbb{E}_{q(\boldsymbol{\theta}_d)}[\log \theta_{d,k}]] \\ &= \exp[\log \phi_{k,v}] \exp[\mathbb{E}_{q(\boldsymbol{\theta}_d)}[\log \theta_{d,k}]] \\ &= \phi_{k,v} \exp[\mathbb{E}_{q(\boldsymbol{\theta}_d)}[\log \theta_{d,k}]] \end{aligned} \quad (3.110)$$

となる。(本当は $q(\phi)$ を導入しないで求めるため、もう少し早い段階で $\phi_{k,v}$ に定まっていたと思われる)

3.3.8 LDA の周辺化変分ベイズ法

$\boldsymbol{\theta}_d, \phi_k$ を周辺化した周辺化変分ベイズ法について説明する。

$\boldsymbol{\theta}_d, \phi_k$ を周辺化した

$$p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta}) = \int p(\mathbf{w}, \mathbf{z}, \boldsymbol{\theta}, \phi | \boldsymbol{\alpha}, \boldsymbol{\beta}) d\boldsymbol{\theta} d\phi$$

を用いる。

・ 変分下限の導出

$$\begin{aligned} \log p(\mathbf{w} | \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \log \sum_{\mathbf{z}} p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta}) \\ &= \log \sum_{\mathbf{z}} q(\mathbf{z}) \frac{p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z})} \\ &\geq \sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z})} \equiv F_{\text{CVB}}[q(\mathbf{z})] \end{aligned} \quad (3.111)$$

この周辺化変分ベイズ法の変分下限 $F_{\text{CVB}}[q(\mathbf{z})]$ と変分ベイズ法の変分下限 (3.82) との関係を見る。

$$F[q(\mathbf{z}, \boldsymbol{\theta}, \phi)] = \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}, \phi) \log \frac{p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta} | \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z}, \boldsymbol{\theta}, \phi)} d\phi d\boldsymbol{\theta} \quad (3.82)$$

$p(\mathbf{w}, \mathbf{z}, \phi, \boldsymbol{\theta} | \boldsymbol{\alpha}, \boldsymbol{\beta}) = p(\phi, \boldsymbol{\theta} | \mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta})$ 、 $q(\mathbf{z}, \boldsymbol{\theta}, \phi) = q(\boldsymbol{\theta}, \phi | \mathbf{z}) q(\mathbf{z})$ より

$$\begin{aligned}
F[q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z})q(\mathbf{z})] &= \int \sum_{\mathbf{z}} q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z})q(\mathbf{z}) \log \frac{p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})p(\mathbf{w}, \mathbf{z}|\boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z})q(\mathbf{z})} d\boldsymbol{\phi}d\boldsymbol{\theta} \\
&= \int \sum_{\mathbf{z}} q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z})q(\mathbf{z}) \left(\log \frac{p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z})} + \log \frac{p(\mathbf{w}, \mathbf{z}|\boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z})} \right) d\boldsymbol{\phi}d\boldsymbol{\theta} \\
&= \int \sum_{\mathbf{z}} q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z})q(\mathbf{z}) \log \frac{p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z})} d\boldsymbol{\phi}d\boldsymbol{\theta} + \sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{p(\mathbf{w}, \mathbf{z}|\boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z})} \quad (3.114)
\end{aligned}$$

となる。

$q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z}) = p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})$ (完全に $\boldsymbol{\theta}, \boldsymbol{\phi}$ を推定できた) とすると ($\log 1 = 0$ より)

$$\begin{aligned}
F[p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})q(\mathbf{z})] &= \int \sum_{\mathbf{z}} p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})q(\mathbf{z}) \log \frac{p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})} d\boldsymbol{\phi}d\boldsymbol{\theta} + \sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{p(\mathbf{w}, \mathbf{z}|\boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z})} \\
&= \sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{p(\mathbf{w}, \mathbf{z}|\boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z})} = F_{\text{CVB}}[q(\mathbf{z})] \quad (3.115)
\end{aligned}$$

$F_{\text{CVB}}[q(\mathbf{z})]$ と等しくなる。従って

$$F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi})] = F[q(\boldsymbol{\theta}, \boldsymbol{\phi}|\mathbf{z})q(\mathbf{z})] \leq F[p(\boldsymbol{\phi}, \boldsymbol{\theta}|\mathbf{w}, \mathbf{z}, \boldsymbol{\alpha}, \boldsymbol{\beta})q(\mathbf{z})] = F_{\text{CVB}}[q(\mathbf{z})] \quad (3.116)$$

という関係が分かる。

・潜在トピックの近似事後分布の導出

変分下限から $q(z_{d,i})$ に関係する項を取り出して $\tilde{F}[q(z_{d,i})]$ とおく。
ここで

$$\begin{aligned}
p(\mathbf{w}, \mathbf{z}|\boldsymbol{\alpha}, \boldsymbol{\beta}) &= p(w_{d,i}, z_{d,i}, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}|\boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= p(w_{d,i}, z_{d,i}|\mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta})p(\mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}|\boldsymbol{\alpha}, \boldsymbol{\beta})
\end{aligned}$$

である。

$$\begin{aligned}
\tilde{F}[q(z_{d,i})] &= \sum_{\mathbf{z}} q(z_{d,i})q(\mathbf{z}^{\setminus d,i}) \log \frac{p(w_{d,i}, z_{d,i}|\mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(z_{d,i})} \quad (3.118) \\
&= \sum_{\mathbf{z}} q(z_{d,i})q(\mathbf{z}^{\setminus d,i}) \left(\log p(w_{d,i}, z_{d,i}|\mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) - \log q(z_{d,i}) \right) \\
&= \sum_{\mathbf{z}} q(z_{d,i})q(\mathbf{z}^{\setminus d,i}) \log p(w_{d,i}, z_{d,i}|\mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) - \sum_{z_{d,i}} q(z_{d,i}) \log q(z_{d,i})
\end{aligned}$$

この式を $q(z_{d,i} = k)$ で微分する。

$$\begin{aligned}
\frac{\partial \tilde{F}[q(z_{d,i} = k)]}{\partial q(z_{d,i} = k)} &= \sum_{\mathbf{z}} q(\mathbf{z}^{\setminus d,i}) \log p(w_{d,i} = v, z_{d,i} = k|\mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) - \log q(z_{d,i} = k) - q(z_{d,i} = k) \frac{1}{q(z_{d,i} = k)} \\
&= \sum_{\mathbf{z}} q(\mathbf{z}^{\setminus d,i}) \log p(w_{d,i} = v, z_{d,i} = k|\mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) - \log q(z_{d,i} = k) - 1
\end{aligned}$$

$\frac{\partial \tilde{F}[q(z_{d,i}=k)]}{\partial q(z_{d,i}=k)} = 0$ となる $q(z_{d,i}=k)$ を求める。

$$\begin{aligned}
\sum_{\mathbf{z}} q(\mathbf{z}^{\setminus d,i}) \log p(w_{d,i}=v, z_{d,i}=k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) - \log q(z_{d,i}=k) - 1 &= 0 \\
\log q(z_{d,i}=k) &= \sum_{\mathbf{z}} q(\mathbf{z}^{\setminus d,i}) \log p(w_{d,i}=v, z_{d,i}=k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) - 1 \\
q(z_{d,i}=k) &= \exp \left[\sum_{\mathbf{z}} q(\mathbf{z}^{\setminus d,i}) \log p(w_{d,i}=v, z_{d,i}=k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) - 1 \right] \\
&\propto \exp \left[\sum_{\mathbf{z}} q(\mathbf{z}^{\setminus d,i}) \log p(w_{d,i}=v, z_{d,i}=k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \right] \\
&= \exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log p(w_{d,i}=v, z_{d,i}=k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \right]
\end{aligned}$$

ここで、式 (3.38) の計算過程より

$$\begin{aligned}
p(w_{d,i}=v, z_{d,i}=k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) &= p(w_{d,i}=v | z_{d,i}=k, \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(z_{d,i}=k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= \frac{n_{k,v}^{\setminus d,i} + \beta_v}{\sum_{v'=1}^V n_{k,v'}^{\setminus d,i} + \beta_{v'}} \frac{n_{d,k}^{\setminus d,i} + \alpha_k}{n_d^{\setminus d,i} + \sum_{k'=1}^K \alpha_{k'}} \quad (3.38)
\end{aligned}$$

である。
よって

$$\begin{aligned}
q(z_{d,i}=k) &\propto \exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log p(w_{d,i}=v, z_{d,i}=k | \mathbf{w}^{\setminus d,i}, \mathbf{z}^{\setminus d,i}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \right] \\
&= \exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log \frac{n_{k,v}^{\setminus d,i} + \beta_v}{\sum_{v'=1}^V n_{k,v'}^{\setminus d,i} + \beta_{v'}} \frac{n_{d,k}^{\setminus d,i} + \alpha_k}{n_d^{\setminus d,i} + \sum_{k'=1}^K \alpha_{k'}} \right] \\
&\propto \exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log \frac{n_{k,v}^{\setminus d,i} + \beta_v}{\sum_{v'=1}^V n_{k,v'}^{\setminus d,i} + \beta_{v'}} (n_{d,k}^{\setminus d,i} + \alpha_k) \right] \\
&= \exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log(n_{k,v}^{\setminus d,i} + \beta_v) - \log \left(\sum_{v'=1}^V n_{k,v'}^{\setminus d,i} + \beta_{v'} \right) + \log(n_{d,k}^{\setminus d,i} + \alpha_k) \right] \\
&= \exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log(n_{k,v}^{\setminus d,i} + \beta_v) \right] \frac{1}{\exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log \left(\sum_{v'=1}^V n_{k,v'}^{\setminus d,i} + \beta_{v'} \right) \right]} \exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log(n_{d,k}^{\setminus d,i} + \alpha_k) \right] \\
&= \frac{\exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log(n_{k,v}^{\setminus d,i} + \beta_v) \right]}{\exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log \left(\sum_{v'=1}^V n_{k,v'}^{\setminus d,i} + \beta_{v'} \right) \right]} \exp \mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log(n_{d,k}^{\setminus d,i} + \alpha_k) \right] \quad (3.120)
\end{aligned}$$

が得られる。

しかしこの式には解析的に積分できない項があるため、近似計算を行うことにする。

・テイラー展開による近似

テイラー展開を用いて近似を考える。

・テイラー展開

対数関数 $\log x$ を a の周りで 2 次までテイラー展開すると

$$\log x \approx \log a + \frac{1}{a}(x - a) - \frac{1}{2a^2}(x - a)^2 \quad (3.121)$$

である。これを $a = \mathbb{E}[x]$ として、更に全体の期待値をとると

$$\begin{aligned} \mathbb{E}[\log x] &\approx \mathbb{E} \left[\log \mathbb{E}[x] + \frac{1}{\mathbb{E}[x]}(x - \mathbb{E}[x]) - \frac{1}{2\mathbb{E}[x]^2}(x - \mathbb{E}[x])^2 \right] \\ &= \mathbb{E}[\log \mathbb{E}[x]] + \mathbb{E} \left[\frac{1}{\mathbb{E}[x]}(x - \mathbb{E}[x]) \right] - \mathbb{E} \left[\frac{1}{2\mathbb{E}[x]^2}(x - \mathbb{E}[x])^2 \right] \\ &= \log \mathbb{E}[x] + \frac{1}{\mathbb{E}[x]}(\mathbb{E}[x] - \mathbb{E}[x]) - \frac{1}{2\mathbb{E}[x]^2} \mathbb{E}[(x - \mathbb{E}[x])^2] \\ &= \log \mathbb{E}[x] - \frac{\mathbb{V}[x]}{2\mathbb{E}[x]^2} \end{aligned} \quad (3.122)$$

になる。また、 $\log(x + b)$ に対して $a = \mathbb{E}[x] + b$ とすると

$$\begin{aligned} \mathbb{E}[\log(x + b)] &\approx \mathbb{E} \left[\log(\mathbb{E}[x] + b) + \frac{1}{\mathbb{E}[x] + b}\{x + b - (\mathbb{E}[x] + b)\} - \frac{1}{2(\mathbb{E}[x] + b)^2}\{x + b - (\mathbb{E}[x] + b)\}^2 \right] \\ &= \mathbb{E}[\log(\mathbb{E}[x] + b)] + \mathbb{E} \left[\frac{1}{\mathbb{E}[x] + b}(x - \mathbb{E}[x]) \right] - \mathbb{E} \left[\frac{1}{2(\mathbb{E}[x] + b)^2}(x - \mathbb{E}[x])^2 \right] \\ &= \log(\mathbb{E}[x] + b) + \frac{1}{\mathbb{E}[x] + b}(\mathbb{E}[x] - \mathbb{E}[x]) - \frac{1}{2(\mathbb{E}[x] + b)^2} \mathbb{E}[(x - \mathbb{E}[x])^2] \\ &= \log(\mathbb{E}[x] + b) - \frac{\mathbb{V}[x]}{2(\mathbb{E}[x] + b)^2} \end{aligned} \quad (3.122')$$

になる。

式 (3.122') を用いて、式 (3.120) を近似していく。

まずは、分子の項 $\log(n_{k,v}^{\setminus d,i} + \beta_v)$ を $\mathbb{E}[n_{k,v}^{\setminus d,i}] + \beta_v$ の周りでテイラー展開する。

$$\mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log(n_{k,v}^{\setminus d,i} + \beta_v) \right] \approx \log(\mathbb{E}[n_{k,v}^{\setminus d,i}] + \beta_v) - \frac{\mathbb{V}[n_{k,v}^{\setminus d,i}]}{2(\mathbb{E}[n_{k,v}^{\setminus d,i}] + \beta_v)^2}$$

次に、分母の項 $\sum_{v=1}^V \log(n_{k,\cdot}^{\setminus d,i} + \beta_v) = \log(n_{k,\cdot}^{\setminus d,i} + \beta_{\cdot})$ を $\mathbb{E}[n_{k,\cdot}^{\setminus d,i}] + \beta_{\cdot}$ の周りでテイラー展開する。

$$\mathbb{E}_{q(\mathbf{z}^{\setminus d,i})} \left[\log(n_{k,\cdot}^{\setminus d,i} + \beta_{\cdot}) \right] \approx \log(\mathbb{E}[n_{k,\cdot}^{\setminus d,i}] + \beta_{\cdot}) - \frac{\mathbb{V}[n_{k,\cdot}^{\setminus d,i}]}{2(\mathbb{E}[n_{k,\cdot}^{\setminus d,i}] + \beta_{\cdot})^2}$$

最後に、後の項 $\log(n_{d,k}^{\setminus d,i} + \alpha_k)$ を $\mathbb{E}[n_{d,k}^{\setminus d,i}] + \alpha_k$ の周りでテイラー展開する。

$$\mathbb{E}_{q(\mathbf{z} \setminus d, i)} \left[\log(n_{d,k}^{d,i} + \alpha_k) \right] \approx \log(\mathbb{E}[n_{d,k}^{d,i}] + \alpha_k) - \frac{\mathbb{V}[n_{d,k}^{d,i}]}{2(\mathbb{E}[n_{d,k}^{d,i}] + \alpha_k)^2} \quad (3.123)$$

これらを式 (3.120) に代入すると

$$q(z_{d,i} = k) \propto \frac{\exp \mathbb{E}_{q(\mathbf{z} \setminus d, i)} \left[\log(n_{k,v}^{d,i} + \beta_v) \right]}{\exp \mathbb{E}_{q(\mathbf{z} \setminus d, i)} \left[\log(\sum_{v'=1}^V n_{k,v'}^{d,i} + \beta_{v'}) \right]} \exp \mathbb{E}_{q(\mathbf{z} \setminus d, i)} \left[\log(n_{d,k}^{d,i} + \alpha_k) \right] \quad (3.120)$$

$$\begin{aligned} &\approx \frac{\exp \left[\log(\mathbb{E}[n_{k,v}^{d,i}] + \beta_v) - \frac{\mathbb{V}[n_{k,v}^{d,i}]}{2(\mathbb{E}[n_{k,v}^{d,i}] + \beta_v)^2} \right]}{\exp \left[\log(\mathbb{E}[n_{k,\cdot}^{d,i}] + \beta) - \frac{\mathbb{V}[n_{k,\cdot}^{d,i}]}{2(\mathbb{E}[n_{k,\cdot}^{d,i}] + \beta)^2} \right]} \exp \left[\log(\mathbb{E}[n_{d,k}^{d,i}] + \alpha_k) - \frac{\mathbb{V}[n_{d,k}^{d,i}]}{2(\mathbb{E}[n_{d,k}^{d,i}] + \alpha_k)^2} \right] \\ &= \frac{\exp \left[\log(\mathbb{E}[n_{k,v}^{d,i}] + \beta_v) \right]}{\exp \left[\log(\mathbb{E}[n_{k,\cdot}^{d,i}] + \beta) \right]} \exp \left[\log(\mathbb{E}[n_{d,k}^{d,i}] + \alpha_k) \right] \\ &\quad * \exp \left[-\frac{\mathbb{V}[n_{k,v}^{d,i}]}{2(\mathbb{E}[n_{k,v}^{d,i}] + \beta_v)^2} \right] \exp \left[-\frac{\mathbb{V}[n_{d,k}^{d,i}]}{2(\mathbb{E}[n_{d,k}^{d,i}] + \alpha_k)^2} \right] \exp \left[-\frac{2(\mathbb{E}[n_{k,\cdot}^{d,i}] + \beta)^2}{\mathbb{V}[n_{k,\cdot}^{d,i}]} \right] \\ &= \frac{\mathbb{E}[n_{k,v}^{d,i}] + \beta_v}{\mathbb{E}[n_{k,\cdot}^{d,i}] + \beta} (\mathbb{E}[n_{d,k}^{d,i}] + \alpha_k) \\ &\quad * \exp \left[-\frac{\mathbb{V}[n_{k,v}^{d,i}]}{2(\mathbb{E}[n_{k,v}^{d,i}] + \beta_v)^2} - \frac{\mathbb{V}[n_{d,k}^{d,i}]}{2(\mathbb{E}[n_{d,k}^{d,i}] + \alpha_k)^2} \right] \exp \left[\frac{\mathbb{V}[n_{k,\cdot}^{d,i}]}{2(\mathbb{E}[n_{k,\cdot}^{d,i}] + \beta)^2} \right] \end{aligned} \quad (3.130)$$

が得られる。

ここで、 $n_{d,k}$ は文書 d において潜在トピックに k が割り当てられた単語数である。また、文書 d の単語 i の潜在トピック $z_{d,i}$ に k を割り当てる確率が $q(z_{d,i} = k)$ である。 $\delta(z_{d,i} = k)$ は $z_{d,i} = k$ のときに 1、 $z_{d,i} \neq k$ のときに 0 となる確率変数である。潜在トピック $z_{d,i}$ が k でない確率は $1 - q(z_{d,i} = k)$ である。つまり、 $\delta(z_{d,i} = k)$ はベルヌーイ分布に従うと言える。

従って、ベルヌーイ分布の期待値と分散の定義より、 $\mathbb{E}[\delta(z_{d,i} = k)] = q(z_{d,i} = k)$ 、 $\mathbb{V}[\delta(z_{d,i} = k)] = q(z_{d,i} = k)(1 - q(z_{d,i} = k))$ であることが分かる。

よって、 $n_{d,k}^{d,i} = \sum_{i' \neq i} \delta(z_{d,i'} = k)$ より

$$\begin{aligned} \mathbb{E}[n_{d,k}^{d,i}] &= \mathbb{E} \left[\sum_{i' \neq i} \delta(z_{d,i'} = k) \right] \\ &= \sum_{i' \neq i} \mathbb{E}[\delta(z_{d,i'} = k)] \\ &= \sum_{i' \neq i} q(z_{d,i'} = k) \end{aligned} \quad (3.124)$$

$$\begin{aligned}
\mathbb{V}[n_{d,k}^{\setminus d,i}] &= \mathbb{V} \left[\sum_{i' \neq i} \delta(z_{d,i'} = k) \right] \\
&= \sum_{i' \neq i} \mathbb{V}[\delta(z_{d,i'} = k)] \\
&= \sum_{i' \neq i} q(z_{d,i'} = k) (1 - q(z_{d,i'} = k))
\end{aligned} \tag{3.125}$$

である。

同様に、 $n_{k,v}$ は文書全体において単語 v の潜在トピックに k が割り当てられた単語数である。 $\delta(w_{d,i} = v)$ は、文書 d の i 番目の単語 $w_{d,i}$ が文書全体で v 番目の単語であるとき 1 となり、 $w_{d,i} \neq v$ のとき 0 となる。

よって、 $n_{k,v}^{\setminus d,i} = \sum_{d=1}^M \sum_{i' \neq i} \delta(z_{d,i'} = k) \delta(w_{d,i'} = v)$ より、それぞれ

$$\begin{aligned}
\mathbb{E}[n_{k,v}^{\setminus d,i}] &= \mathbb{E} \left[\sum_{d=1}^M \sum_{i' \neq i} \delta(z_{d,i'} = k) \delta(w_{d,i'} = v) \right] \\
&= \sum_{d=1}^M \sum_{i' \neq i} \mathbb{E}[\delta(z_{d,i'} = k) \delta(w_{d,i'} = v)] \\
&= \sum_{d=1}^M \sum_{i' \neq i} q(z_{d,i'} = k) \delta(w_{d,i'} = v)
\end{aligned} \tag{3.126}$$

$$\mathbb{E}[n_{k,\cdot}^{\setminus d,i}] = \sum_{v=1}^V \mathbb{E}[n_{k,v}^{\setminus d,i}] \tag{3.127}$$

$$\begin{aligned}
\mathbb{V}[n_{k,v}^{\setminus d,i}] &= \mathbb{V} \left[\sum_{d=1}^M \sum_{i' \neq i} \delta(z_{d,i'} = k) \delta(w_{d,i'} = v) \right] \\
&= \sum_{d=1}^M \sum_{i' \neq i} \mathbb{V}[\delta(z_{d,i'} = k) \delta(w_{d,i'} = v)] \\
&= \sum_{d=1}^M \sum_{i' \neq i} q(z_{d,i'} = k) \delta(w_{d,i'} = v) (1 - q(z_{d,i'} = k)) \delta(w_{d,i'} = v) \\
&= \sum_{d=1}^M \sum_{i' \neq i} q(z_{d,i'} = k) (1 - q(z_{d,i'} = k)) \delta(w_{d,i'} = v)^2
\end{aligned} \tag{3.128}$$

(こう??。ついでに $\delta(w_{d,i'} = v)^2 = \delta(w_{d,i'} = v)$ だよね)

$$\mathbb{V}[n_{k,\cdot}^{\setminus d,i}] = \sum_{v=1}^V \mathbb{V}[n_{k,v}^{\setminus d,i}] \tag{3.129}$$

となる。

3.4 逐次ベイズ学習——変分近似法の場合——

データ 1 つひとつを処理する際に、逐次的に近似事後分布を更新する逐次学習について説明する。

3.4.1 確率的最適化と逐次学習

・勾配法

目的関数 $f(x)$ が最小となる x^* について考える。微分して 0 となる x を求められればよいのだが、できないことが多い。そこで、ランダムに決めた初期値 $x^{(1)}$ から更新を繰り返して x^* に近づけていく。このような手法を反復法と呼ぶ。

まず、 $f(x^{(1)})$ の微分係数 (傾き) $\frac{\partial}{\partial x} f(x^{(1)})$ を調べる。微分係数が正の値だったとき、 $x^{(1)}$ をマイナス方向に少し動かすことで $f(x^{(1)})$ が小さくなることが分かる。逆に微分係数が負の値だったとき、 $x^{(1)}$ をプラスの方向に少し動かすことで、目的関数が小さくなる。

微分係数の正負と逆方向に動かすために、 $x^{(s-1)}$ から微分係数 $\frac{\partial}{\partial x} f(x^{(s-1)})$ を引いた値を s 回目の更新値 $x^{(s)}$ とする。

$$x^{(s)} = x^{(s-1)} - \frac{\partial}{\partial x} f(x^{(s-1)})$$

次に、1 回の更新でどれだけ x を動かすのかを調整する。大きすぎると x^* を飛び越えてしまうなどの問題が生じる。逆に小さすぎると、必要な更新回数が増えてしまう。

そこで、微分係数 $\frac{\partial}{\partial x} f(x^{(s-1)})$ にステップサイズ (学習率) $\nu^{(s)}$ を移動量を調整するための重みとして掛けた値を引くことにする。

$$x^{(s)} = x^{(s-1)} - \nu^{(s)} \frac{\partial}{\partial x} f(x^{(s-1)})$$

更に、多次元関数に一般化する。 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ としたとき、微分係数のベクトル

$$\frac{\partial}{\partial \mathbf{x}} f(\mathbf{x}^{(s-1)}) = \left(\frac{\partial}{\partial x_1} f(x_1^{(s-1)}), \frac{\partial}{\partial x_2} f(x_2^{(s-1)}), \dots, \frac{\partial}{\partial x_n} f(x_n^{(s-1)}) \right)^\top$$

を勾配と呼ぶ。すると、先ほどの式は

$$\mathbf{x}^{(s)} = \mathbf{x}^{(s-1)} - \nu^{(s)} \nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)}) \quad (3.133)$$

となる。ここで、 $\nabla_{\mathbf{x}} = \frac{\partial}{\partial \mathbf{x}}$ とおく。

この手法を勾配法の中でも最急降下法と呼ぶ。

・確率的勾配法

続いて、目的関数が

$$f(\mathbf{x}) = \sum_{i=1}^n f_i(\mathbf{x})$$

の形をしている場合を考える。

このとき、勾配は $\nabla_{\mathbf{x}} f(\mathbf{x}) = \sum_{i=1}^n \nabla_{\mathbf{x}} f_i(\mathbf{x})$ となる。この式は \sum を含み計算コストが高いため、近似することを考える。

そこで、目的関数を

$$f(\mathbf{x}) = \sum_{i=1}^n f_i(\mathbf{x}) = n \sum_{i=1}^n \frac{1}{n} f_i(\mathbf{x})$$

と変形すると、確率 $p(i) = \frac{1}{n}$ による f_i の期待値とみることができる。

$$f(\mathbf{x}) = n \sum_{i=1}^n \frac{1}{n} f_i(\mathbf{x}) = n \mathbb{E}_{p(i)}[f_i(\mathbf{x})]$$

従って、 $\{f_i\}_{i=1}^n$ から確率 $p(i) = \frac{1}{n}$ でサンプリングした f_i を用いて

$$f(\mathbf{x}) = n \mathbb{E}_{p(i)}[f_i(\mathbf{x})] \approx n f_i(\mathbf{x}), \quad i \sim p(i)$$

とすれば、更新式は

$$\mathbf{x}^{(s)} = \mathbf{x}^{(s-1)} - \nu^{(s)} n \nabla_{\mathbf{x}} f_i(\mathbf{x}^{(s-1)}) \quad (3.134)$$

となる。この式で逐次的に更新を行うことができる。

この手法はアルゴリズムに乱数を含むことから確率的勾配降下法と呼ばれる。

ではこれを用いて、ある確率変数 θ による期待値計算を含む目的関数

$$f(\mathbf{x}) = \int p(\theta) f_{\theta}(\mathbf{x}) d\theta = \mathbb{E}_{p(\theta)}[f_{\theta}(\mathbf{x})]$$

について考える。

この関数の勾配は $\nabla_{\mathbf{x}} \mathbb{E}_{p(\theta)}[f_{\theta}(\mathbf{x})]$ である。これを、 $\theta_i \sim p(\theta)$ として確率的勾配 $\nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x})$ によりサンプル近似すると、更新式は

$$\mathbf{x}^{(s)} = \mathbf{x}^{(s-1)} - \nu^{(s)} \nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)})$$

である。

ここから更に、 $\nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)}) - \nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)}) = 0$ を加えて

$$\begin{aligned} \mathbf{x}^{(s)} &= \mathbf{x}^{(s-1)} - \nu^{(s)} \nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)}) \\ &= \mathbf{x}^{(s-1)} - \nu^{(s)} \left(\nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)}) + \nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)}) - \nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)}) \right) \\ &= \mathbf{x}^{(s-1)} - \nu^{(s)} \nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)}) - \nu^{(s)} \left(\nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)}) - \nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)}) \right) \\ &= \mathbf{x}^{(s-1)} - \nu^{(s)} \nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)}) - \nu^{(s)} \boldsymbol{\epsilon}^{(s)} \end{aligned} \quad (3.135)$$

と変形する。ここで、 $\boldsymbol{\epsilon}^{(s)} = \nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)}) - \nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)})$ とおく。

$\boldsymbol{\epsilon}^{(s)}$ は確率的勾配 $\nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)})$ と真の勾配 $\nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)})$ との差であるため

$$\begin{aligned}
\epsilon^{(s)} &= \nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)}) - \nabla_{\mathbf{x}} f(\mathbf{x}^{(s-1)}) \\
&= \nabla_{\mathbf{x}} f_{\theta_i}(\mathbf{x}^{(s-1)}) - \nabla_{\mathbf{x}} \mathbb{E}_{p(\theta)}[f_{\theta}(\mathbf{x}^{(s-1)})]
\end{aligned} \tag{3.136}$$

平均からのサンプル誤差を示す。

従って、式 (1.135) は、真の勾配による勾配法 (3.133) に確率的なノイズ $\epsilon^{(s)}$ を組み込んだと見ることができる。

3.4.2 自然勾配法

目的関数が確率分布に依存する場合に、その確率分布に基づいた空間における勾配を計算する。

この節では、目的関数が

$$f(\theta) = \sum_{i=1}^n \log p(x_i|\theta)$$

のように確率分布 $p(x_i|\theta)$ によって構成されているとする。 $f(\theta)$ を最大化する θ について考える。

・勾配の導出

$f(\theta + \delta\theta)$ を θ の周りで 1 次までテイラー展開すると

$$\begin{aligned}
f(\theta + \delta\theta) &\approx f(\theta) + \frac{\partial f(\theta)^\top}{\partial \theta} \{(\theta + \delta\theta) - \theta\} \\
&= f(\theta) + \nabla_{\theta} f(\theta)^\top \delta\theta
\end{aligned}$$

であることを用いて

$$\begin{aligned}
\operatorname{argmax}_{\delta\theta} f(\theta + \delta\theta) &\approx \operatorname{argmax}_{\delta\theta} \{f(\theta) + \nabla_{\theta} f(\theta)^\top \delta\theta\} \\
&= \operatorname{argmax}_{\delta\theta} \nabla_{\theta} f(\theta)^\top \delta\theta
\end{aligned} \tag{3.139}$$

となる。 $f(\theta)$ は $\delta\theta$ に影響しないため省ける。

$\delta\theta$ について、 $\|\delta\theta\|^2 \leq \epsilon$ ($\epsilon > 0$) の制約を導入する。この制約の下での最適化問題として、ラグランジュ乗数 $\lambda \geq 0$ を用いて

$$\operatorname{argmax}_{\delta\theta} \nabla_{\theta} f(\theta)^\top \delta\theta + \lambda(\epsilon - \|\delta\theta\|^2)$$

を解くと (ムリだった...)

$$\operatorname{argmax}_{\delta\theta: \|\delta\theta\|^2 \leq \epsilon} \nabla_{\theta} f(\theta)^{\top} \delta\theta = \sqrt{\frac{\epsilon}{\|\nabla_{\theta} f(\theta)\|^2}} \nabla_{\theta} f(\theta) \quad (3.140)$$

となる。 $\nu = \sqrt{\frac{\epsilon}{\|\nabla_{\theta} f(\theta)\|^2}}$ とおくと、勾配は

$$\operatorname{argmax}_{\delta\theta: \|\delta\theta\|^2 \leq \epsilon} f(\theta + \delta\theta) \approx \operatorname{argmax}_{\delta\theta: \|\delta\theta\|^2 \leq \epsilon} \nabla_{\theta} f(\theta)^{\top} \delta\theta = \nu \nabla_{\theta} f(\theta) \quad (3.141)$$

と最適化問題により定義できる。

更に、ユークリッド空間における距離の制約 $\|\delta\theta\|^2$ を $\|\delta\theta\|^2 = \|\theta - (\theta + \delta\theta)\|^2$ として、これを確率分布間の距離 (正確には距離とは言えない) である KL 情報量に置き換える。

確率分布 $p(x|\delta\theta)$ と $p(x|\theta + \delta\theta)$ との KL 情報量 $KL[p(x|\theta)||p(x|\theta + \delta\theta)]$ を用いて、勾配は

$$\operatorname{argmax}_{\delta\theta: KL[p(x|\theta)||p(x|\theta + \delta\theta)] \leq \epsilon} \nabla_{\theta} f(\theta)^{\top} \delta\theta \quad (3.142)$$

と定式化できる。

ただし、この最適化問題を解析的に解くことは難しいため、テイラー近似およびフィッシャーの情報行列を用いて KL 情報量を近似する。

・フィッシャー情報量

パラメータ θ を持つ確率分布 $p(x|\theta)$ の対数をとって θ で偏微分したものをスコア関数 $S(x)$ と呼ぶ。

$$S(x) = \frac{\partial}{\partial \theta} \log p(x|\theta)$$

スコア関数は、期待値が

$$\begin{aligned} \mathbb{E}[S(x)] &= \int p(x|\theta) \frac{\partial}{\partial \theta} \log p(x|\theta) dx \\ &= \int p(x|\theta) \frac{1}{p(x|\theta)} \frac{\partial}{\partial \theta} p(x|\theta) dx \\ &= \int \frac{\partial}{\partial \theta} p(x|\theta) dx \\ &= \frac{\partial}{\partial \theta} \int p(x|\theta) dx \\ &= \frac{\partial}{\partial \theta} 1 \\ &= 0 \end{aligned}$$

0 となる性質を持つ。ただし、微分と積分を交換可能であるとする。

また、スコア関数の分散をフィッシャー情報量 $g(\theta)$ と呼ぶ。

$$g(\theta) = \mathbb{V}[S(x)]$$

スコア関数の期待値は 0 であることから、フィッシャー情報量は

$$\begin{aligned}
g(\theta) &= \mathbb{V}[S(x)] \\
&= \mathbb{E}[S(x)^2] - \mathbb{E}[S(x)]^2 \\
&= \mathbb{E}[S(x)^2] \\
&= \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log p(x|\theta) \right)^2 \right]
\end{aligned}$$

である。

また、 $\log p(x|\theta)$ を 2 階微分すると

$$\begin{aligned}
\frac{\partial^2}{\partial \theta^2} \log p(x|\theta) &= \frac{\partial}{\partial \theta} \left(\frac{1}{p(x|\theta)} \frac{\partial}{\partial \theta} p(x|\theta) \right) \\
&= -\frac{1}{p(x|\theta)^2} \frac{\partial}{\partial \theta} p(x|\theta) \frac{\partial}{\partial \theta} p(x|\theta) + \frac{1}{p(x|\theta)} \frac{\partial^2}{\partial \theta^2} p(x|\theta) \\
&= -\left(\frac{1}{p(x|\theta)} \frac{\partial}{\partial \theta} p(x|\theta) \right)^2 + \frac{1}{p(x|\theta)} \frac{\partial^2}{\partial \theta^2} p(x|\theta) \\
\left(\frac{1}{p(x|\theta)} \frac{\partial}{\partial \theta} p(x|\theta) \right)^2 &= \frac{1}{p(x|\theta)} \frac{\partial^2}{\partial \theta^2} p(x|\theta) - \frac{\partial^2}{\partial \theta^2} \log p(x|\theta)
\end{aligned}$$

【途中式の途中式】

0. $(\log p(x|\theta))' = \frac{1}{p(x|\theta)} p(x|\theta)'$ より、 $(\log p(x|\theta))'' = (\frac{1}{p(x|\theta)} p(x|\theta)')'$ となる。
1. (積の (合成関数の) 微分を行う。

$$\begin{aligned}
f(x) &= \frac{1}{p(x|\theta)} = p(x|\theta)^{-1} \\
h'(x) &= \frac{\partial}{\partial \theta} p(x|\theta)
\end{aligned}$$

とおき、右辺を (積の) 微分すると $(f(x)h'(x))' = f'(x)h'(x) + f(x)h''(x)$ の形になる。よって、他の項は

$$\begin{aligned}
f'(x) &= -p(x|\theta)^{-2} \frac{\partial}{\partial \theta} p(x|\theta) = -\frac{1}{p(x|\theta)^2} \frac{\partial}{\partial \theta} p(x|\theta) \\
h''(x) &= \frac{\partial^2}{\partial \theta^2} p(x|\theta)
\end{aligned}$$

となる。

2. 項を整理する。
3. 移項する。

両辺で期待値をとる (あるいは $g(\theta) = \mathbb{E}[(\frac{\partial}{\partial \theta} \log p(x|\theta))^2]$ に代入する) と

$$\begin{aligned}
\mathbb{E} \left[\left(\frac{1}{p(x|\theta)} \frac{\partial}{\partial \theta} p(x|\theta) \right)^2 \right] &= \mathbb{E} \left[\frac{1}{p(x|\theta)} \frac{\partial^2}{\partial \theta^2} p(x|\theta) - \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \right] \\
\mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log p(x|\theta) \right)^2 \right] &= \mathbb{E} \left[\frac{1}{p(x|\theta)} \frac{\partial^2}{\partial \theta^2} p(x|\theta) \right] - \mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \right] \\
g(\theta) &= \int p(x|\theta) \frac{1}{p(x|\theta)} \frac{\partial^2}{\partial \theta^2} p(x|\theta) dx - \mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \right] \\
&= \int \frac{\partial^2}{\partial \theta^2} p(x|\theta) dx - \mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \right] \\
&= \frac{\partial^2}{\partial \theta^2} \int p(x|\theta) dx - \mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \right] \\
&= -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \right]
\end{aligned}$$

となる。(左辺は計算過程より $g(\theta) = \mathbb{E}[(\frac{\partial}{\partial \theta} \log p(x|\theta))^2] = \mathbb{E}[(\frac{1}{p(x|\theta)} \frac{\partial}{\partial \theta} p(x|\theta))^2]$ である。)

・フィッシャー情報行列

フィッシャー情報量

$$\begin{aligned}
g(\theta) &= -\mathbb{E}_{p(x|\theta)} \left[\frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \right] \\
&= -\int p(x|\theta) \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) dx
\end{aligned}$$

を多次元に拡張したものをフィッシャー情報行列 $G(\theta)$ と呼ぶ。(他の節と表記を合わせるには $\mathbf{x}, \boldsymbol{\theta}$ とすべきでは? $g(\theta)$ と $G(\theta)$ で式変わってないし...)

$$\begin{aligned}
G(\theta) &= -\int p(x|\theta) \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) dx \\
&= -\int p(x|\theta) \nabla_{\theta}^2 \log p(x|\theta) dx
\end{aligned} \tag{3.143}$$

また、各要素は

$$G_{j,i}(\theta) = -\int p(x|\theta) \frac{\partial^2}{\partial \theta_j \partial \theta_i} \log p(x|\theta) dx \tag{3.144}$$

と定義される。

・KL 情報量とフィッシャー情報行列の関係

$\log p(x|\theta + \delta\theta)$ を θ の周りで2次までテイラー展開すると

$$\log p(x|\theta + \delta\theta) \approx \log p(x|\theta) + \frac{\partial}{\partial \theta} \log p(x|\theta)^\top \delta\theta + \frac{1}{2} \delta\theta^\top \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \delta\theta \tag{A.6}$$

である。これを用いて、KL 情報量を式変形する。

$$\begin{aligned}
KL[p(x|\theta)||p(x|\theta + \delta\theta)] &= \int p(x|\theta) \log \frac{p(x|\theta)}{p(x|\theta + \delta\theta)} dx \\
&= \int p(x|\theta) \left(\log p(x|\theta) - \log p(x|\theta + \delta\theta) \right) dx \\
&\approx \int p(x|\theta) \left\{ \log p(x|\theta) - \left(\log p(x|\theta) + \frac{\partial}{\partial \theta} \log p(x|\theta)^\top \delta\theta + \frac{1}{2} \delta\theta^\top \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \delta\theta \right) \right\} dx \\
&= \int p(x|\theta) \left(-\frac{\partial}{\partial \theta} \log p(x|\theta)^\top \delta\theta - \frac{1}{2} \delta\theta^\top \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \delta\theta \right) dx \quad (\text{A.7}) \\
&= - \int p(x|\theta) \frac{\partial}{\partial \theta} \log p(x|\theta)^\top \delta\theta dx - \int \frac{1}{2} p(x|\theta) \delta\theta^\top \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \delta\theta dx
\end{aligned}$$

前の因子は

$$\begin{aligned}
&- \int p(x|\theta) \frac{\partial}{\partial \theta} \log p(x|\theta)^\top \delta\theta dx \\
&= - \int p(x|\theta) \frac{1}{p(x|\theta)} \frac{\partial}{\partial \theta} p(x|\theta)^\top \delta\theta dx \\
&= - \frac{\partial}{\partial \theta} \int p(x|\theta)^\top \delta\theta dx \\
&= - \frac{\partial}{\partial \theta} 1 \delta\theta \\
&= 0
\end{aligned}$$

なので、式 (A.7) はフィッシャー情報行列 (3.143) を用いて

$$\begin{aligned}
KL[p(x|\theta)||p(x|\theta + \delta\theta)] &\approx - \int \frac{1}{2} p(x|\theta) \delta\theta^\top \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) \delta\theta dx \\
&= \frac{1}{2} \delta\theta^\top \left(- \int p(x|\theta) \frac{\partial^2}{\partial \theta^2} \log p(x|\theta) dx \right) \delta\theta \\
&= \frac{1}{2} \delta\theta^\top G(\theta) \delta\theta \quad (\text{A.9, 3.147})
\end{aligned}$$

と近似できる。

・勾配の近似

では話戻って、勾配 (3.142) を近似していく。

$p(x|\theta)$ のフィッシャー情報行列 $G(\theta)$ を用いて KL 情報量を近似する。

$$\operatorname{argmax}_{\delta\theta: KL[p(x|\theta)||p(x|\theta + \delta\theta)] \leq \epsilon} \nabla_\theta f(\theta)^\top \delta\theta \approx \operatorname{argmax}_{\delta\theta: \frac{1}{2} \delta\theta^\top G(\theta) \delta\theta \leq \epsilon} \nabla_\theta f(\theta)^\top \delta\theta \quad (\text{3.148})$$

これを、制約 $\frac{1}{2}\delta\theta^\top G(\theta)\delta\theta$ の下での最適化問題としてラグランジュ乗数 λ を用いて解く。

$$L(\delta\theta) = \nabla_\theta f(\theta)^\top \delta\theta + \lambda \left(\epsilon - \frac{1}{2}\delta\theta^\top G(\theta)\delta\theta \right)$$

この式を $\delta\theta$ で微分する。

$$\begin{aligned} \frac{\partial L(\delta\theta)}{\partial \delta\theta} &= \nabla_\theta f(\theta) - \frac{1}{2}\lambda G(\theta)^\top \delta\theta - \frac{1}{2}\lambda \delta\theta^\top G(\theta) \\ &= \nabla_\theta f(\theta) - \frac{1}{2}\lambda \left(G(\theta)^\top + G(\theta) \right) \delta\theta \\ &= \nabla_\theta f(\theta) - \lambda G(\theta) \delta\theta \end{aligned}$$

$\frac{\partial L(\delta\theta)}{\partial \delta\theta} = 0$ となる $\delta\theta$ を求める。

$$\begin{aligned} \nabla_\theta f(\theta) - \lambda G(\theta) \delta\theta &= 0 \\ \delta\theta &= \frac{\nabla_\theta f(\theta)}{\lambda G(\theta)} \\ &= \lambda G(\theta)^{-1} \nabla_\theta f(\theta) \end{aligned}$$

(こっちも解けない...どうしたら λ を消せるんだ? ϵ を出すためにも、制約の式を使って置き換えるのがセオリーだと思っていたのだが...解らん??)

従って

$$\operatorname{argmax}_{\delta\theta: \frac{1}{2}\delta\theta^\top G(\theta)\delta\theta \leq \epsilon} \nabla_\theta f(\theta)^\top \delta\theta = \nu G(\theta)^{-1} \nabla_\theta f(\theta) \quad (3.150)$$

となる。

これを利用して、更新式

$$\theta = \theta + \nu G(\theta)^{-1} \nabla_\theta f_\theta(p(x|\theta)) \quad (3.151)$$

が得られる。

3.4.3 LDA の確率的変分ベイズ法

単語分布の近似事後分布 $q(\phi_k | \xi_k^\phi)$ を逐次学習により更新する。

・フィッシャー情報行列の導出

まずは、フィッシャー情報行列を求めるために $\nabla_\xi^2 \log q(\phi_k | \xi_k^\phi)$ を求める。

$$\begin{aligned}
\frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \log p(\phi_k | \xi_k^\phi) &= \frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \prod_{v=1}^V \phi_{k,v}^{\xi_{k,v}^\phi - 1} \\
&= \frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \left(\log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} + \sum_{v=1}^V (\xi_{k,v}^\phi - 1) \log \phi_{k,v} \right) \\
&= \frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} + \frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \sum_{v=1}^V (\xi_{k,v}^\phi - 1) \log \phi_{k,v} \quad (3.152)
\end{aligned}$$

後の因子は

$$\frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \sum_{v=1}^V (\xi_{k,v}^\phi - 1) \log \phi_{k,v} = \frac{\partial}{\partial \xi_{k,v}^\phi} \log \phi_{k,v'} = 0$$

であるため

$$\begin{aligned}
\frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \log p(\phi_k | \xi_k^\phi) &= \frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \\
&= \frac{\partial}{\partial \xi_{k,v}^\phi} \frac{\partial}{\partial \xi_{k,v'}^\phi} \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)}
\end{aligned}$$

となる。更に、式 (3.103) を用いて期待値に置き換える。

$$\begin{aligned}
\frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \log p(\phi_k | \xi_k^\phi) &= -\frac{\partial}{\partial \xi_{k,v}^\phi} \frac{\partial}{\partial \xi_{k,v'}^\phi} \left(-\log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right) \\
&= -\frac{\partial}{\partial \xi_{k,v}^\phi} \frac{\partial}{\partial \xi_{k,v'}^\phi} \left(\sum_{v=1}^V \log \Gamma(\xi_{k,v}^\phi) - \log \Gamma\left(\sum_{v=1}^V \xi_{k,v}^\phi\right) \right) \\
&= -\frac{\partial}{\partial \xi_{k,v}^\phi} \left(\Psi(\xi_{k,v'}^\phi) - \Psi\left(\sum_{v=1}^V \xi_{k,v}^\phi\right) \right) \\
&= -\frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\phi_k | \xi_k^\phi)} [\log \phi_{k,v'}] \quad (3.153)
\end{aligned}$$

従って、式 (3.144) より $q(\phi_k | \xi_k^\phi)$ のフィッシャー情報行列 $G(\xi_k^\phi)$ の v, v' 要素は

$$\begin{aligned}
G_{v,v'}(\xi_k^\phi) &= -\int q(\phi_k | \xi_k^\phi) \frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \log q(\phi_k | \xi_k^\phi) d\phi_k \\
&= -\mathbb{E}_{q(\phi_k | \xi_k^\phi)} \left[\frac{\partial^2}{\partial \xi_{k,v}^\phi \partial \xi_{k,v'}^\phi} \log q(\phi_k | \xi_k^\phi) \right] \\
&= -\mathbb{E}_{q(\phi_k | \xi_k^\phi)} \left[-\frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\phi_k | \xi_k^\phi)} [\log \phi_{k,v'}] \right] \\
&= \frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\phi_k | \xi_k^\phi)} [\log \phi_{k,v'}] \quad (3.154)
\end{aligned}$$

となる。

・変分下限の勾配の導出

LDA の変分下限は 3.3.6 項の式 (3.102) を用いる。

$$\begin{aligned}
F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)] &= \sum_{k=1}^K \left[\log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} - \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right] + \sum_{k=1}^K \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&\quad + \sum_{d=1}^M \left[\log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} - \log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \right] + \sum_{d=1}^M \sum_{k=1}^K (\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k - \xi_{d,k}^\theta) \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k)
\end{aligned} \tag{3.102}$$

変分下限の勾配 $\nabla_{\xi_{k,v}^\phi} F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)]$ を求める。

$$\begin{aligned}
\frac{\partial}{\partial \xi_{k,v}^\phi} F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)] &= \frac{\partial}{\partial \xi_{k,v}^\phi} \left(-\log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right) + \frac{\partial}{\partial \xi_{k,v}^\phi} \left(-\xi_{k,v}^\phi \right) \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&\quad + \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&= \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] - \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&\quad + \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&= \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}]
\end{aligned} \tag{3.104}$$

・更新式の導出

従って、式 (3.150) より自然勾配を用いた更新式は、ステップサイズを ν_s として

$$\begin{aligned}
\xi_k^{\phi(s+1)} &= \xi_k^{\phi(s)} + \nu_s G^{-1}(\xi_k^\phi) \nabla_{\xi_k^\phi} F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)] \\
&= \xi_k^{\phi(s)} + \nu_s G^{-1}(\xi_k^\phi) \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}]
\end{aligned} \tag{3.156}$$

となる。

また、各成分は、式 (3.154) より

$$\begin{aligned}
\xi_{k,v}^{\phi(s+1)} &= \xi_{k,v}^{\phi(s)} + \nu_s G_{v,v'}(\boldsymbol{\xi}_k^\phi)^{-1} (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\phi_k|\boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&= \xi_{k,v}^{\phi(s)} + \nu_s \frac{1}{\frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\phi_k|\boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}]} (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \frac{\partial}{\partial \xi_{k,v}^\phi} \mathbb{E}_{q(\phi_k|\boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&= \xi_{k,v}^{\phi(s)} + \nu_s (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \\
&= \xi_{k,v}^{\phi(s)} - \nu_s \xi_{k,v}^\phi + \nu_s (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v) \\
&= (1 - \nu_s) \xi_{k,v}^\phi + \nu_s (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v)
\end{aligned} \tag{3.157}$$

となる。

この更新式が $\nu_s = 1$ のとき

$$\xi_{k,v}^{\phi(s+1)} = \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v \tag{3.95}$$

となり、変分ベイズ法での更新式となることが確認できる。

・ 確率的最適化

文書 d に含まれる同一単語 v の中でトピック k が割り当てられた単語数を $n_{d,k,v}$ とすると、その期待値は

$$\mathbb{E}_{q(\mathbf{z})}[n_{d,k,v}] = \sum_{i=1}^{n_d} q(z_{d,i} = k) \delta(w_{d,i} = v)$$

である。全文書における同一単語 v の中でトピック k が割り当てられた単語数 $n_{k,v}$ の期待値は

$$\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] = \sum_{d=1}^M \mathbb{E}_{q(\mathbf{z})}[n_{d,k,v}]$$

となる。

これを用いて、式 (3.157) の (3 行目の) 勾配を

$$\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi = \sum_{d=1}^M \frac{1}{M} \left(M \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi \right) \tag{3.158}$$

と変形する。 $p(d) = \frac{1}{M}$ として、確率的最適化による更新式

$$\xi_{k,v}^{\phi(s+1)} = \xi_{k,v}^{\phi(s)} + \nu_s (M \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^{\phi(s)}) \tag{3.159}$$

が得られる。

3.5 逐次ベイズ学習——サンプリング近似法の場合——

データに対して S 個の周辺化ギブスサンプリングを並列に行うことで事後分布を近似する。

3.5.1 粒子フィルタ

粒子フィルタは、時系列データを解析する動的システムにおいて、潜在変数のサンプリングを可能にする技術である。ある時刻において、それまでに与えられた観測データの下での潜在変数の事後分布を重み付きサンプルによって近似する。

時刻 t の観測データ x_t は、潜在変数 z_t に依存する確率分布 $p(x_t|z_t)$ によって生成されたと仮定する。また、潜在変数 z_t は 1 つ前の時刻 $t-1$ における潜在変数 z_{t-1} に依存した確率分布 $p(z_t|z_{t-1})$ によって生成されたと仮定する。(図 3.7(a))

$$\begin{aligned}x_t &\sim p(x_t|z_t) \\ z_t &\sim p(z_t|z_{t-1})\end{aligned}$$

・重みの導入

時刻 $t+1$ において、それまでに観測されたデータ $x_{1:t}$ が与えられた下で、観測データ x_{t+1} を生成する潜在変数 z_{t+1} の条件付き確率分布 $p(z_{t+1}|x_{1:t})$ は、提案分布 $q(z_{1:t}|x_{1:t})$ を $\frac{q(z_{1:t}|x_{1:t})}{q(z_{1:t}|x_{1:t})} = 1$ を掛ける形で導入して

$$\begin{aligned}p(z_{t+1}|x_{1:t}) &= \int p(z_{t+1}, z_{1:t}|x_{1:t}) dz_{1:t} \\ &= \int p(z_{t+1}|z_{1:t}, x_{1:t}) p(z_{1:t}|x_{1:t}) dz_{1:t} \\ &= \int p(z_{t+1}|z_{1:t}) \frac{p(z_{1:t}|x_{1:t})}{q(z_{1:t}|x_{1:t})} q(z_{1:t}|x_{1:t}) dz_{1:t} \\ &= \int p(z_{t+1}|z_{1:t}) \omega(z_{1:t}) q(z_{1:t}|x_{1:t}) dz_{1:t}\end{aligned}\tag{3.160}$$

となる。ここで

$$\omega(z_{1:t}) = \frac{p(z_{1:t}|x_{1:t})}{q(z_{1:t}|x_{1:t})}\tag{3.161}$$

とおく。

提案分布 $q(z_{1:t}|x_{1:t})$ からのサンプル $z_{1:t}^{(s)} \sim q(z_{1:t}|x_{1:t})$ ($s = 1, 2, \dots, S$) を用いて、 $p(z_{1:t}|x_{1:t})$ を

$$\begin{aligned}p(z_{1:t}|x_{1:t}) &= \frac{p(z_{1:t}|x_{1:t})}{q(z_{1:t}|x_{1:t})} q(z_{1:t}|x_{1:t}) \\ &= \omega(z_{1:t}) q(z_{1:t}|x_{1:t}) \approx \tilde{p}_S(z_{1:t}|x_{1:t})\end{aligned}$$

と近似する。 $\tilde{p}_S(z_{1:t}|x_{1:t})$ は

$$\begin{aligned}
\tilde{p}_S(z_{1:t}|x_{1:t}) &= \sum_{s=1}^S \frac{\omega(z_{1:t}^{(s)})}{\sum_{s=1}^S \omega(z_{1:t}^{(s)})} \delta(z_{1:t} = z_{1:t}^{(s)}) \\
&= \sum_{s=1}^S \bar{\omega}(z_{1:t}^{(s)}) \delta(z_{1:t} = z_{1:t}^{(s)})
\end{aligned} \tag{3.162}$$

である。ここで、 $\bar{\omega}(z_{1:t}^{(s)}) = \frac{\omega(z_{1:t}^{(s)})}{\sum_{s=1}^S \omega(z_{1:t}^{(s)})}$, $0 \leq \bar{\omega}(z_{1:t}^{(s)}) \leq 1$, $\sum_{s=1}^S \bar{\omega}(z_{1:t}^{(s)}) = 1$ とおく。(数学的に高度なので読み飛ばし可とのことなので今回はこの理由を読み飛ばした...) 次からは、この重みの逐次更新式を求めていく。

・重みの更新式の導出

式 (3.60) の積分を $\tilde{p}_S(z_{1:t}|x_{1:t})$ によって近似する。

$$\begin{aligned}
p(z_{t+1}|x_{1:t}) &= \int p(z_{t+1}|z_{1:t}) p(z_{1:t}|x_{1:t}) dz_{1:t} \\
&\approx \int p(z_{t+1}|z_{1:t}) \tilde{p}_S(z_{1:t}|x_{1:t}) dz_{1:t} \\
&= \int p(z_{t+1}|z_{1:t}) \sum_{s=1}^S \bar{\omega}(z_{1:t}^{(s)}) \delta(z_{1:t} = z_{1:t}^{(s)}) dz_{1:t} \\
&= \sum_{s=1}^S \bar{\omega}(z_{1:t}^{(s)}) p(z_{t+1}|z_{1:t}^{(s)})
\end{aligned} \tag{3.165}$$

デルタ関数の性質 $\int f(x) \delta(x = a) dx = f(x = a)$ を用いている。
ここで、提案分布を

$$\begin{aligned}
q(z_{1:t}|x_{1:t}) &= q(z_t, z_{1:t-1}|x_{1:t}) \\
&= q(z_t|x_{1:t}, z_{1:t-1}) q(z_{1:t-1}|x_{1:t}) \\
&= q(z_t|x_{1:t}, z_{1:t-1}) q(z_{t-1}, z_{1:t-2}|x_{1:t}) \\
&= q(z_t|x_{1:t}, z_{1:t-1}) q(z_{t-1}|x_{1:t}, z_{1:t-2}) q(z_{1:t-2}|x_{1:t}) \\
&= q(z_t|x_{1:t}, z_{1:t-1}) q(z_{t-1}|x_{1:t}, z_{1:t-2}) \cdots q(z_1|x_{1:t}, z_0) q(z_0|x_{1:t}) \\
&= q(z_t|x_{1:t}, z_{1:t-1}) q(z_{t-1}|x_{1:t-1}, z_{1:t-2}) \cdots q(z_1|x_1, z_0) q(z_0) \\
&= q(z_0) \prod_{l=1}^t q(z_l|x_{1:l}, z_{1:l-1})
\end{aligned} \tag{3.166}$$

とおく。ただし図 3.7(a) より、時刻 t の観測値 x_t が 1 つ前の時刻の潜在変数 z_{t-1} に影響しないことを考慮して、 $q(z_{1:t-1}|x_{1:t}) = q(z_{1:t-1}|x_{1:t-1})$ と設定し、置き換えている。

これを用いて、重みの更新式を導出する。更新式は $\omega(z_{1:t}^{(s)}) = \omega(z_{1:t-1}^{(s)}) F(\cdot)$ の形になることから、 $\frac{\omega(z_{1:t}^{(s)})}{\omega(z_{1:t-1}^{(s)})}$ を求めればよい。よって、式 (3.161) より

$$\begin{aligned}
\frac{\omega(z_{1:t}^{(s)})}{\omega(z_{1:t-1}^{(s)})} &= \frac{p(z_{1:t}^{(s)}|x_{1:t})}{q(z_{1:t}^{(s)}|x_{1:t})} \frac{q(z_{1:t-1}^{(s)}|x_{1:t-1})}{p(z_{1:t-1}^{(s)}|x_{1:t-1})} \\
&= \frac{p(z_{1:t}^{(s)}|x_{1:t})}{p(z_{1:t-1}^{(s)}|x_{1:t-1})} \frac{q(z_{1:t-1}^{(s)}|x_{1:t-1})}{q(z_{1:t}^{(s)}|x_{1:t})} \\
&= \frac{p(z_{1:t}^{(s)}, x_{1:t})p(x_{1:t-1})}{p(x_{1:t})p(z_{1:t-1}^{(s)}, x_{1:t-1})} \frac{q(z_{1:t-1}^{(s)}|x_{1:t-1})}{q(z_t^{(s)}|x_{1:t}, z_{1:t-1}^{(s)})q(z_{1:t-1}^{(s)}|x_{1:t})} \\
&\propto \frac{p(z_{1:t}^{(s)}, x_{1:t})}{p(z_{1:t-1}^{(s)}, x_{1:t-1})} \frac{1}{q(z_t^{(s)}|x_{1:t}, z_{1:t-1}^{(s)})} \\
&= \frac{p(z_t^{(s)}, x_t, z_{1:t-1}^{(s)}, x_{1:t-1})}{p(z_{1:t-1}^{(s)}, x_{1:t-1})} \frac{1}{q(z_t^{(s)}|x_{1:t}, z_{1:t-1}^{(s)})} \\
&= \frac{p(z_t^{(s)}, x_t|z_{1:t-1}^{(s)}, x_{1:t-1})}{q(z_t^{(s)}|x_{1:t}, z_{1:t-1}^{(s)})} \\
&= \frac{p(x_t|z_t^{(s)}, z_{1:t-1}^{(s)}, x_{1:t-1})p(z_t^{(s)}|z_{1:t-1}^{(s)}, x_{1:t-1})}{q(z_t^{(s)}|x_{1:t}, z_{1:t-1}^{(s)})} \tag{3.168}
\end{aligned}$$

【途中式の途中式】

0. 式 (3.161) より置き換える。
1. $p(\cdot)$ と $q(\cdot)$ を揃えるために、分母を入れ替える。
2. 項を変形する。
 - $p(A_1|A_2, B) = \frac{p(A_1, A_2|B)}{p(A_2|B)}$ より、前の因子の分母分子をそれぞれ変形する。
 - $p(A_{1:2}|B) = p(A_1, A_2|B) = p(A_1|A_2, B)p(A_2|B)$ より、後ろの因子の分母を変形する。
3. 式を整理する。
 - $z_{1:t}^{(s)}, z_{1:t-1}^{(s)}$ に関係する項のみ取り出す。
 - 提案分布を $q(z_{1:t-1}^{(s)}|x_{1:t}) = q(z_{1:t-1}^{(s)}|x_{1:t-1})$ と設定したので、約分する。
4. 式を整理するために、分子の項から t についての変数を取り出しておく。
5. $\frac{p(A_1, A_2)}{p(A_2)} = p(A_1|A_2)$ より、変形する。

更に、提案分布を $q(z_t^{(s)}|x_{1:t}, z_{1:t-1}^{(s)}) = p(z_t^{(s)}|z_{1:t-1}^{(s)}, x_{1:t-1})$ とすると

$$\frac{\omega(z_{1:t}^{(s)})}{\omega(z_{1:t-1}^{(s)})} \propto \frac{p(x_t|z_t^{(s)}, z_{1:t-1}^{(s)}, x_{1:t-1})p(z_t^{(s)}|z_{1:t-1}^{(s)}, x_{1:t-1})}{q(z_t^{(s)}|x_{1:t}, z_{1:t-1}^{(s)})} \tag{3.168}$$

$$\begin{aligned}
&= \frac{p(x_t|z_t^{(s)}, z_{1:t-1}^{(s)}, x_{1:t-1})p(z_t^{(s)}|z_{1:t-1}^{(s)}, x_{1:t-1})}{p(z_t^{(s)}|z_{1:t-1}^{(s)}, x_{1:t-1})} \\
&= p(x_t|z_t^{(s)}, z_{1:t-1}^{(s)}, x_{1:t-1}) \\
\omega(z_{1:t}^{(s)}) &= \omega(z_{1:t-1}^{(s)})p(x_t|z_t^{(s)}, z_{1:t-1}^{(s)}, x_{1:t-1}) \tag{3.169}
\end{aligned}$$

重みの逐次更新式が得られる。

正規化は次の式で行う。

$$\bar{\omega}(z_{1:t}^{(s)}) = \frac{\omega(z_{1:t}^{(s)})}{\sum_{s=1}^S \omega(z_{1:t}^{(s)})}$$

3.5.2 LDA の粒子フィルタ

LDA の学習に粒子フィルタを用いる方法を説明する。

観測された単語 \mathbf{w} の下での、潜在トピック \mathbf{z} の条件付き分布 $p(\mathbf{z}|\mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta})$ を粒子フィルタを用いて近似する。

・ サンプル式式の導出

3.2.4 項 (LDA の周辺化ギブスサンプリング) のサンプリング式 (3.38) の導出過程と同様にして、 $\mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i)}$ が与えられた下での潜在変数 $z_{d,i}$ の分布を求める。

$$\begin{aligned}
& p(z_{d,i} = k | w_{d,i} = v, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= \frac{p(z_{d,i} = k, w_{d,i} = v, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)} | \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(w_{d,i} = v, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)} | \boldsymbol{\alpha}, \boldsymbol{\beta})} \\
&\propto p(z_{d,i} = k, w_{d,i} = v, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)} | \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= p(w_{d,i} = v | z_{d,i} = k, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(z_{d,i} = k | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(\mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)} | \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&\propto p(w_{d,i} = v | z_{d,i} = k, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(z_{d,i} = k | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})
\end{aligned}$$

周辺化したパラメータを明示すると

$$\begin{aligned}
& p(z_{d,i} = k | w_{d,i} = v, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&\propto p(w_{d,i} = v | z_{d,i} = k, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)} | \boldsymbol{\alpha}, \boldsymbol{\beta}) p(z_{d,i} = k | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= \int p(w_{d,i} = v, \phi | z_{d,i} = k, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) d\phi \int p(z_{d,i} = k, \theta | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) d\theta \\
&= \int p(w_{d,i} = v | \phi, z_{d,i} = k, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(\phi | z_{d,i} = k, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) d\phi \\
&\quad * \int p(z_{d,i} = k | \theta, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(\theta | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) d\theta \\
&= \int p(w_{d,i} = v | z_{d,i} = k, \phi) p(\phi | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\beta}) d\phi \int p(z_{d,i} = k | \theta) p(\theta | \mathbf{z}^{(d,i-1)}, \boldsymbol{\alpha}) d\theta \\
&\propto \int p(w_{d,i} = v | z_{d,i} = k, \phi_k) p(\phi_k | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\beta}) d\phi_k \int p(z_{d,i} = k | \theta_d) p(\theta_d | \mathbf{z}^{(d,i-1)}, \boldsymbol{\alpha}) d\theta_d \\
&= \int \phi_{k,v} p(\phi_k | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\beta}) d\phi_k \int \theta_{d,k} p(\theta_d | \mathbf{z}^{(d,i-1)}, \boldsymbol{\alpha}) d\theta_d \\
&= \mathbb{E}_{p(\phi_k | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\beta})} [\phi_{k,v}] \mathbb{E}_{p(\theta_d | \mathbf{z}^{(d,i-1)}, \boldsymbol{\alpha})} [\theta_{d,k}]
\end{aligned}$$

となる。 $p(\phi_k | \cdot), p(\theta_d | \cdot)$ をそれぞれ正規化した (正規化項を付けた) 上で、Dirichlet 分布の期待値計算 (2.10) を行うと

$$\begin{aligned}
p(z_{d,i} = k | w_{d,i} = v, \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \mathbb{E}_{p(\phi_k | \mathbf{z}^{(d,i-1)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\beta})} [\phi_{k,v}] \mathbb{E}_{p(\theta_d | \mathbf{z}^{(d,i-1)}, \boldsymbol{\alpha})} [\theta_{d,k}] \\
&= \frac{n_{k,v}^{(d,i-1)} + \beta_v}{\sum_{v=1}^V (n_{k,v}^{(d,i-1)} + \beta_v)} \frac{n_{d,k}^{(d,i-1)} + \alpha_k}{\sum_{k=1}^K (n_{d,k}^{(d,i-1)} + \alpha_k)} \quad (3.171)
\end{aligned}$$

が得られる。

従って、S 個の並列サンプルを $\{\mathbf{z}^{(d,i)(s)}\}_{s=1}^S$ として表すと、それぞれのサンプル粒子 $\mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i)}$ が与えられた下での $z_{d,i}^{(s)}$ の分布は

$$p(z_{d,i}^{(s)} = k | w_{d,i} = v, \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \propto \frac{n_{k,v}^{(d,i-1)(s)} + \beta_v}{\sum_{v=1}^V (n_{k,v}^{(d,i-1)(s)} + \beta_v)} \frac{n_{d,k}^{(d,i-1)(s)} + \alpha_k}{\sum_{k=1}^K (n_{d,k}^{(d,i-1)(s)} + \alpha_k)} \quad (3.172)$$

となる。(正規化した上で期待値を出した結果がこの式なので両辺はイコールでいいと思うのだから??)

・重みの更新式の導出

3.5.1 項の重みの更新式 (3.168) より、LDA の重みの更新式は

$$\frac{\omega(\mathbf{z}^{(d,i)(s)})}{\omega(\mathbf{z}^{(d,i-1)(s)})} = \frac{p(w_{d,i} | z_{d,i}^{(s)}, \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta})} \quad (3.173)$$

となる。

分母の提案分布を

$$q(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = p(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

と設定すると

$$\begin{aligned} \frac{\omega(\mathbf{z}^{(d,i)(s)})}{\omega(\mathbf{z}^{(d,i-1)(s)})} &\propto p(w_{d,i} | z_{d,i}^{(s)}, \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \frac{1}{p(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta})} p(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\ &= \frac{p(w_{d,i}, z_{d,i}^{(s)}, \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(z_{d,i}^{(s)}, \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})} \frac{p(\mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(z_{d,i}^{(s)}, \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta})} p(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\ &= \frac{p(\mathbf{z}^{(d,i)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(\mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})} \frac{p(\mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(\mathbf{z}^{(d,i)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta})} \\ &\quad * p(z_{d,i}^{(s)} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\ &= \frac{p(\mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(\mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})} \\ &= \frac{p(w_{d,i}, \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})}{p(\mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta})} \\ &= p(w_{d,i} | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\ &= \sum_{k=1}^K p(w_{d,i}, z_{d,i} = k | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \end{aligned} \quad (3.174)$$

となる。最後は周辺化 $\sum_B p(A, B | C) = p(A | C)$ する形式で、 $z_{d,i}$ を式に含めた。

従って、重みの更新式

$$\omega(\mathbf{z}^{(d,i)(s)}) \propto \omega(\mathbf{z}^{(d,i-1)(s)}) \sum_{k=1}^K p(w_{d,i}, z_{d,i}^{(s)} = k | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \quad (3.175)$$

が得られる。ここで、サンプリング式 (3.171) の導出仮定より

$$\begin{aligned}
& \sum_{k=1}^K p(w_{d,i} = v, z_{d,i}^{(s)} = k | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= \sum_{k=1}^K p(w_{d,i} = v | z_{d,i}^{(s)} = k, \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) p(z_{d,i}^{(s)} = k | \mathbf{z}^{(d,i-1)(s)}, \mathbf{w}^{(d,i-1)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&= \sum_{k=1}^K \frac{n_{k,v}^{(d,i-1)(s)} + \beta_v}{\sum_{v=1}^V (n_{k,v}^{(d,i-1)(s)} + \beta_v)} \frac{n_{d,k}^{(d,i-1)(s)} + \alpha_k}{\sum_{k=1}^K (n_{d,k}^{(d,i-1)(s)} + \alpha_k)}
\end{aligned} \tag{3.176}$$

である。

・事後分布の近似

重み $\omega(\mathbf{z}^{(d,i-1)(s)})$ を次の式で正規化する。

$$\bar{w}(\mathbf{z}^{(d,i-1)(s)}) = \frac{\omega(\mathbf{z}^{(d,i-1)(s)})}{\sum_{s=1}^S \omega(\mathbf{z}^{(d,i-1)(s)})}$$

これを用い、式 (3.162) と同様にして、 $p(\mathbf{z} | \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta})$ を近似できる。

$$p(\mathbf{z}^{(d,i)} | \mathbf{w}^{(d,i)}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \approx \sum_{s=1}^S \bar{w}(\mathbf{z}^{(d,i-1)(s)}) \delta(\mathbf{z}^{(d,i)} = \mathbf{z}^{(d,i)(s)}) \tag{3.177}$$

3.6 Dirichlet 分布のパラメータ推定

事前分布 $p(\boldsymbol{\theta}_d | \boldsymbol{\alpha})$, $p(\phi_k | \boldsymbol{\beta})$ のパラメータ $\boldsymbol{\alpha}$, $\boldsymbol{\beta}$ を点推定する方法について説明する。

3.6.1 対象/非対称 Dirichlet 分布の性質

トピック分布のパラメータ $\boldsymbol{\alpha}$ は非対称とし、単語分布のパラメータ $\boldsymbol{\beta}$ は対称とした方が良い結果になることが知られている。

3.6.2 変分ベイズ法における Dirichlet 分布のパラメータ推定

特になし。

3.6.3 固定点反復法

固定点反復法を用いて、LDA のハイパーパラメータ $\boldsymbol{\alpha}$, $\boldsymbol{\beta}$ を推定する。

関数 $f(x)$ に対して

$$x = f(x) \quad (3.180)$$

の形の非線形方程式を考える。この方程式を満たす x^* を関数 $f(x)$ の固定点 (不動点) と呼ぶ。
固定点反復法は、適当な初期値 $x^{(0)}$ から

$$x^{(s+1)} = f(x^{(s)}) \quad (3.181)$$

の計算を繰り返し行うことで不動点 x^* に近づけていく方法である。

・変分下限の導出

Dirichlet 分布のパラメータ推定における固定点反復法では、変分下限の更に下限を用いる。

3.3.6 項 (LDA の変分ベイズ法 (2)) の変分下限 (3.102) を用いる。

$$\begin{aligned} F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)] &= \sum_{k=1}^K \left[\log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} - \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right] \\ &\quad + \sum_{k=1}^K \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\ &\quad + \sum_{d=1}^M \left[\log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} - \log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \right] \\ &\quad + \sum_{d=1}^M \sum_{k=1}^K (\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k - \xi_{d,k}^\theta) \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \\ &\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \end{aligned} \quad (3.102)$$

また、3.3.5 項や 3.3.6 項で導出したハイパーパラメータの更新式は

$$\begin{aligned} \xi_{k,v}^\phi &= \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v \\ \xi_{d,k}^\theta &= \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k \end{aligned}$$

である。

この更新後の値をそれぞれ変分下限 (3.102) に代入すると

$$\begin{aligned}
F[q(\mathbf{z}, \boldsymbol{\theta}, \phi | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)] &= \sum_{k=1}^K \left[\log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} - \log \frac{\Gamma(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v)}{\prod_{v=1}^V \Gamma(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v)} \right] \\
&\quad + \sum_{d=1}^M \left[\log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} - \log \frac{\Gamma(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k)}{\prod_{k=1}^K \Gamma(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k)} \right] \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&= \sum_{k=1}^K \log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} \frac{\prod_{v=1}^V \Gamma(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v)}{\Gamma(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v)} \\
&\quad + \sum_{d=1}^M \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \frac{\prod_{k=1}^K \Gamma(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k)}{\Gamma(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k)} \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \\
&= \sum_{k=1}^K \log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\Gamma(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v)} \prod_{v=1}^V \frac{\Gamma(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v)}{\Gamma(\beta_v)} \tag{1} \\
&\quad + \sum_{d=1}^M \log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\Gamma(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k)} \prod_{k=1}^K \frac{\Gamma(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k)}{\Gamma(\alpha_k)} \tag{2} \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) \tag{3.182}
\end{aligned}$$

が得られる。次の不等式と対応させるために、それぞれ分母を入れ替えて式を整理している。

・ガンマ関数の不等式

任意の $\hat{x} \geq 0$ に対して、 $x > 0$, $n \geq 0$ のとき

$$\frac{\Gamma(x)}{\Gamma(n+x)} \geq \frac{\Gamma(\hat{x}) \exp\left((\hat{x}-x)b\right)}{\Gamma(n+\hat{x})} \tag{3.183}$$

$$b = \Psi(n+\hat{x}) - \Psi(\hat{x}) \tag{3.184}$$

また、 $n \geq 1$ のとき

$$\frac{\Gamma(n+x)}{\Gamma(x)} \geq cx^a \tag{3.185}$$

$$a = \left(\Psi(n+\hat{x}) - \Psi(\hat{x}) \right) \hat{x} \tag{3.186}$$

$$c = \frac{\Gamma(n+\hat{x})}{\Gamma(\hat{x})} \hat{x}^{-a} \tag{3.187}$$

が成り立つ。

この不等式を用いて、変分下限 (3.182) の更に下限を求めて、それを用いてハイパーパラメータの更新式を導出する。

・トピック分布のパラメータの更新式の導出

まずは、トピック分布のパラメータ α を求める。

式 (2) について、 $\sum_{k=1}^K \alpha_k$, α_k を x , $\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}]$, $\mathbb{E}_{p(\mathbf{z}_d)}[n_{d,k}]$ を n と対応させて、 a , b をそれぞれ $a_{d,k}^\theta$, b_d^θ として、下限を求める。

前の因子は

$$\frac{\Gamma\left(\sum_{k=1}^K \alpha_k\right)}{\Gamma\left(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k\right)} \geq \frac{\Gamma\left(\sum_{k=1}^K \hat{\alpha}_k\right) \exp\left(\left(\sum_{k=1}^K \hat{\alpha}_k - \alpha_k\right)b_d^\theta\right)}{\Gamma\left(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k\right)}$$

$$b_d^\theta = \Psi\left(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k\right) - \Psi\left(\sum_{k=1}^K \hat{\alpha}_k\right)$$

となり、また後の因子は

$$\frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k\right)}{\Gamma(\alpha_k)} \geq \frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k\right)}{\Gamma(\hat{\alpha}_k)} \hat{\alpha}_k^{-a_{d,k}^\theta} \alpha_k^{a_{d,k}^\theta}$$

$$a_{d,k}^\theta = \left(\Psi\left(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k\right) - \Psi(\hat{\alpha}_k)\right) \hat{\alpha}_k$$

となる。

従って、式 (2) の下限はこれらを組み併せて

$$\begin{aligned} & \sum_{d=1}^M \log \frac{\Gamma\left(\sum_{k=1}^K \alpha_k\right)}{\Gamma\left(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k\right)} \prod_{k=1}^K \frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k\right)}{\Gamma(\alpha_k)} \\ & \geq \sum_{d=1}^M \log \frac{\Gamma\left(\sum_{k=1}^K \hat{\alpha}_k\right) \exp\left(\left(\sum_{k=1}^K \hat{\alpha}_k - \alpha_k\right)b_d^\theta\right)}{\Gamma\left(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k\right)} \prod_{k=1}^K \frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k\right)}{\Gamma(\hat{\alpha}_k)} \hat{\alpha}_k^{-a_{d,k}^\theta} \alpha_k^{a_{d,k}^\theta} \\ & = \sum_{d=1}^M \left[\log \Gamma\left(\sum_{k=1}^K \hat{\alpha}_k\right) + \left(\sum_{k=1}^K \hat{\alpha}_k - \alpha_k\right)b_d^\theta - \log \Gamma\left(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k\right) \right. \\ & \quad \left. + \sum_{k=1}^K \left\{ \log \Gamma\left(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k\right) - \log \Gamma(\hat{\alpha}_k) - a_{d,k}^\theta \log \hat{\alpha}_k + a_{d,k}^\theta \log \alpha_k \right\} \right] \\ & = \sum_{d=1}^M \left[-b_d^\theta \sum_{k=1}^K \alpha_k + \sum_{k=1}^K a_{d,k}^\theta \log \alpha_k \right] + (\text{const.}) \equiv F[\alpha_k] \end{aligned} \tag{3.190}$$

となる。(どうせ微分すると消えるので) α に関係しない項をまとめて (const.) とする。
この下限 $F[\alpha_k]$ を最大にする α を求めるために、 α_k で微分して 0 となる停留点を求める。

$$\frac{\partial F[\alpha_k]}{\partial \alpha_k} = \sum_{d=1}^M \left[-b_d^\theta + \frac{1}{\alpha_k} a_{d,k}^\theta \right] = 0$$

$$\alpha_k = \frac{\sum_{d=1}^M a_{d,k}^\theta}{\sum_{d=1}^M b_d^\theta}$$

$a_{d,k}^\theta, b_d^\theta$ をそれぞれ代入すると

$$\alpha_k = \hat{\alpha}_k \frac{\sum_{d=1}^M [\Psi(\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \hat{\alpha}_k) - \Psi(\hat{\alpha}_k)]}{\sum_{d=1}^M [\Psi(\sum_{k=1}^K \mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k) - \Psi(\sum_{k=1}^K \hat{\alpha}_k)]} \quad (3.191)$$

が得られる。

$\hat{\alpha}_k$ を 1 ステップ前の値とすれば、 α_k に対する固定点反復法が得られた。

・ 単語分布のパラメータの更新式の導出

・ 非対称

同様に、単語分布のパラメータ β を求める。

式 (1) について、 $\sum_{v=1}^V \beta_v, \beta_v$ を $x, \sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}], \mathbb{E}_{p(\mathbf{z}_d)}[n_{k,v}]$ を n と対応させて、 a, b をそれぞれ $a_{k,v}^\phi, b_k^\phi$ として、下限を求める。

前の因子は

$$\frac{\Gamma\left(\sum_{v=1}^V \beta_v\right)}{\Gamma\left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v\right)} \geq \frac{\Gamma\left(\sum_{v=1}^V \hat{\beta}_v\right) \exp\left((\sum_{v=1}^V \hat{\beta}_v - \beta_v) b_k^\phi\right)}{\Gamma\left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right)}$$

$$b_k^\phi = \Psi\left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right) - \Psi\left(\sum_{v=1}^V \hat{\beta}_v\right)$$

となり。また後ろの因子は

$$\frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v\right)}{\Gamma(\beta_v)} \geq \frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right)}{\Gamma(\hat{\beta}_v)} \hat{\beta}_v^{-a_{k,v}^\phi} \beta_v^{a_{k,v}^\phi}$$

$$a_{k,v}^\phi = \left(\Psi(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v) - \Psi(\hat{\beta}_v)\right) \hat{\beta}_v$$

となる。

従って、式 (1) の下限はこれらを組み併せて

$$\begin{aligned}
& \sum_{k=1}^K \log \frac{\Gamma\left(\sum_{v=1}^V \beta_v\right)}{\Gamma\left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v\right)} \prod_{v=1}^V \frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v\right)}{\Gamma(\beta_v)} \\
& \geq \sum_{k=1}^K \log \frac{\Gamma\left(\sum_{v=1}^V \hat{\beta}_v\right) \exp\left((\sum_{v=1}^V \hat{\beta}_v - \beta_v) b_k^\phi\right)}{\Gamma\left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right)} \prod_{v=1}^V \frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right)}{\Gamma(\hat{\beta}_v)} \hat{\beta}_v^{-a_{k,v}^\phi} \beta_v^{a_{k,v}^\phi} \\
& = \sum_{k=1}^K \left[\log \Gamma\left(\sum_{v=1}^V \hat{\beta}_v\right) + \left(\sum_{v=1}^V \hat{\beta}_v - \beta_v\right) b_k^\phi - \log \Gamma\left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right) \right. \\
& \quad \left. + \sum_{v=1}^V \left\{ \log \Gamma\left(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right) - \log \Gamma(\hat{\beta}_v) - a_{k,v}^\phi \log \hat{\beta}_v + a_{k,v}^\phi \log \beta_v \right\} \right] \\
& = \sum_{k=1}^K \left[-b_k^\phi \sum_{v=1}^V \beta_v + \sum_{v=1}^V a_{k,v}^\phi \log \beta_v \right] + (\text{const.}) \equiv F[\beta_v]
\end{aligned} \tag{1}$$

となる。(どうせ微分すると消えるので) β と関係しない項を (const.) とする。
この下限 $F[\beta_v]$ を最大にする β を求めるために、 β_v で微分して 0 となる停留点を求める。

$$\begin{aligned}
\frac{\partial F[\beta_v]}{\partial \beta_v} &= \sum_{k=1}^K \left[-b_k^\phi + \frac{1}{\beta_v} a_{k,v}^\phi \right] = 0 \\
\beta_v &= \frac{\sum_{k=1}^K a_{k,v}^\phi}{\sum_{k=1}^K b_k^\phi}
\end{aligned}$$

$a_{k,v}^\phi, b_k^\phi$ をそれぞれ代入すると

$$\beta_v = \hat{\beta}_v \frac{\sum_{k=1}^K \left[\Psi\left(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right) - \Psi(\hat{\beta}_v) \right]}{\sum_{k=1}^K \left[\Psi\left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}_v\right) - \Psi\left(\sum_{v=1}^V \hat{\beta}_v\right) \right]} \tag{3.192}$$

が得られる。

$\hat{\beta}_v$ を 1 ステップ前の値とすれば、 β_v に対する固定点反復法が得られた。

・対称

β は対称とした方が良い結果となることが経験的に知られている。全ての単語に対して同じ値 β を用いる場合の更新式も求める。

$\beta = (\beta, \beta, \dots, \beta)$ のとき、 $\sum_{v=1}^V \beta = V\beta$ なので、式 (1) は

$$\begin{aligned}
& \sum_{k=1}^K \log \frac{\Gamma(V\beta)}{\Gamma\left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta\right)} \prod_{v=1}^V \frac{\Gamma\left(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta\right)}{\Gamma(\beta)} \\
& \geq \sum_{k=1}^K \left[-b_k^\phi V\beta + \sum_{v=1}^V a_{k,v}^\phi \log \beta \right] + (\text{const.}) \equiv F[\beta]
\end{aligned} \tag{1}$$

となる。

$a_{k,v}^\phi, b_k^\phi$ をそれぞれ代入すると

$$F[\beta] \equiv \sum_{k=1}^K \left[- \left(\Psi \left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta} \right) - \Psi(V\hat{\beta}) \right) V\beta + \sum_{v=1}^V \left(\Psi(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}) - \Psi(\hat{\beta}) \right) \hat{\beta} \log \beta \right] + (\text{const.}) \quad (3.193)$$

β で微分して 0 となる停留点を求める。

$$\frac{\partial F[\beta]}{\partial \beta} = \sum_{k=1}^K \left[- \left(\Psi \left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta} \right) - \Psi(V\hat{\beta}) \right) V + \frac{1}{\beta} \sum_{v=1}^V \left(\Psi(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}) - \Psi(\hat{\beta}) \right) \hat{\beta} \right] = 0$$

これを解くと

$$\begin{aligned} V\beta \sum_{k=1}^K \left[\Psi \left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta} \right) - \Psi(V\hat{\beta}) \right] &= \hat{\beta} \sum_{k=1}^K \sum_{v=1}^V \left[\Psi(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}) - \Psi(\hat{\beta}) \right] \\ \beta &= \frac{\hat{\beta}}{V} \frac{\sum_{k=1}^K \sum_{v=1}^V \left[\Psi(\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta}) - \Psi(\hat{\beta}) \right]}{\sum_{k=1}^K \left[\Psi \left(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta} \right) - \Psi(V\hat{\beta}) \right]} \end{aligned} \quad (3.194)$$

が得られる。 (\sum_v, \sum_k) がどこまで影響するのか注意すること。例えば $\Psi(\sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \hat{\beta})$ は $\Psi(V\hat{\beta} + \sum_{v=1}^V \mathbb{E}_{q(\mathbf{z})}[n_{k,v}])$ である。))

3.6.4 ニュートン・ラフソン法

ニュートン・ラフソン法を用いて LDA のハイパーパラメータを推定する。

・変分下限の導出

3.3.6 項 (LDA の変分ベイズ法 (2)) の変分下限 (3.102) を用いる。

$$\begin{aligned}
F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\xi}^\theta, \boldsymbol{\xi}^\phi)] &= \sum_{k=1}^K \left[\log \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} - \log \frac{\Gamma(\sum_{v=1}^V \xi_{k,v}^\phi)}{\prod_{v=1}^V \Gamma(\xi_{k,v}^\phi)} \right] \\
&\quad + \sum_{k=1}^K \sum_{v=1}^V (\mathbb{E}_{q(\mathbf{z})}[n_{k,v}] + \beta_v - \xi_{k,v}^\phi) \mathbb{E}_{q(\boldsymbol{\phi}_k | \boldsymbol{\xi}_k^\phi)}[\log \phi_{k,v}] \\
&\quad + \sum_{d=1}^M \left[\log \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} - \log \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \right] \\
&\quad + \sum_{d=1}^M \sum_{k=1}^K (\mathbb{E}_{q(\mathbf{z}_d)}[n_{d,k}] + \alpha_k - \xi_{d,k}^\theta) \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k)
\end{aligned} \tag{3.102}$$

(次の微分で他の項は消えるので) ここから、 $\boldsymbol{\alpha}$ に関係のある項を取り出して

$$F[\boldsymbol{\alpha}] = \sum_{d=1}^M \left[\log \Gamma \left(\sum_{k=1}^K \alpha_k \right) - \sum_{k=1}^K \log \Gamma(\alpha_k) + \sum_{k=1}^K \alpha_k \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \right] \tag{3.195}$$

とおく。

よって、変分下限 (3.102) を $\boldsymbol{\alpha}$ で微分すると、プサイ関数を用いた Dirichlet 分布の期待値計算 (3.74) を用いて

$$\begin{aligned}
\frac{\partial F[\boldsymbol{\alpha}]}{\partial \alpha_k} &= \sum_{d=1}^M \left[\frac{\partial \log \Gamma \left(\sum_{k=1}^K \alpha_k \right)}{\partial \alpha_k} - \frac{\partial \log \Gamma(\alpha_k)}{\partial \alpha_k} + \mathbb{E}_{q(\boldsymbol{\theta}_d | \boldsymbol{\xi}_d^\theta)}[\log \theta_{d,k}] \right] \\
&= \sum_{d=1}^M \left[\Psi \left(\sum_{k=1}^K \alpha_k \right) - \Psi(\alpha_k) + \Psi(\xi_{d,k}^\theta) - \Psi \left(\sum_{k=1}^K \xi_{d,k}^\theta \right) \right] \\
&= M \left[\Psi \left(\sum_{k=1}^K \alpha_k \right) - \Psi(\alpha_k) \right] + \sum_{d=1}^M \left[\Psi(\xi_{d,k}^\theta) - \Psi \left(\sum_{k'=1}^K \xi_{d,k'}^\theta \right) \right]
\end{aligned} \tag{3.196}$$

となる。

最適化問題を解くために、 $\frac{\partial F[\boldsymbol{\alpha}]}{\partial \alpha_k}$ が 0 となる $\boldsymbol{\alpha}$ を求めたいが、この式を解析的に求めるのは困難である。そこで、ニュートン・ラフソン法と呼ばれる最適化手法を用いる。

・テイラー展開による近似

通常の勾配法では、1 次のテイラー展開により勾配の導出を行ったが、ニュートン・ラフソン法では、2 次のテイラー展開を行う。そのため、目的関数が持つ 2 次情報を勾配に利用することができる。

・ヘッセ行列

関数 $f(\mathbf{x})$, $\mathbf{x} = (x_1, x_2, \dots, x_N)$ を $\mathbf{x} = \mathbf{a}$ で2次までテイラー展開すると

$$f(\mathbf{x}) = f(\mathbf{a}) + (\mathbf{x} - \mathbf{a})^\top \frac{\partial}{\partial \mathbf{x}} f(\mathbf{x}) + \frac{1}{2} (\mathbf{x} - \mathbf{a})^\top \frac{\partial^2}{\partial \mathbf{x}^2} f(\mathbf{a}) (\mathbf{x} - \mathbf{a})$$

となる(たぶん)。ここで、2次偏導関数を並べた行列のことをヘッセ行列 $H(\mathbf{x})$ 呼ぶ。

$$H(\mathbf{x}) = \frac{\partial^2}{\partial \mathbf{x}^2} f(\mathbf{a}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_N} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{bmatrix}$$

ヘッセ行列の $k'k$ 成分は

$$H(\mathbf{x})_{k'k} = \frac{\partial^2}{\partial x_{k'} \partial x_k} f(\mathbf{x})$$

である。

$F[\alpha]$ を α の近傍点 $\hat{\alpha}$ を中心として2次のテイラー展開したものを $\tilde{F}[\alpha]$ とおく。

$$\begin{aligned} \tilde{F}[\alpha] &= F[\hat{\alpha}] + (\alpha - \hat{\alpha})^\top \left. \frac{\partial}{\partial \alpha} F[\alpha] \right|_{\alpha=\hat{\alpha}} + \frac{1}{2} (\alpha - \hat{\alpha})^\top \left. \frac{\partial^2}{\partial \alpha^2} F[\alpha] \right|_{\alpha=\hat{\alpha}} (\alpha - \hat{\alpha}) \\ &= F[\hat{\alpha}] + (\alpha - \hat{\alpha})^\top \left. \frac{\partial}{\partial \alpha} F[\alpha] \right|_{\alpha=\hat{\alpha}} + \frac{1}{2} (\alpha - \hat{\alpha})^\top H(\hat{\alpha}) (\alpha - \hat{\alpha}) \end{aligned} \quad (3.197)$$

($|_{\alpha=\hat{\alpha}}$ は $\hat{\alpha}$ の周りでテイラー展開したって示してるだけで深い意味はないですよ? 検索の仕方が分からないのでよく分かってないまま)

ヘッセ行列の $k'k$ 成分は

$$H(\hat{\alpha})_{k'k} = \left. \frac{\partial^2 F[\alpha]}{\partial \alpha_{k'} \partial \alpha_k} \right|_{\alpha=\hat{\alpha}} \quad (3.98)$$

である。

$F[\alpha]$ の近似式 $\tilde{F}[\alpha]$ も α で偏微分して $\mathbf{0}$ となる α を求める。

$$\begin{aligned} \frac{\partial \tilde{F}[\alpha]}{\partial \alpha} &= \dots = 0 \\ \alpha &= \hat{\alpha} - H^{-1}(\hat{\alpha}) g(\hat{\alpha}) \end{aligned} \quad (3.199)$$

(...線形代数と微積勉強しますちゃんとします)
ここで

$$g(\hat{\alpha}) = \left. \frac{\partial}{\partial \alpha} F[\alpha] \right|_{\alpha=\hat{\alpha}} \quad (3.200)$$

とおく。

式 (3.199) がハイパーパラメータの更新式になる。この計算を行うために、式に含まれるヘッセ行列の逆行列 $H^{-1}(\hat{\alpha})$ を求めていく。

・ヘッセ行列の逆行列の導出

トリガンマ関数

$$\Psi^{(1)}(x) = \frac{d}{dx} \Psi(x) = \frac{d^2}{dx^2} \log \Gamma(x)$$

を用いて、ヘッセ行列の $k'k$ 成分は、式 (3.196) より

$$\begin{aligned} H(\alpha)_{k'k} &= \frac{\partial^2 F[\alpha]}{\partial \alpha_{k'} \partial \alpha_k} = M \left[\frac{\partial}{\partial \alpha_{k'}} \Psi \left(\sum_{k=1}^K \alpha_k \right) - \frac{\partial}{\partial \alpha_{k'}} \Psi(\alpha_k) \right] \\ &= M \left[\Psi^{(1)} \left(\sum_{k=1}^K \alpha_k \right) - \delta(k' = k) \Psi^{(1)}(\alpha_k) \right] \end{aligned} \quad (3.201)$$

となる。後の因子は

$$\Psi^{(1)}(\alpha_k) = \frac{\partial}{\partial \alpha_k} \Psi(\alpha_k) = \frac{\partial}{\partial \alpha_k^2} \Gamma(\alpha_k) = \frac{\partial}{\partial \alpha_k^2} \alpha_k \Gamma(\alpha_k - 1)$$

である。つまり、 $k' \neq k$ のとき (α_k 以外の α で偏微分したとき) 0 になる。そこで、 $k' = k$ のとき 1 となり $k' \neq k$ のとき 0 となるデルタ関数 $\delta(k' = k)$ を用いている。

式 (3.201) の前の因子を

$$y = M \Psi^{(1)} \left(\sum_{k=1}^K \hat{\alpha}_k \right) \quad (3.203)$$

とおく。また、後ろの因子を

$$h_k = -M \Psi^{(1)}(\hat{\alpha}_k) \quad (3.202)$$

とおき、更に、 $\text{diag}(\mathbf{h})$ を $\mathbf{h} = (h_1, h_2, \dots, h_K)$ を対角要素とする対角行列とする。

これらと、K 個の 1 を要素とする行ベクトル

$$\mathbf{1}^\top = (1, 1, \dots, 1) \quad (3.204)$$

を用いて、式 (3.201) を参考に (k 成分以外を含めて)、ヘッセ行列 $H(\hat{\alpha})$ を

$$H(\hat{\alpha}) = \text{diag}(\mathbf{h}) + y\mathbf{1}\mathbf{1}^\top \quad (3.205)$$

とする。

次に

$$Y = \text{diag}(\mathbf{h})^{-1} - \frac{\text{diag}(\mathbf{h})^{-1}\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}}{\frac{1}{y} + \mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}\mathbf{1}} \quad (\text{A.4})$$

とおく。(何故こういう形なのかは深く考えない...と言うかこれが逆行列であることを求めていく。)
これを式 (3.205) と掛けると、単位行列を E として

$$\begin{aligned} H(\hat{\alpha})Y &= \left(\text{diag}(\mathbf{h}) + y\mathbf{1}\mathbf{1}^\top \right) \left(\text{diag}(\mathbf{h})^{-1} - \frac{\text{diag}(\mathbf{h})^{-1}\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}}{\frac{1}{y} + \mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}\mathbf{1}} \right) \\ &= E - \frac{\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}}{\frac{1}{y} + \mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}\mathbf{1}} + y\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} - \frac{y\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}}{\frac{1}{y} + \mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}\mathbf{1}} \\ &= E + y\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} - \frac{\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} + y\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}}{\frac{1}{y} + \mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}\mathbf{1}} \end{aligned}$$

となる。
ここで

$$\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}\mathbf{1} = \sum_{k=1}^K \frac{1}{h_k}$$

より、置き換えると

$$\begin{aligned} H(\hat{\alpha})Y &= E + y\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} - \frac{\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} + y\mathbf{1}\left(\sum_{k=1}^K \frac{1}{h_k}\right)\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}}{\frac{1}{y} + \sum_{k=1}^K \frac{1}{h_k}} \\ &= E + y\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} - \frac{\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} \left\{ 1 + y \left(\sum_{k=1}^K \frac{1}{h_k} \right) \right\}}{\frac{1}{y} + \sum_{k=1}^K \frac{1}{h_k}} \\ &= E + y\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} - \frac{\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} y \left\{ \frac{1}{y} + \sum_{k=1}^K \frac{1}{h_k} \right\}}{\frac{1}{y} + \sum_{k=1}^K \frac{1}{h_k}} \\ &= E + y\mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1} - \mathbf{1}\mathbf{1}^\top\text{diag}(\mathbf{h})^{-1}y \\ &= E \end{aligned} \quad (\text{A.5})$$

となる。
右逆行列の存在定理より

$$YH(\hat{\alpha}) = E$$

$$Y = H^{-1}(\hat{\alpha})$$

となる。

従って、式 (A.4) がヘッセ行列 $H(\hat{\alpha})$ の逆行列である。(逆行列の導出は難しい (あるいは紙面をとる) からこういう形で一応証明したということ?)

・ハイパーパラメータの更新式の導出

ヘッセ行列の逆行列

$$H^{-1}(\hat{\alpha}) = \text{diag}(\mathbf{h})^{-1} - \frac{\text{diag}(\mathbf{h})^{-1} \mathbf{1} \mathbf{1}^{\top} \text{diag}(\mathbf{h})^{-1}}{y^{-1} + \sum_{k=1}^K h_k^{-1}} \quad (3.206)$$

の kk 成分は

$$H^{-1}(\hat{\alpha})_{kk} = h_k^{-1} - \frac{h_k^{-1} \sum_{k=1}^K h_k^{-1}}{y^{-1} + \sum_{k=1}^K h_k^{-1}}$$

である (?)。

また、 $g(\hat{\alpha})$ の k 番目の要素 $g(\hat{\alpha})_k$ は $\frac{\partial F[\alpha]}{\partial \alpha_k}$ なので、式 (3.196) である。

これらを用いて、 $H^{-1}(\hat{\alpha})g(\hat{\alpha})$ の k 番目の要素 $\left(H^{-1}(\hat{\alpha})g(\hat{\alpha})\right)_k$ は

$$\begin{aligned} \left(H^{-1}(\hat{\alpha})g(\hat{\alpha})\right)_k &= \left(h_k^{-1} - \frac{h_k^{-1} \sum_{k=1}^K h_k^{-1}}{y^{-1} + \sum_{k=1}^K h_k^{-1}}\right) g(\hat{\alpha})_k \\ &= \left(\frac{1}{h_k} - \frac{1}{h_k} \frac{1}{y^{-1} + \sum_{k=1}^K h_k^{-1}} \sum_{k=1}^K \frac{1}{h_k}\right) g(\hat{\alpha})_k \\ &= \frac{g(\hat{\alpha})_k}{h_k} - \frac{1}{h_k} \frac{1}{y^{-1} + \sum_{k=1}^K h_k^{-1}} \sum_{k=1}^K \frac{g(\hat{\alpha})_k}{h_k} \end{aligned} \quad (3.207)$$

となる (??? 式が入れ子過ぎて整理できない)。(あと $g(\hat{\alpha})_k$ が \sum_k の影響下になるのは、 $\mathbf{1}^{\top} \text{diag}(\mathbf{h})^{-1} * g(\hat{\alpha})$ の計算を理解しないとイケないんでしょね)

従って、式 (3.199) より $\hat{\alpha}$ を 1 ステップ前の α とすると、 α の各要素の更新式は

$$\alpha_k^{(s+1)} = \alpha_k^{(s)} - \left(H^{-1}(\alpha^{(s)})g(\alpha^{(s)})\right)_k \quad (3.209)$$

が得られる。

単語分布のパラメータ β も同様に求めることができる。

3.6.5 逐次学習—確率的ニュートン・ラフソン法

ニュートン・ラフソン法において、文書ごとに勾配を求めることで LDA のハイパーパラメータを逐次更新する。

ニュートン・ラフソン法によるハイパーパラメータの更新式 (3.209) において、文書全体に関わる部分は $g_k(\boldsymbol{\alpha})$

$$g_k(\boldsymbol{\alpha}) = \frac{\partial F[\boldsymbol{\alpha}]}{\partial \alpha_k} = M \left[\Psi \left(\sum_{k=1}^K \alpha_k \right) - \Psi(\alpha_k) \right] + \sum_{d=1}^M \left[\Psi(\xi_{d,k}^\theta) - \Psi \left(\sum_{k'=1}^K \xi_{d,k'}^\theta \right) \right] \quad (3.210)$$

の後の因子である。

そこで、後ろの因子を

$$\sum_{d=1}^M \left[\Psi(\xi_{d,k}^\theta) - \Psi \left(\sum_{k'=1}^K \xi_{d,k'}^\theta \right) \right] = M \sum_{d=1}^M \frac{1}{M} \left[\Psi(\xi_{d,k}^\theta) - \Psi \left(\sum_{k'=1}^K \xi_{d,k'}^\theta \right) \right] \quad (3.210)$$

とする。

$p(d) = \frac{1}{M}$ とすると、 $d \sim p(d)$ としてサンプリングすることで、確率的勾配により

$$\tilde{g}_k(\boldsymbol{\alpha}) = \frac{\partial F[\boldsymbol{\alpha}]}{\partial \alpha_k} = M \left[\Psi \left(\sum_{k=1}^K \alpha_k \right) - \Psi(\alpha_k) \right] + M \left[\Psi(\xi_{d,k}^\theta) - \Psi \left(\sum_{k'=1}^K \xi_{d,k'}^\theta \right) \right] \quad (3.212)$$

と近似できる。

従って、s ステップ目のステップサイズを ν_s とすると、更新式

$$\boldsymbol{\alpha}^{(s+1)} = \boldsymbol{\alpha}^{(s)} - \nu_s H^{-1}(\boldsymbol{\alpha}^{(s)}) \tilde{g}(\boldsymbol{\alpha}^{(s)}) \quad (3.213)$$

が得られる。

単語分布のパラメータ $\boldsymbol{\beta}$ も同様に求めることができる。

3.6.6 周辺化ギブスサンプリング/変分ベイズ法の場合

LDA のハイパーパラメータを点推定する。

・周辺化ギブスサンプリングの場合

周辺化ギブスサンプリングでハイパーパラメータの推定を行う。

パラメータ ϕ , $\boldsymbol{\theta}$ を積分消去した周辺尤度 $p(\boldsymbol{w}, \boldsymbol{z} | \boldsymbol{\alpha}, \boldsymbol{\beta})$ を考える。

$$\begin{aligned}
p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \int p(\mathbf{w}, \mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\alpha}, \boldsymbol{\beta}) d\boldsymbol{\theta} d\boldsymbol{\phi} \\
&= \int p(\mathbf{w} | \boldsymbol{\phi}, \mathbf{z}) p(\mathbf{z} | \boldsymbol{\theta}) p(\boldsymbol{\phi} | \boldsymbol{\beta}) p(\boldsymbol{\theta} | \boldsymbol{\alpha}) d\boldsymbol{\theta} d\boldsymbol{\phi} \\
&= \int \left[\prod_{d=1}^M \prod_{i=1}^{N_d} p(w_{d,i} | \phi_{z_{d,i}}) p(z_{d,i} | \boldsymbol{\theta}_d) \right] \left[\prod_{k=1}^K p(\phi_k | \boldsymbol{\beta}) \right] \left[\prod_{d=1}^M p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) \right] d\boldsymbol{\theta} d\boldsymbol{\phi} \\
&= \int \prod_{k=1}^K \left[\prod_{v=1}^V \phi_{k,v}^{\sum_{d=1}^M \sum_{i=1}^{N_d} \delta(z_{d,i}=k, w_{d,i}=v)} \right] p(\phi_k | \boldsymbol{\beta}) d\phi_k \int \prod_{d=1}^M \left[\prod_{k=1}^K \theta_{d,k}^{\sum_{i=1}^{N_d} \delta(z_{d,i}=k)} \right] p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) d\boldsymbol{\theta}_d
\end{aligned} \tag{3.214}$$

それぞれ

$$\begin{aligned}
n_{k,v} &= \sum_{d=1}^M \sum_{i=1}^{N_d} \delta(z_{d,i} = k, w_{d,i} = v) \\
n_{d,k} &= \sum_{i=1}^{N_d} \delta(z_{d,i} = k)
\end{aligned}$$

とする。

$n_{k,v}$ は、トピック k が割り当てられた語彙 v の数を、デルタ関数を使って全文書の全単語について和をとることで求めたもの。 $n_{d,k}$ は、各文書においてトピック k が割り当てられた単語数を、デルタ関数を使って和をとることで求めたもの。

それぞれ置き換えると

$$\begin{aligned}
p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \int \prod_{k=1}^K \left[\prod_{v=1}^V \phi_{k,v}^{n_{k,v}} \right] p(\phi_k | \boldsymbol{\beta}) d\phi_k \int \prod_{d=1}^M \left[\prod_{k=1}^K \theta_{d,k}^{n_{d,k}} \right] p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) d\boldsymbol{\theta}_d \\
&= \int \prod_{k=1}^K \left[\prod_{v=1}^V \phi_{k,v}^{n_{k,v}} \right] \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} \prod_{v=1}^V \phi_{k,v}^{\beta_v-1} d\phi_k \int \prod_{d=1}^M \left[\prod_{k=1}^K \theta_{d,k}^{n_{d,k}} \right] \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K \theta_{d,k}^{\alpha_k-1} d\boldsymbol{\theta}_d \\
&= \int \prod_{k=1}^K \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} \prod_{v=1}^V \phi_{k,v}^{n_{k,v} + \beta_v - 1} d\phi_k \int \prod_{d=1}^M \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K \theta_{d,k}^{n_{d,k} + \alpha_k - 1} d\boldsymbol{\theta}_d
\end{aligned}$$

となる。

$\prod_{v=1}^V \phi_{k,v}^{n_{k,v} + \beta_v - 1}$, $\prod_{k=1}^K \theta_{d,k}^{n_{d,k} + \alpha_k - 1}$ のみ取り出すと、それぞれパラメータ $n_{k,v} + \beta_v - 1$, $n_{d,k} + \alpha_k - 1$ を持つ正規化項のない Dirichlet 分布とみることができる。よって定義より、正規化項の逆数の形に変形できる (そもそもこれの逆数が正規化項である)。

$$\begin{aligned}
p(\mathbf{w}, \mathbf{z} | \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \prod_{k=1}^K \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} \frac{\prod_{v=1}^V \Gamma(n_{k,v} + \beta_v)}{\Gamma(\sum_{v=1}^V n_{k,v} + \beta_v)} \prod_{d=1}^M \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \frac{\prod_{k=1}^K \Gamma(n_{d,k} + \alpha_k)}{\Gamma(\sum_{k=1}^K n_{d,k} + \alpha_k)} \\
&= \prod_{k=1}^K \left[\frac{\Gamma(\sum_{v=1}^V \beta_v)}{\Gamma(\sum_{v=1}^V n_{k,v} + \beta_v)} \prod_{v=1}^V \frac{\Gamma(n_{k,v} + \beta_v)}{\Gamma(\beta_v)} \right] \prod_{d=1}^M \left[\frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\Gamma(\sum_{k=1}^K n_{d,k} + \alpha_k)} \prod_{k=1}^K \frac{\Gamma(n_{d,k} + \alpha_k)}{\Gamma(\alpha_k)} \right]
\end{aligned} \tag{3.215}$$

対数を取り対数周辺尤度として、サンプリングした S 個のトピック $\mathbf{z}^{(s)}$ を用いると

$$\begin{aligned}\log p(\mathbf{w}, \mathbf{z}^{(s)} | \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \sum_{k=1}^K \log \left(\frac{\Gamma(\sum_{v=1}^V \beta_v)}{\Gamma(\sum_{v=1}^V n_{k,v}^{(s)} + \beta_v)} \prod_{v=1}^V \frac{\Gamma(n_{k,v}^{(s)} + \beta_v)}{\Gamma(\beta_v)} \right) \\ &\quad * \prod_{d=1}^M \log \left(\frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\Gamma(\sum_{k=1}^K n_{d,k}^{(s)} + \alpha_k)} \prod_{k=1}^K \frac{\Gamma(n_{d,k}^{(s)} + \alpha_k)}{\Gamma(\alpha_k)} \right)\end{aligned}$$

となる。
 サンプルの平均

$$\begin{aligned}\mathbb{E}[n_{k,v}] &= \frac{1}{S} \sum_{s=1}^S n_{k,v}^{(s)} \\ \mathbb{E}[n_{d,k}] &= \frac{1}{S} \sum_{s=1}^S n_{d,k}^{(s)}\end{aligned}$$

にそれぞれ置き換えると、(教科書の (このノートだと 3 行目を除いた)) 式 (3.182) となる。

従って、ハイパーパラメータの更新式は 3.6.3 項と同様にして求まる。
 また、単語分布のパラメータ $\boldsymbol{\beta}$ についても同様にして導出できる。

・変分ベイズ法の場合

変分ベイズ法でハイパーパラメータの推定を行う。

潜在トピック集合 \mathbf{z} とパラメータ $\boldsymbol{\phi}$, $\boldsymbol{\theta}$ を積分消去した周辺尤度 $p(\mathbf{w} | \boldsymbol{\alpha}, \boldsymbol{\beta})$ を考える。

$$\begin{aligned}p(\mathbf{w} | \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \int \sum_{\mathbf{z}} p(\mathbf{w}, \mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\phi} | \boldsymbol{\alpha}, \boldsymbol{\beta}) d\boldsymbol{\theta} d\boldsymbol{\phi} \\ &= \int \sum_{\mathbf{z}} p(\mathbf{w} | \boldsymbol{\phi}, \mathbf{z}) p(\mathbf{z} | \boldsymbol{\theta}) p(\boldsymbol{\phi} | \boldsymbol{\beta}) p(\boldsymbol{\theta} | \boldsymbol{\alpha}) d\boldsymbol{\theta} d\boldsymbol{\phi} \\ &= \int \prod_{d=1}^M \prod_{i=1}^{N_d} \sum_{k=1}^K p(w_{d,i} | z_{d,i} = k, \boldsymbol{\phi}_k) p(z_{d,i} = k | \boldsymbol{\theta}_d) p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) d\boldsymbol{\theta}_d \prod_{k=1}^K p(\boldsymbol{\phi}_k | \boldsymbol{\beta}) d\boldsymbol{\phi}_k \\ &= \int \prod_{d=1}^M \prod_{i=1}^{N_d} \sum_{k=1}^K (\phi_{k,w_{d,i}} \theta_{d,k}) p(\boldsymbol{\theta}_d | \boldsymbol{\alpha}) d\boldsymbol{\theta}_d \prod_{k=1}^K p(\boldsymbol{\phi}_k | \boldsymbol{\beta}) d\boldsymbol{\phi}_k\end{aligned}$$

$\sum_{k=1}^K \phi_{k,w_{d,i}} \theta_{d,k}$ を $\sum_{k=1}^K f(\phi, \theta)$ とおき、対数を取り、 $\frac{q(z_{d,i}=k)}{q(z_{d,i}=k)} = 1$ を掛けることで $q(z_{d,i} = k)$ を導入し、イエンセンの不等式を用いて

$$\begin{aligned}
\log \sum_{k=1}^K f(\phi, \theta) &= \log \sum_{k=1}^K q(z_{d,i} = k) \frac{f(\phi, \theta)}{q(z_{d,i} = k)} \\
&\geq \sum_{k=1}^K q(z_{d,i} = k) \log \frac{f(\phi, \theta)}{q(z_{d,i} = k)} \\
&= \log \prod_{k=1}^K \left(\frac{f(\phi, \theta)}{q(z_{d,i} = k)} \right)^{q(z_{d,i} = k)}
\end{aligned}$$

下限を求める。これを log を外して用いると

$$\begin{aligned}
p(\mathbf{w}|\boldsymbol{\alpha}, \boldsymbol{\beta}) &= \int \prod_{d=1}^M \prod_{i=1}^{N_d} \sum_{k=1}^K (\phi_{k,w_{d,i}} \theta_{d,k}) p(\boldsymbol{\theta}_d|\boldsymbol{\alpha}) d\boldsymbol{\theta}_d \prod_{k=1}^K p(\phi_k|\boldsymbol{\beta}) d\phi_k \\
&\geq \int \prod_{d=1}^M \prod_{i=1}^{N_d} \prod_{k=1}^K \left(\frac{\phi_{k,w_{d,i}} \theta_{d,k}}{q(z_{d,i} = k)} \right)^{q(z_{d,i} = k)} p(\boldsymbol{\theta}_d|\boldsymbol{\alpha}) d\boldsymbol{\theta}_d \prod_{k=1}^K p(\phi_k|\boldsymbol{\beta}) d\phi_k \\
&= \left[\prod_{k=1}^K \int \prod_{d=1}^M \prod_{i=1}^{N_d} \prod_{v=1}^V \phi_{k,v}^{q(z_{d,i}=k)\delta(w_{d,i}=v)} p(\phi_k|\boldsymbol{\beta}) d\phi_k \right] \left[\prod_{d=1}^M \int \prod_{i=1}^{N_d} \prod_{k=1}^K \theta_{d,k}^{q(z_{d,i}=k)} p(\boldsymbol{\theta}_d|\boldsymbol{\alpha}) d\boldsymbol{\theta}_d \right] \\
&\quad * \prod_{d=1}^M \prod_{i=1}^{N_d} \prod_{k=1}^K \left(\frac{1}{q(z_{d,i} = k)} \right)^{q(z_{d,i} = k)} \\
&= \left[\prod_{k=1}^K \int \prod_{v=1}^V \phi_{k,v}^{\sum_{d=1}^M \sum_{i=1}^{N_d} q(z_{d,i}=k)\delta(w_{d,i}=v)} p(\phi_k|\boldsymbol{\beta}) d\phi_k \right] \left[\prod_{d=1}^M \int \prod_{k=1}^K \theta_{d,k}^{\sum_{i=1}^{N_d} q(z_{d,i}=k)} p(\boldsymbol{\theta}_d|\boldsymbol{\alpha}) d\boldsymbol{\theta}_d \right] \\
&\quad * \prod_{d=1}^M \prod_{i=1}^{N_d} \prod_{k=1}^K \left(\frac{1}{q(z_{d,i} = k)} \right)^{q(z_{d,i} = k)}
\end{aligned}$$

となる。
それぞれ

$$\begin{aligned}
\mathbb{E}[n_{k,v}] &= \sum_{d=1}^M \sum_{i=1}^{N_d} q(z_{d,i} = k) \delta(w_{d,i} = v) \\
\mathbb{E}[n_{d,k}] &= \sum_{i=1}^{N_d} q(z_{d,i} = k)
\end{aligned}$$

とする。

$\mathbb{E}[n_{k,v}]$ は、トピック k が割り当てられた語彙 v の数の期待値を、各単語がトピック k となる確率 $q(z_{d,i} = k)$ を全文書の全単語について和をとることで求めたもの。ただし、デルタ関数を使って各単語をそれぞれの語彙に変換している。 $\mathbb{E}[n_{d,k}]$ は、各文書においてトピック k が割り当てられた単語数の期待値を、各単語がトピック k となる確率 $q(z_{d,i} = k)$ の全単語について和をとることで求めたもの。

それぞれ置き換えると

$$\begin{aligned}
p(\mathbf{w}|\boldsymbol{\alpha}, \boldsymbol{\beta}) &= \prod_{k=1}^K \left[\prod_{v=1}^V \phi_{k,v}^{\mathbb{E}[n_{k,v}]} \frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} \prod_{v=1}^V \phi_{k,v}^{\beta_v-1} \right] \prod_{d=1}^M \left[\prod_{k=1}^K \theta_{d,k}^{\mathbb{E}[n_{d,k}]} \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K \theta_{d,k}^{\alpha_k-1} \right] \\
&\quad * \prod_{d=1}^M \prod_{i=1}^{N_d} \prod_{k=1}^K \left(\frac{1}{q(z_{d,i}=k)} \right)^{q(z_{d,i}=k)} \\
&= \prod_{k=1}^K \left[\frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} \prod_{v=1}^V \phi_{k,v}^{\mathbb{E}[n_{k,v}]+\beta_v-1} \right] \prod_{d=1}^M \left[\frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K \theta_{d,k}^{\mathbb{E}[n_{d,k}]+\alpha_k-1} \right] \\
&\quad * \prod_{d=1}^M \prod_{i=1}^{N_d} \prod_{k=1}^K \left(\frac{1}{q(z_{d,i}=k)} \right)^{q(z_{d,i}=k)} \\
&= \prod_{k=1}^K \left[\frac{\Gamma(\sum_{v=1}^V \beta_v)}{\prod_{v=1}^V \Gamma(\beta_v)} \frac{\prod_{v=1}^V \Gamma(\mathbb{E}[n_{k,v}] + \beta_v)}{\Gamma(\sum_{v=1}^V \mathbb{E}[n_{k,v}] + \beta_v)} \right] \prod_{d=1}^M \left[\frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \frac{\prod_{k=1}^K \Gamma(\mathbb{E}[n_{d,k}] + \alpha_k)}{\Gamma(\sum_{k=1}^K \mathbb{E}[n_{d,k}] + \alpha_k)} \right] \\
&\quad * \prod_{d=1}^M \prod_{i=1}^{N_d} \prod_{k=1}^K \left(\frac{1}{q(z_{d,i}=k)} \right)^{q(z_{d,i}=k)} \\
&= \prod_{k=1}^K \left[\frac{\Gamma(\sum_{v=1}^V \beta_v)}{\Gamma(\sum_{v=1}^V \mathbb{E}[n_{k,v}] + \beta_v)} \prod_{v=1}^V \frac{\Gamma(\mathbb{E}[n_{k,v}] + \beta_v)}{\Gamma(\beta_v)} \right] \prod_{d=1}^M \left[\frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\Gamma(\sum_{k=1}^K \mathbb{E}[n_{d,k}] + \alpha_k)} \prod_{k=1}^K \frac{\Gamma(\mathbb{E}[n_{d,k}] + \alpha_k)}{\Gamma(\alpha_k)} \right] \\
&\quad * \prod_{d=1}^M \prod_{i=1}^{N_d} \prod_{k=1}^K \left(\frac{1}{q(z_{d,i}=k)} \right)^{q(z_{d,i}=k)} \tag{3.218}
\end{aligned}$$

となる。

対数をとると (教科書だと 3 行目を除くと) 式 (3.182) となる。

従って、ハイパーパラメータの更新式は 3.6.3 項と同様にして求まる。

また、単語分布のパラメータ $\boldsymbol{\beta}$ についても同様にして導出できる。

おわりに

あとがきまで読んでいただきありがとうございます。

年度内には疑似コードを R で実装します。

著者略歴

しよこ β (@anemptyarchive)

2020 年 2 月 線形代数と微分積分に入門

R4DS 修了

2020 年 3 月 疑似コードを R で組む

2020 年 4 月 Python に入門

白トピックモデルのノート

2020 年 2 月 2 日 初版 第 1 刷

著者 @anemptyarchive

発行者 anarchive-beta.com

製本 RStudio
